

Introdução à Mineração de Dados e KDD

Módulo 1

Prof. Elton Sarmanho¹
eltonss@ufpa.br

¹Faculdade de Sistemas de Informação – UFPA Campus Cametá

30 de junho de 2026

Roteiro

O que é Mineração de Dados

Evolução Histórica

Processo KDD

Tarefas de Mineração

Relação com Outras Disciplinas

Ferramentas

Ética e LGPD

Definição Formal

Definição Clássica (Fayyad et al., 1996)

Mineração de Dados é a extração de informação **implícita**, **previamente desconhecida** e **potencialmente útil** a partir de dados armazenados em grandes bases de dados.

Implícita

Não diretamente observável: requer inferência e busca.

Desconhecida

Novo conhecimento, que não confirma hipóteses já sabidas.

Útil

Valor prático ou teórico, passível de ação.

*Para detalhes, consulte o **Material Didático, Módulo 1.***

Exemplos Práticos

Netflix

Algoritmos de filtragem colaborativa recomendam filmes e séries, reduzindo o custo de retenção de assinantes.

Detecção de Fraude

Visa e Mastercard identificam transações suspeitas em tempo real, prevenindo bilhões em perdas anuais.


Medicina

Modelos preditivos auxiliam no diagnóstico precoce de câncer e diabetes a partir de imagens e histórico clínico.

Regra de Associação


“Clientes que comprem fraldas às sextas-feiras também tendem a comprar cerveja.”

Linha do Tempo da Mineração de Dados



Consulte o **Material Didático, Módulo 1** para detalhes de cada período.

Etapas do Processo KDD (Fayyad, 1996)



- 1. Seleção:** definir universo e fontes de dados
- 2. Pré-processamento:** tratar valores ausentes, outliers e inconsistências
(60–80% do esforço!)
- 3. Transformação:** normalização, encoding, feature engineering
- 4. Mineração:** aplicar algoritmos para descobrir padrões
- 5. Avaliação:** validar resultados com métricas e domínio
- 6. Utilização:** integrar o conhecimento a sistemas reais

Metodologia CRISP-DM



CRISP-DM (*Cross-Industry Standard Process for Data Mining*) é o padrão de facto na indústria.


- ▶ Foco no **negócio** desde o início
- ▶ Processo **cíclico** e iterativo
- ▶ Adotado por empresas e academia

Diferença para o KDD: O CRISP-DM incorpora explicitamente a perspectiva de negócios e é mais orientado à prática industrial.

Principais Tarefas de Mineração de Dados

Tarefa	Tipo	Exemplo de Aplicação
Classificação	Supervisionado	Detecção de spam; diagnóstico médico
Regressão	Supervisionado	Preço de imóvel; demanda futura
Agrupamento (Clustering)	Não Superv.	Segmentação de clientes
Regras de Associação	Não Superv.	Análise de cesta de compras
Detecção de Anomalias	Semi-Superv.	Fraude financeira; falha em equipamentos
Sumarização	N/A	Perfis de usuários; relatórios automáticos

Interdisciplinaridade



- ▶ **Estatística:** inferência, amostragem, modelos probabilísticos
- ▶ **Machine Learning:** algoritmos de aprendizado (árvores, redes neurais, SVM)
- ▶ **Bancos de Dados:** armazenamento, SQL, ETL, Data Warehouse
- ▶ **Rec. de Padrões:** extração de features, PCA, métricas de similaridade

Ecosistema Python para Mineração de Dados

Dados e Análise

- ▶ **NumPy**: arrays e computação numérica
- ▶ **Pandas**: manipulação de dados tabulares
- ▶ **SciPy**: algoritmos científicos e estatística

Visualização

- ▶ **Matplotlib**: gráficos estáticos 2D
- ▶ **Seaborn**: visualização estatística
- ▶ **Plotly**: visualizações interativas

Machine Learning

- ▶ **Scikit-learn**: ML clássico e pré-processamento
- ▶ **XGBoost / LightGBM**: gradient boosting de alta performance
- ▶ **PyTorch / TensorFlow**: deep learning

Explicabilidade e AutoML

- ▶ **SHAP**: Shapley values para interpretabilidade
- ▶ **PyCaret**: AutoML low-code

Ferramentas com Interface Gráfica (GUI)

WEKA

Univ. de Waikato (NZ). Centenas de algoritmos. Ideal para uso acadêmico e pedagógico.

KNIME

Open-source. Fluxo de trabalho visual por nós. Amplamente adotado na indústria farmacêutica e financeira.

RapidMiner

Plataforma drag-and-drop (versão community). Rápida construção de pipelines de DM.

Orange

Open-source (Univ. de Ljubljana). Interface visual excelente para ensino. Extensões para bioinformática e text mining.

Ética e Responsabilidade em Mineração de Dados

⚠ Atenção: Ética não é Opcional

Vieses em dados de treino podem causar discriminação sistemática. Ignorar a LGPD pode resultar em multas de até 2% do faturamento (limite de R\$ 50 milhões por infração).

⚖ Viés Algorítmico

Modelos treinados com dados históricos podem perpetuar desigualdades (ex.: caso COMPAS na Justiça americana).

🔒 Privacidade de Dados

Dados pessoais sensíveis exigem anonimização eficaz, consentimento informado e minimização de uso.

🔑 LGPD (Lei 13.709/2018)

Direitos dos titulares: acesso, correção, exclusão e portabilidade. Todo projeto com dados pessoais deve estar em conformidade.

👁 Transparência Algorítmica

O “direito de explicação” impõe restrições ao uso de modelos caixa-preta em contextos de alto impacto.

Referências e Material de Estudo

- [1] FAYYAD, U. et al. From Data Mining to Knowledge Discovery in Databases. *AI Magazine*, v.17, n.3, 1996.
- [2] HAN, J.; PEI, J.; KAMBER, M. *Data Mining: Concepts and Techniques*. 3.ed. Morgan Kaufmann, 2011.
- [3] WIRTH, R.; HIPPE, J. CRISP-DM: Towards a Standard Process Model for Data Mining. *PKDD*, 2000.
- [4] WITTEN, I. H. et al. *Data Mining: Practical ML Tools and Techniques*. 4.ed. Morgan Kaufmann, 2016.

Material Didático

Para aprofundamento em todos os tópicos desta aula, consulte:

Módulo 1: Introdução à Mineração de Dados e KDD

- ▶ Definições completas
- ▶ Exercícios práticos
- ▶ Código Python comentado
- ▶ Algoritmos detalhados