

Introdução à Mineração de Dados e KDD

Módulo 1

Prof. Elton Sarmanho¹
eltonss@ufpa.br

¹Faculdade de Sistemas de Informação – UFPA Campus Cametá

30 de junho de 2026

Objetivos de Aprendizagem

- ▶ **✓ Compreender** o conceito formal de Mineração de Dados e sua distinção em relação a BI, Estatística e ML
- ▶ **✓ Distinguir** os tipos de tarefas: classificação, regressão, agrupamento, associação, anomalias e sumarização
- ▶ **✓ Aplicar** o processo KDD e a metodologia CRISP-DM a problemas reais
- ▶ **✓ Analisar** a relação entre Mineração de Dados e Estatística, IA, BD e Reconhecimento de Padrões
- ▶ **✓ Construir** pipelines básicos com Python (Pandas, Scikit-learn, Matplotlib)
- ▶ **✓ Avaliar** criticamente o uso de DM sob perspectivas éticas, considerando viés e a LGPD
- ▶ **✓ Relacionar** o contexto histórico com o estado da arte atual (AutoML, XAI, LLMs)
- ▶ **✓ Identificar** as ferramentas especializadas para mineração de dados (WEKA, 

Roteiro

O que é Mineração de Dados

Evolução Histórica

Processo KDD

Tarefas de Mineração

Relação com Outras Disciplinas

Ferramentas

Estado da Arte

Ética e LGPD

Definição Formal

Definição Clássica (Fayyad et al., 1996)

Mineração de Dados é a extração de informação **implícita**, **previamente desconhecida** e **potencialmente útil** a partir de dados armazenados em grandes bases de dados.


🔍 Implícita

Não diretamente observável: requer **inferência e busca** — o padrão não aparece na simples leitura dos dados.

💡 Previamente Desconhecida

Novo conhecimento: **não** se trata de confirmar hipóteses já sabidas, mas de descobrir relações inesperadas.

Da Pirâmide de Dados ao Conhecimento



A Mineração de Dados transforma automaticamente **Dados** em **Conhecimento** acionável.

Exemplos Práticos de Mineração de Dados

Netflix com Filtragem Colaborativa

Algoritmos recomendam filmes e séries com base no histórico de visualizações, reduzindo o custo de retenção de assinantes.

Detecção de Fraude Financeira

Visa e Mastercard identificam transações suspeitas em tempo real, prevenindo bilhões de dólares em perdas anuais.

Medicina Preditiva

Modelos auxiliam no diagnóstico precoce de câncer e diabetes a partir de exames de imagem e histórico clínico.

Regra de Associação Clássica


“Clientes que compram fraldas às sextas-feiras também tendem a comprar cerveja.” → padrão inesperado e valiosa para posicionamento de prateleiras.

Distinção entre Conceitos Relacionados


Conceito	Foco Principal	Orientação	Exemplo de Uso
Business Intelligence	Relatórios e dashboards	Dados históricos	KPIs mensais de vendas
OLAP	Análise multidimensional	Dados agregados	Cubo de vendas por região e período
Estatística Clássica	Inferência e testes de hipótese	Amostras pequenas	Teste A/B de interface web
Machine Learning	Aprendizado a partir de dados	Preditivo e adaptativo	Classificação de spam
Mineração de Dados	Descoberta de padrões em grandes volumes	Exploratório e preditivo	Detecção de fraude em cartões
Big Data	Processamento de volumes massivos	Infraestrutura e escala	Análise de logs em tempo real

A Mineração de Dados destaca-se por seu foco **exploratório**: busca padrões *sem hipótese prévia*, em grandes volumes, combinando aspectos de ML, Estatística e BD.

Linha do Tempo da Mineração de Dados



Visão Geral



Processo **iterativo e interativo**: feedbacks podem reiniciar etapas anteriores. A etapa 4 (Mineração) é apenas **uma** das seis fases sendo dependente de todas as anteriores.

Etapas 1 a 3: Preparação dos Dados

Etapa 1: Seleção de Dados

Identificação e seleção dos dados relevantes. Define o universo de análise, escolhe as fontes (bancos transacionais, data warehouses, arquivos externos) e extrai o subconjunto a ser analisado. Uma boa seleção reduz ruído e custo computacional.

Etapa 2: Pré-processamento

⚠ 60–80% do esforço total

Limpeza e consolidação: tratamento de valores ausentes (imputação, remoção), identificação e tratamento de *outliers*, resolução de inconsistências e integração de múltiplas fontes.

Etapa 3: Transformação

Conversão para formato adequado ao algoritmo: normalização, *One-Hot Encoding*, *feature engineering*, redução de dimensionalidade (PCA, t-SNE) e discretização de variáveis contínuas.

Etapas 4 a 6: Mineração e Utilização

Etapa 4: Mineração de Dados

Aplicação de algoritmos para descobrir padrões, regras, clusters ou modelos nos dados transformados. A escolha depende da tarefa (classificação, regressão, agrupamento, associação) e dos objetivos do negócio.

Etapa 5: Interpretação e Avaliação

Validação dos padrões com métricas adequadas: acurácia, F1-score, AUC-ROC (classificação); RMSE, MAE (regressão). O domínio do negócio é fundamental para distinguir padrões genuínos de artefatos estatísticos.

Etapa 6: Utilização do Conhecimento

Integração do modelo a sistemas de produção. O conhecimento é incorporado as estratégias organizacionais. Novas descobertas frequentemente geram novas perguntas, **reiniciando o ciclo KDD**.

Metodologia CRISP-DM



CRISP-DM (*Cross-Industry Standard Process for Data Mining*)

Diferença para o KDD é que o CRISP-DM incorpora explicitamente a **perspectiva de negócios**.

CRISP-DM: As 6 Fases em Detalhe

1. **Entendimento do Negócio:** Definição precisa do problema, critérios de sucesso e viabilidade. *Um mal entendimento é a principal causa de falha em projetos de DM.*
2. **Entendimento dos Dados:** Coleta inicial, exploração (estatísticas descritivas, visualizações), identificação de problemas de qualidade.
3. **Preparação dos Dados:** Limpeza, *feature engineering*, divisão em treino/validação/teste. Corresponde as etapas 2 e 3 do KDD.
4. **Modelagem:** Seleção e aplicação de técnicas, ajuste de parâmetros, comparação de modelos. Frequentemente requer retorno a fase 3.
5. **Avaliação:** Verificação rigorosa dos critérios de negócio. A aprovação nesta fase autoriza a implantação.
6. **Implantação:** Integração ao ambiente de produção, monitoramento (*data drift*), documentação e lições aprendidas.

CRISP-DM: As 6 Fases em Detalhe

1. **Entendimento do Negócio:** Definição precisa do problema, critérios de sucesso e viabilidade. *Um mal entendimento é a principal causa de falha em projetos de DM.*
2. **Entendimento dos Dados:** Coleta inicial, exploração (estatísticas descritivas, visualizações), identificação de problemas de qualidade.
3. **Preparação dos Dados:** Limpeza, *feature engineering*, divisão em treino/validação/teste. Corresponde as etapas 2 e 3 do KDD.
4. **Modelagem:** Seleção e aplicação de técnicas, ajuste de parâmetros, comparação de modelos. Frequentemente requer retorno a fase 3.
5. **Avaliação:** Verificação rigorosa dos critérios de negócio. A aprovação nesta fase autoriza a implantação.
6. **Implantação:** Integração ao ambiente de produção, monitoramento (*data drift*), documentação e lições aprendidas.

CRISP-DM: As 6 Fases em Detalhe

1. **Entendimento do Negócio:** Definição precisa do problema, critérios de sucesso e viabilidade. *Um mal entendimento é a principal causa de falha em projetos de DM.*
2. **Entendimento dos Dados:** Coleta inicial, exploração (estatísticas descritivas, visualizações), identificação de problemas de qualidade.
3. **Preparação dos Dados:** Limpeza, *feature engineering*, divisão em treino/validação/teste. Corresponde as etapas 2 e 3 do KDD.
4. **Modelagem:** Seleção e aplicação de técnicas, ajuste de parâmetros, comparação de modelos. Frequentemente requer retorno a fase 3.
5. **Avaliação:** Verificação rigorosa dos critérios de negócio. A aprovação nesta fase autoriza a implantação.
6. **Implantação:** Integração ao ambiente de produção, monitoramento (*data drift*), documentação e lições aprendidas.

CRISP-DM: As 6 Fases em Detalhe

1. **Entendimento do Negócio:** Definição precisa do problema, critérios de sucesso e viabilidade. *Um mal entendimento é a principal causa de falha em projetos de DM.*
2. **Entendimento dos Dados:** Coleta inicial, exploração (estatísticas descritivas, visualizações), identificação de problemas de qualidade.
3. **Preparação dos Dados:** Limpeza, *feature engineering*, divisão em treino/validação/teste. Corresponde as etapas 2 e 3 do KDD.
4. **Modelagem:** Seleção e aplicação de técnicas, ajuste de parâmetros, comparação de modelos. Frequentemente requer retorno a fase 3.
5. **Avaliação:** Verificação rigorosa dos critérios de negócio. A aprovação nesta fase autoriza a implantação.
6. **Implantação:** Integração ao ambiente de produção, monitoramento (*data drift*), documentação e lições aprendidas.

CRISP-DM: As 6 Fases em Detalhe

1. **Entendimento do Negócio:** Definição precisa do problema, critérios de sucesso e viabilidade. *Um mal entendimento é a principal causa de falha em projetos de DM.*
2. **Entendimento dos Dados:** Coleta inicial, exploração (estatísticas descritivas, visualizações), identificação de problemas de qualidade.
3. **Preparação dos Dados:** Limpeza, *feature engineering*, divisão em treino/validação/teste. Corresponde as etapas 2 e 3 do KDD.
4. **Modelagem:** Seleção e aplicação de técnicas, ajuste de parâmetros, comparação de modelos. Frequentemente requer retorno a fase 3.
5. **Avaliação:** Verificação rigorosa dos critérios de negócio. A aprovação nesta fase autoriza a implantação.
6. **Implantação:** Integração ao ambiente de produção, monitoramento (*data drift*), documentação e lições aprendidas.


CRISP-DM: As 6 Fases em Detalhe

1. **Entendimento do Negócio:** Definição precisa do problema, critérios de sucesso e viabilidade. *Um mal entendimento é a principal causa de falha em projetos de DM.*
2. **Entendimento dos Dados:** Coleta inicial, exploração (estatísticas descritivas, visualizações), identificação de problemas de qualidade.
3. **Preparação dos Dados:** Limpeza, *feature engineering*, divisão em treino/validação/teste. Corresponde as etapas 2 e 3 do KDD.
4. **Modelagem:** Seleção e aplicação de técnicas, ajuste de parâmetros, comparação de modelos. Frequentemente requer retorno a fase 3.
5. **Avaliação:** Verificação rigorosa dos critérios de negócio. A aprovação nesta fase autoriza a implantação.
6. **Implantação:** Integração ao ambiente de produção, monitoramento (*data drift*), documentação e lições aprendidas.

Principais Tarefas de Mineração de Dados


Tarefa	Tipo	Exemplo de Aplicação
Classificação	Supervisionado	Detecção de spam; diagnóstico médico
Regressão	Supervisionado	Preço de imóvel; demanda futura
Agrupamento (Clustering)	Não Superv.	Segmentação de clientes
Regras de Associação	Não Superv.	Análise de cesta de compras
Detecção de Anomalias	Semi-Superv.	Fraude financeira; falha em equipamentos
Sumarização	N/A	Perfis de usuários; relatórios automáticos

Como Escolher a Tarefa Correta?



A escolha da tarefa deve ser guiada pelo **problema de negócio**, não pela familiaridade com um algoritmo específico.

Interdisciplinaridade da Mineração de Dados



A Inteligência Artificial também contribui com representações de conhecimento e, modernamente, com **LLMs** para mineração de texto.

Contribuições de Cada Disciplina

Estatística

Arcabouço teórico para inferência: distribuições de probabilidade, testes de hipótese, regressão e intervalos de confiança. Diferença-chave: a estatística parte de hipóteses *a priori*; a DM é **predominantemente exploratória**.

Machine Learning

Fornece os algoritmos centrais: Árvores de Decisão, Redes Neurais, SVM, K-Means, Random Forest, Gradient Boosting. Foco em **generalização e predição**; a DM foca também na **interpretabilidade** e descoberta de novo conhecimento.

Bancos de Dados

Infraestrutura de armazenamento, SQL, ETL (*Extract, Transform, Load*), Data Warehousing e modelagem dimensional (esquema estrela e floco de neve).

Reconhecimento de Padrões

Extração de features, análise de componentes principais (PCA) e métricas de similaridade amplamente usadas em tarefas de agrupamento e classificação.

Biblioteca	Finalidade	Uso em DM
NumPy	Computação numérica e arrays	Matrizes de dados e álgebra linear
Pandas	Manipulação de dados tabulares	Limpeza, seleção e transformação
Scikit-learn	ML clássico e pré-processamento	Classificação, clustering, métricas
Matplotlib / Seaborn	Visualização 2D e estatística	Exploração e apresentação dos dados
SciPy	Algoritmos científicos e estatística	Otimização, testes estatísticos
XGBoost / LightGBM	Gradient Boosting de alta performance	Competições e produção
PyTorch / TensorFlow	Deep Learning	Imagens, texto, séries temporais
SHAP	Explicabilidade (Shapley values)	Interpretação de predições

Ferramentas com Interface Gráfica (GUI)

WEKA

Centenas de algoritmos de classificação, regressão, clustering e seleção de atributos. Ideal para uso **acadêmico e pedagógico**.

KNIME

Open-source. Fluxo de trabalho visual por nós. Amplamente adotado na indústria **farmacêutica e financeira**. Integra Python, R e Spark.

RapidMiner

Plataforma drag-and-drop (versão community). Rápida construção de pipelines de DM **sem necessidade de código**.

Orange

Open-source. Interface visual excelente para ensino. Extensões para bioinformática e text mining.

Estado da Arte: AutoML

⚙ AutoML — Aprendizado Automático de Máquina

AutoML automatiza a **seleção de modelos**, engenharia de features e ajuste de hiperparâmetros, tornando o Machine Learning acessível a não especialistas.

- ▶ **AutoGluon** (Amazon): foca em benchmarks de alto desempenho para dados tabulares, texto e imagem, com ensembles automáticos
- ▶ **H2O AutoML**: constrói automaticamente um leaderboard de modelos e seleciona o melhor
- ▶ **TPOT**: usa programação genética para otimizar pipelines de Scikit-learn
- ▶ **Auto-sklearn 2.0**: aplica meta-aprendizado e Bayesian Optimization para seleção de algoritmos
- ▶ **PyCaret**: biblioteca Python low-code que facilita a comparação e o deploy de modelos

Estado da Arte: Explainable AI (XAI)

👁 Por que Interpretabilidade?

Em aplicações de alto impacto (crédito, saúde, justiça), modelos caixa-preta são insuficientes. A interpretabilidade é requisito **ético e legal** (LGPD, GDPR).

- ▶ **SHAP** (Lundberg & Lee, 2017): baseado na teoria dos jogos cooperativos. Atribui contribuições individuais a cada *feature* para uma predição.
- ▶ **LIME** (Ribeiro et al., 2016): aproxima qualquer modelo caixa-preta por um modelo interpretável localmente, em torno de uma instância específica.
- ▶ **Grad-CAM**: para visão computacional, destaca as regiões da imagem que mais influenciaram a predição.
- ▶ **Counterfactual Explanations**: responde “o que teria que mudar para obter uma predição diferente?”

Estado da Arte: Federated Learning

🔒 Aprendizado Federado (McMahan et al., 2017)

Permite treinar modelos **sem centralizar dados sensíveis**. Os dados permanecem nos dispositivos locais (smartphones, hospitais, bancos); apenas gradientes são compartilhados com o servidor central.

- ▶ **Alta relevância:** contexto da LGPD brasileira e do GDPR europeu
- ▶ **Aplicações:** teclados preditivos (Google Gboard), detecção de fraude bancária distribuída, diagnóstico médico federado
- ▶ **Desafios:**
 - ▶ Heterogeneidade dos dados entre clientes (*non-IID*)
 - ▶ Comunicação eficiente entre dispositivos e servidor
 - ▶ Robustez a ataques (*envenenamento de gradientes*)

Estado da Arte: LLMs em Mineração de Dados

🗨️ Grandes Modelos de Linguagem (LLMs)

GPT-4, Llama 3 e Gemini estão abrindo novas possibilidades para a mineração de dados além do texto puro.

- ▶ **Text Mining Avançado:** superam TF-IDF e Word2Vec em classificação de texto, análise de sentimentos e extração de entidades
- ▶ **Data Augmentation:** geração sintética de dados para treinar modelos em domínios com poucos exemplos (*few-shot learning*)
- ▶ **Feature Engineering Automático:** geração de descrições semânticas de features e embeddings ricos para dados tabulares
- ▶ **Análise Conversacional:** ferramentas como Code Interpreter (OpenAI) permitem interagir com dados usando **linguagem natural**

Ética e Responsabilidade em Mineração de Dados

⚠ Atenção: Ética não é Opcional

Vieses em dados de treino podem causar discriminação sistemática. Ignorar a LGPD pode resultar em multas de até 2% do faturamento (limite de R\$ 50 milhões por infração).

⚖ Viés Algorítmico (*Algorithmic Bias*)

Modelos treinados com dados históricos podem perpetuar e amplificar desigualdades existentes. Exemplo: sistema COMPAS usado na Justiça americana apresentou tendência contra réus negros ao prever reincidência criminal.

🔒 Privacidade de Dados

Dados pessoais sensíveis exigem **anonimização eficaz**, consentimento informado e minimização do uso que são princípios centrais da LGPD.

LGPD e Transparência Algorítmica

🔗 LGPD — Lei Geral de Proteção de Dados (Lei 13.709/2018)

Inspirada no GDPR europeu. Estabelece:

- ▶ **Direitos dos titulares:** acesso, correção, exclusão e portabilidade dos dados pessoais
- ▶ **Obrigações:** controladores e operadores devem garantir conformidade em todo o ciclo de vida dos dados
- ▶ **Penalidades:** multas de até 2% do faturamento (R\$ 50 milhões por infração)

👁️ Transparência Algorítmica

O “direito de explicação” impõe restrições ao uso de modelos caixa-preta em contextos de alto impacto. Decisões automatizadas significativas **devem poder ser explicadas** aos titulares afetados. Isso favorece o uso de XAI (SHAP, LIME) em sistemas de crédito, saúde e seleção de pessoal.

Fairness e Responsabilidade (Accountability)

Fairness em ML: Métricas de Equidade

- ▶ **Demographic Parity:** taxa de predições positivas deve ser igual entre grupos demográficos
- ▶ **Equalized Odds:** TVP e TFP iguais entre grupos protegidos (gênero, raça, etc.)
- ▶ **Individual Fairness:** indivíduos similares devem receber predições similares

Atenção: algumas dessas métricas são matematicamente incompatíveis entre si (impossibilidade de Fairness).

? Responsabilidade (Accountability)

Quando um modelo causa dano, quem é responsável: o **desenvolvedor** do algoritmo, a **empresa** que o implantou ou o **usuário** que tomou a decisão final? A ausência de frameworks claros é uma lacuna ética e legal importante que o profissional de dados deve considerar.

Referências e Material de Estudo

- [1] FAYYAD, U. et al. From Data Mining to Knowledge Discovery in Databases. *AI Magazine*, v.17, n.3, 1996.
- [2] HAN, J.; PEI, J.; KAMBER, M. *Data Mining: Concepts and Techniques*. 3.ed. Morgan Kaufmann, 2011.
- [3] WIRTH, R.; HIPPIE, J. CRISP-DM: Towards a Standard Process Model for Data Mining. *PKDD*, 2000.
- [4] WITTEN, I. H. et al. *Data Mining: Practical ML Tools and Techniques*. 4.ed. Morgan Kaufmann, 2016.
- [5] LUNDBERG, S. M.; LEE, S.-I. A Unified Approach to Interpreting Model Predictions. *NeurIPS*, 2017.
- [6] McMAHAN, B. et al. Communication-Efficient Learning of Deep Networks from Decentralized Data. *AISTATS*, 2017.