

Introdução à Mineração de Dados e KDD

Módulo 1

Prof. Elton Sarmanho¹
eltonss@ufpa.br

¹Faculdade de Sistemas de Informação – UFPA Campus Cametá

30 de junho de 2026

Objetivos de Aprendizagem

- ▶ **✓ Compreender** o conceito formal de Mineração de Dados e sua distinção em relação a BI, Estatística e ML
- ▶ **✓ Distinguir** os tipos de tarefas: classificação, regressão, agrupamento, associação, anomalias e sumarização
- ▶ **✓ Aplicar** o processo KDD e a metodologia CRISP-DM a problemas reais
- ▶ **✓ Analisar** a relação entre Mineração de Dados e Estatística, IA, BD e Reconhecimento de Padrões
- ▶ **✓ Construir** pipelines básicos com Python (Pandas, Scikit-learn, Matplotlib)
- ▶ **✓ Avaliar** criticamente o uso de DM sob perspectivas éticas, considerando viés e a LGPD
- ▶ **✓ Relacionar** o contexto histórico com o estado da arte atual (AutoML, XAI, LLMs)
- ▶ **✓ Identificar** as ferramentas especializadas para mineração de dados (WEKA, 

Roteiro

O que é Mineração de Dados

Evolução Histórica

Processo KDD

Tarefas de Mineração

Relação com Outras Disciplinas

Ferramentas

Estado da Arte

Ética e LGPD

Definição Formal

Definição Clássica (Fayyad et al., 1996)

Mineração de Dados é a extração de informação **implícita**, **previamente desconhecida** e **potencialmente útil** a partir de dados armazenados em grandes bases de dados.


Q Implícita

Não diretamente observável: requer **inferência e busca** — o padrão não aparece na simples leitura dos dados.

💡 Previamente Desconhecida

Novo conhecimento: **não** se trata de confirmar hipóteses já sabidas, mas de descobrir relações inesperadas.

Da Pirâmide de Dados ao Conhecimento



A Mineração de Dados transforma automaticamente **Dados** em **Conhecimento** acionável.

Exemplos Práticos de Mineração de Dados

Netflix com Filtragem Colaborativa

Algoritmos recomendam filmes e séries com base no histórico de visualizações, reduzindo o custo de retenção de assinantes.

Detecção de Fraude Financeira

Visa e Mastercard identificam transações suspeitas em tempo real, prevenindo bilhões de dólares em perdas anuais.

Medicina Preditiva

Modelos auxiliam no diagnóstico precoce de câncer e diabetes a partir de exames de imagem e histórico clínico.

Regra de Associação Clássica


“Clientes que compram fraldas às sextas-feiras também tendem a comprar cerveja.” → padrão inesperado e valiosa para posicionamento de prateleiras.

Distinção entre Conceitos Relacionados


Conceito	Foco Principal	Orientação	Exemplo de Uso
Business Intelligence	Relatórios e dashboards	Dados históricos	KPIs mensais de vendas
OLAP	Análise multidimensional	Dados agregados	Cubo de vendas por região e período
Estatística Clássica	Inferência e testes de hipótese	Amostras pequenas	Teste A/B de interface web
Machine Learning	Aprendizado a partir de dados	Preditivo e adaptativo	Classificação de spam
Mineração de Dados	Descoberta de padrões em grandes volumes	Exploratório e preditivo	Detecção de fraude em cartões
Big Data	Processamento de volumes massivos	Infraestrutura e escala	Análise de logs em tempo real

A Mineração de Dados destaca-se por seu foco **exploratório**: busca padrões *sem hipótese prévia*, em grandes volumes, combinando aspectos de ML, Estatística e BD.

Linha do Tempo da Mineração de Dados



Visão Geral



Processo **iterativo e interativo**: feedbacks podem reiniciar etapas anteriores. A etapa 4 (Mineração) é apenas **uma** das seis fases sendo dependente de todas as anteriores.

Etapas 1 a 3: Preparação dos Dados

Etapa 1: Seleção de Dados

Identificação e seleção dos dados relevantes. Define o universo de análise, escolhe as fontes (bancos transacionais, data warehouses, arquivos externos) e extrai o subconjunto a ser analisado. Uma boa seleção reduz ruído e custo computacional.

Etapa 2: Pré-processamento

⚠ 60–80% do esforço total

Limpeza e consolidação: tratamento de valores ausentes (imputação, remoção), identificação e tratamento de *outliers*, resolução de inconsistências e integração de múltiplas fontes.

Etapa 3: Transformação

Conversão para formato adequado ao algoritmo: normalização, *One-Hot Encoding*, *feature engineering*, redução de dimensionalidade (PCA, t-SNE) e discretização de variáveis contínuas.

Etapas 4 a 6: Mineração e Utilização

Etapa 4: Mineração de Dados

Aplicação de algoritmos para descobrir padrões, regras, clusters ou modelos nos dados transformados. A escolha depende da tarefa (classificação, regressão, agrupamento, associação) e dos objetivos do negócio.

Etapa 5: Interpretação e Avaliação

Validação dos padrões com métricas adequadas: acurácia, F1-score, AUC-ROC (classificação); RMSE, MAE (regressão). O domínio do negócio é fundamental para distinguir padrões genuínos de artefatos estatísticos.

Etapa 6: Utilização do Conhecimento

Integração do modelo a sistemas de produção. O conhecimento é incorporado as estratégias organizacionais. Novas descobertas frequentemente geram novas perguntas, **reiniciando o ciclo KDD**.

Metodologia CRISP-DM



CRISP-DM (*Cross-Industry Standard Process for Data Mining*)

Diferença para o KDD é que o CRISP-DM incorpora explicitamente a **perspectiva de negócios**.

CRISP-DM: As 6 Fases em Detalhe

1. **Entendimento do Negócio:** Definição precisa do problema, critérios de sucesso e viabilidade. *Um mal entendimento é a principal causa de falha em projetos de DM.*
2. **Entendimento dos Dados:** Coleta inicial, exploração (estatísticas descritivas, visualizações), identificação de problemas de qualidade.
3. **Preparação dos Dados:** Limpeza, *feature engineering*, divisão em treino/validação/teste. Corresponde as etapas 2 e 3 do KDD.
4. **Modelagem:** Seleção e aplicação de técnicas, ajuste de parâmetros, comparação de modelos. Frequentemente requer retorno a fase 3.
5. **Avaliação:** Verificação rigorosa dos critérios de negócio. A aprovação nesta fase autoriza a implantação.
6. **Implantação:** Integração ao ambiente de produção, monitoramento (*data drift*), documentação e lições aprendidas.

CRISP-DM: As 6 Fases em Detalhe

1. **Entendimento do Negócio:** Definição precisa do problema, critérios de sucesso e viabilidade. *Um mal entendimento é a principal causa de falha em projetos de DM.*
2. **Entendimento dos Dados:** Coleta inicial, exploração (estatísticas descritivas, visualizações), identificação de problemas de qualidade.
3. **Preparação dos Dados:** Limpeza, *feature engineering*, divisão em treino/validação/teste. Corresponde as etapas 2 e 3 do KDD.
4. **Modelagem:** Seleção e aplicação de técnicas, ajuste de parâmetros, comparação de modelos. Frequentemente requer retorno a fase 3.
5. **Avaliação:** Verificação rigorosa dos critérios de negócio. A aprovação nesta fase autoriza a implantação.
6. **Implantação:** Integração ao ambiente de produção, monitoramento (*data drift*), documentação e lições aprendidas.

CRISP-DM: As 6 Fases em Detalhe

1. **Entendimento do Negócio:** Definição precisa do problema, critérios de sucesso e viabilidade. *Um mal entendimento é a principal causa de falha em projetos de DM.*
2. **Entendimento dos Dados:** Coleta inicial, exploração (estatísticas descritivas, visualizações), identificação de problemas de qualidade.
3. **Preparação dos Dados:** Limpeza, *feature engineering*, divisão em treino/validação/teste. Corresponde as etapas 2 e 3 do KDD.
4. **Modelagem:** Seleção e aplicação de técnicas, ajuste de parâmetros, comparação de modelos. Frequentemente requer retorno a fase 3.
5. **Avaliação:** Verificação rigorosa dos critérios de negócio. A aprovação nesta fase autoriza a implantação.
6. **Implantação:** Integração ao ambiente de produção, monitoramento (*data drift*), documentação e lições aprendidas.

CRISP-DM: As 6 Fases em Detalhe

1. **Entendimento do Negócio:** Definição precisa do problema, critérios de sucesso e viabilidade. *Um mal entendimento é a principal causa de falha em projetos de DM.*
2. **Entendimento dos Dados:** Coleta inicial, exploração (estatísticas descritivas, visualizações), identificação de problemas de qualidade.
3. **Preparação dos Dados:** Limpeza, *feature engineering*, divisão em treino/validação/teste. Corresponde as etapas 2 e 3 do KDD.
4. **Modelagem:** Seleção e aplicação de técnicas, ajuste de parâmetros, comparação de modelos. Frequentemente requer retorno a fase 3.
5. **Avaliação:** Verificação rigorosa dos critérios de negócio. A aprovação nesta fase autoriza a implantação.
6. **Implantação:** Integração ao ambiente de produção, monitoramento (*data drift*), documentação e lições aprendidas.

CRISP-DM: As 6 Fases em Detalhe

1. **Entendimento do Negócio:** Definição precisa do problema, critérios de sucesso e viabilidade. *Um mal entendimento é a principal causa de falha em projetos de DM.*
2. **Entendimento dos Dados:** Coleta inicial, exploração (estatísticas descritivas, visualizações), identificação de problemas de qualidade.
3. **Preparação dos Dados:** Limpeza, *feature engineering*, divisão em treino/validação/teste. Corresponde as etapas 2 e 3 do KDD.
4. **Modelagem:** Seleção e aplicação de técnicas, ajuste de parâmetros, comparação de modelos. Frequentemente requer retorno a fase 3.
5. **Avaliação:** Verificação rigorosa dos critérios de negócio. A aprovação nesta fase autoriza a implantação.
6. **Implantação:** Integração ao ambiente de produção, monitoramento (*data drift*), documentação e lições aprendidas.


CRISP-DM: As 6 Fases em Detalhe

1. **Entendimento do Negócio:** Definição precisa do problema, critérios de sucesso e viabilidade. *Um mal entendimento é a principal causa de falha em projetos de DM.*
2. **Entendimento dos Dados:** Coleta inicial, exploração (estatísticas descritivas, visualizações), identificação de problemas de qualidade.
3. **Preparação dos Dados:** Limpeza, *feature engineering*, divisão em treino/validação/teste. Corresponde as etapas 2 e 3 do KDD.
4. **Modelagem:** Seleção e aplicação de técnicas, ajuste de parâmetros, comparação de modelos. Frequentemente requer retorno a fase 3.
5. **Avaliação:** Verificação rigorosa dos critérios de negócio. A aprovação nesta fase autoriza a implantação.
6. **Implantação:** Integração ao ambiente de produção, monitoramento (*data drift*), documentação e lições aprendidas.

Principais Tarefas de Mineração de Dados


Tarefa	Tipo	Exemplo de Aplicação
Classificação	Supervisionado	Detecção de spam; diagnóstico médico
Regressão	Supervisionado	Preço de imóvel; demanda futura
Agrupamento (Clustering)	Não Superv.	Segmentação de clientes
Regras de Associação	Não Superv.	Análise de cesta de compras
Detecção de Anomalias	Semi-Superv.	Fraude financeira; falha em equipamentos
Sumarização	N/A	Perfis de usuários; relatórios automáticos

Como Escolher a Tarefa Correta?



A escolha da tarefa deve ser guiada pelo **problema de negócio**, não pela familiaridade com um algoritmo específico.

Interdisciplinaridade da Mineração de Dados



A Inteligência Artificial também contribui com representações de conhecimento e, modernamente, com **LLMs** para mineração de texto.

Contribuições de Cada Disciplina

Estatística

Arcabouço teórico para inferência: distribuições de probabilidade, testes de hipótese, regressão e intervalos de confiança. Diferença-chave: a estatística parte de hipóteses *a priori*; a DM é **predominantemente exploratória**.

Machine Learning

Fornece os algoritmos centrais: Árvores de Decisão, Redes Neurais, SVM, K-Means, Random Forest, Gradient Boosting. Foco em **generalização e predição**; a DM foca também na **interpretabilidade** e descoberta de novo conhecimento.

Bancos de Dados

Infraestrutura de armazenamento, SQL, ETL (*Extract, Transform, Load*), Data Warehousing e modelagem dimensional (esquema estrela e floco de neve).

Ecosistema Python para Mineração de Dados

Biblioteca	Finalidade	Uso em DM
NumPy	Computação numérica e arrays	Matrizes de dados e álgebra linear
Pandas	Manipulação de dados tabulares	Limpeza, seleção e transformação
Scikit-learn	ML clássico e pré-processamento	Classificação, clustering, métricas
Matplotlib / Seaborn	Visualização 2D e estatística	Exploração e apresentação dos dados
SciPy	Algoritmos científicos e estatística	Otimização, testes estatísticos
XGBoost / LightGBM	Gradient Boosting de alta performance	Competições e produção
PyTorch / TensorFlow	Deep Learning	Imagens, texto, séries temporais
SHAP	Explicabilidade (Shapley values)	Interpretação de predições

Ferramentas com Interface Gráfica (GUI)

WEKA (Univ. de Waikato, NZ)

Centenas de algoritmos de classificação, regressão, clustering e seleção de atributos. Ideal para uso **acadêmico e pedagógico**.

KNIME

Open-source. Fluxo de trabalho visual por nós. Amplamente adotado na indústria **farmacêutica e financeira**. Integra Python, R e Spark.

RapidMiner

Plataforma drag-and-drop (versão community). Rápida construção de pipelines de DM **sem necessidade de código**.

Orange (Univ. de Ljubljana)

Estado da Arte: AutoML

⚙ AutoML — Aprendizado Automático de Máquina

AutoML automatiza a **seleção de modelos**, engenharia de features e ajuste de hiperparâmetros, tornando o Machine Learning acessível a não especialistas.

- ▶ **AutoGluon** (Amazon): foca em benchmarks de alto desempenho para dados tabulares, texto e imagem, com ensembles automáticos
- ▶ **H2O AutoML**: constrói automaticamente um leaderboard de modelos e seleciona o melhor
- ▶ **TPOT**: usa programação genética para otimizar pipelines de Scikit-learn
- ▶ **Auto-sklearn 2.0**: aplica meta-aprendizado e Bayesian Optimization para seleção de algoritmos
- ▶ **PyCaret**: biblioteca Python low-code que facilita a comparação e o deploy de modelos

Estado da Arte: Explainable AI (XAI)

👁 Por que Interpretabilidade?

Em aplicações de alto impacto (crédito, saúde, justiça), modelos caixa-preta são insuficientes. A interpretabilidade é requisito **ético e legal** (LGPD, GDPR).

- ▶ **SHAP** (Lundberg & Lee, 2017): baseado na teoria dos jogos cooperativos. Atribui contribuições individuais a cada *feature* para uma predição. Agnóstico ao modelo e matematicamente consistente.
- ▶ **LIME** (Ribeiro et al., 2016): aproxima qualquer modelo caixa-preta por um modelo interpretável localmente, em torno de uma instância específica.
- ▶ **Grad-CAM**: para visão computacional, destaca as regiões da imagem que mais influenciaram a predição.
- ▶ **Counterfactual Explanations**: responde “o que teria que mudar para obter uma predição diferente?”

Estado da Arte: Federated Learning

🔒 Aprendizado Federado (McMahan et al., 2017)

Permite treinar modelos **sem centralizar dados sensíveis**. Os dados permanecem nos dispositivos locais (smartphones, hospitais, bancos); apenas gradientes são compartilhados com o servidor central.

- ▶ **Alta relevância:** contexto da LGPD brasileira e do GDPR europeu
- ▶ **Aplicações:** teclados preditivos (Google Gboard), detecção de fraude bancária distribuída, diagnóstico médico federado
- ▶ **Desafios:**
 - ▶ Heterogeneidade dos dados entre clientes (*non-IID*)
 - ▶ Comunicação eficiente entre dispositivos e servidor
 - ▶ Robustez a ataques (*envenenamento de gradientes*)

Estado da Arte: LLMs em Mineração de Dados

🗨️ Grandes Modelos de Linguagem (LLMs)

GPT-4, Llama 3 e Gemini estão abrindo novas possibilidades para a mineração de dados além do texto puro.

- ▶ **Text Mining Avançado:** superam TF-IDF e Word2Vec em classificação de texto, análise de sentimentos e extração de entidades
- ▶ **Data Augmentation:** geração sintética de dados para treinar modelos em domínios com poucos exemplos (*few-shot learning*)
- ▶ **Feature Engineering Automático:** geração de descrições semânticas de features e embeddings ricos para dados tabulares
- ▶ **Análise Conversacional:** ferramentas como Code Interpreter (OpenAI) permitem interagir com dados usando **linguagem natural**

Ética e Responsabilidade em Mineração de Dados

⚠ Atenção: Ética não é Opcional

Vieses em dados de treino podem causar discriminação sistemática. Ignorar a LGPD pode resultar em multas de até 2% do faturamento (limite de R\$ 50 milhões por infração).

⚖ Viés Algorítmico (*Algorithmic Bias*)

Modelos treinados com dados históricos podem perpetuar e amplificar desigualdades existentes. Exemplo: sistema COMPAS usado na Justiça americana apresentou tendência contra réus negros ao prever reincidência criminal.

🔒 Privacidade de Dados

Dados pessoais sensíveis exigem **anonimização eficaz**, consentimento informado e minimização do uso — princípios centrais da LGPD.

LGPD e Transparência Algorítmica

🔗 LGPD — Lei Geral de Proteção de Dados (Lei 13.709/2018)

Inspirada no GDPR europeu. Estabelece:

- ▶ **Direitos dos titulares:** acesso, correção, exclusão e portabilidade dos dados pessoais
- ▶ **Obrigações:** controladores e operadores devem garantir conformidade em todo o ciclo de vida dos dados
- ▶ **Penalidades:** multas de até 2% do faturamento (R\$ 50 milhões por infração)

👁️ Transparência Algorítmica

O “direito de explicação” impõe restrições ao uso de modelos caixa-preta em contextos de alto impacto. Decisões automatizadas significativas **devem poder ser explicadas** aos titulares afetados. Isso favorece o uso de XAI (SHAP, LIME) em sistemas de

Fairness e Responsabilidade (*Accountability*)

Fairness em ML — Métricas de Equidade

- ▶ **Demographic Parity:** taxa de predições positivas deve ser igual entre grupos demográficos
- ▶ **Equalized Odds:** TVP e TFP iguais entre grupos protegidos (gênero, raça, etc.)
- ▶ **Individual Fairness:** indivíduos similares devem receber predições similares

Atenção: algumas dessas métricas são matematicamente incompatíveis entre si (impossibilidade de Fairness).

? Responsabilidade (*Accountability*)

Quando um modelo causa dano, quem é responsável: o **desenvolvedor** do algoritmo, a **empresa** que o implantou ou o **usuário** que tomou a decisão final? A ausência de frameworks claros é uma lacuna ética e legal importante que o profissional de dados

Referências e Material de Estudo

- [1] FAYYAD, U. et al. From Data Mining to Knowledge Discovery in Databases. *AI Magazine*, v.17, n.3, 1996.
- [2] HAN, J.; PEI, J.; KAMBER, M. *Data Mining: Concepts and Techniques*. 3.ed. Morgan Kaufmann, 2011.
- [3] WIRTH, R.; HIPPI, J. CRISP-DM: Towards a Standard Process Model for Data Mining. *PKDD*, 2000.
- [4] WITTEN, I. H. et al. *Data Mining: Practical ML Tools and Techniques*. 4.ed. Morgan Kaufmann, 2016.
- [5] LUNDBERG, S. M.; LEE, S.-I. A Unified Approach to Interpreting Model Predictions. *NeurIPS*, 2017.
- [6] McMAHAN, B. et al. Communication-Efficient Learning of Deep Networks from Decentralized Data. *AISTATS*, 2017.

Material Didático

Módulo 1: Introdução à Mineração de Dados e KDD — definições completas, exercícios práticos, código Python comentado e algoritmos detalhados.