

Mineração de Dados: Conceitos e Aplicações

Módulo 2: Pré-processamento de Dados

Prof. Elton Sarmanho¹
eltonss@ufpa.br

¹Faculdade de Sistemas de Informação - UFPA Campus Cametá

30 de junho de 2026

Roteiro da Aula

Qualidade de Dados

Tipos de Dados

Dados Ausentes

Outliers

Normalização e Escalonamento

Seleção de Atributos

Balanceamento de Classes

PCA

Por que Pré-processar os Dados?

Regra 80-20

80% do tempo de um projeto de ciência de dados é gasto em **pré-processamento**; apenas 20% em modelagem.

Dados do mundo real chegam:

- ▶ Incompletos (valores ausentes)
- ▶ Inconsistentes (duplicatas, erros)
- ▶ Desbalanceados (classes raras)
- ▶ Em escalas diferentes

6 Dimensões de Qualidade de Dados:

Acurácia

Dados refletem a realidade?

Compleitude

Dados necessários presentes?

Consistência

Dados coerentes entre si?

Temporalidade

Dados estão atualizados?

Validade

Dentro dos domínios esperados?

Unicidade

Sem duplicatas indevidas?

Escala	Característica	Exemplos
Nominal	Apenas categorias, sem ordem	Cor dos olhos, Estado civil, Tipo sanguíneo
Ordinal	Categorias com ordem; intervalos desiguais	Satisfação (1–5), Grau de escolaridade
Intervalar	Intervalos iguais; zero arbitrário	Temperatura (°C), Ano calendário
Razão	Intervalos iguais; zero absoluto	Peso (kg), Altura (cm), Renda (R\$)

Estruturados vs. Não Estruturados

Dados tabulares (SQL) vs. texto, imagem, áudio, que requerem extração de features.

Séries Temporais e Espaciais

Sequências ordenadas no tempo ou com componente geográfico, exigindo técnicas especiais.

Mecanismos de Ausência: MCAR, MAR e MNAR

MCAR

Missing Completely At Random

A ausência **não depende** de nenhum dado.

Ex.: Sensor falha aleatoriamente a cada 1000 medições.

Tratamento: Remoção de registros (sem viés), porém perde poder estatístico.

MAR

Missing At Random

Ausência depende de **outras variáveis observadas**.

Ex.: Pessoas com alta renda tendem a não informar renda (dependendo de escolaridade).

Tratamento: Imputação múltipla (MICE).

MNAR


Missing Not At Random

Ausência depende do **próprio valor ausente**.

Ex.: Pacientes com pressão muito alta faltam às consultas.

Tratamento: Modelagem explícita do mecanismo: qualquer imputação simples introduz viés.

Padrões de Ausência: Visualização



Técnicas de Imputação

Técnica	Como funciona	Quando usar	Limitação
Média / Mediana	Substitui pelo valor central da coluna	MCAR, < 5% ausentes	Reduz variância
KNN Imputer	Média ponderada dos k vizinhos mais próximos	Relações locais entre instâncias	Custo $O(n^2)$
MICE	Cada coluna modelada por regressão iterativa	MAR; dados com relações complexas	Custo computacional

Diagnóstico Primeiro!

A escolha da estratégia **deve ser precedida** do diagnóstico do mecanismo. Remover registros com MAR/MNAR introduz viés sistemático.

O que é um Outlier? Critério IQR


Definição

Observação que se desvia significativamente do padrão esperado. Pode ser **erro de medição** ou **evento genuíno** (fraude, evento raro).

Critério de Tukey (IQR):

$$IQR = Q_3 - Q_1$$

Outlier se $x < Q_1 - 1.5 \cdot IQR$
ou $x > Q_3 + 1.5 \cdot IQR$



Métodos de Detecção de Outliers

Métodos Univariados

- ▶ **Z-Score:** $z_i = \frac{x_i - \mu}{\sigma}$
Outlier se $|z_i| > 3$. Sensível a extremos.
- ▶ **IQR (Tukey):**
Robusto; usa quartis. Não assume normalidade.
- ▶ **Z-Score Modificado (MAD):**
Usa mediana, extremamente robusto.

Métodos Multivariados / ML

- ▶ **Isolation Forest:**
Isola anomalias em menos divisões de árvore. Eficiente em alta dimensão.
- ▶ **LOF (Local Outlier Factor):**
Compara densidade local com vizinhos. Detecta outliers locais.
- ▶ **One-Class SVM:**
Aprende fronteira de normalidade. Pontos fora = anomalia.

Como Tratar Outliers?

Estratégia	Descrição	Quando usar	Cuidado
Remoção	Excluir registros com outliers	Erros claros de coleta	Pode perder dados raros legítimos
Winsorização	Substituir pelos limites IQR	Extremos improváveis mas não impossíveis	Distorce distribuição original
Transformação	Log, raiz quadrada, Box-Cox	Distribuição com cauda longa	Dificulta interpretação
Manter	Não tratar	Outliers genuínos (fraude, doença rara)	Treinamento pode ser prejudicado

Métodos de Normalização e Escalonamento

Min-Max Normalization

$$x'_i = \frac{x_i - x_{min}}{x_{max} - x_{min}} \in [0, 1]$$

Mapeia para [0, 1]. Sensível a outliers.

Z-Score Standardization

$$x'_i = \frac{x_i - \mu}{\sigma}$$

Média 0, desvio 1. Mais usado como padrão.

Robust Scaler

$$x'_i = \frac{x_i - Q_2}{IQR}$$

Usa mediana e IQR. Robusto a outliers.

Transformação Logarítmica

$$x'_i = \log(1 + x_i)$$

Reduz assimetria em distribuições com cauda longa. O +1 evita $\log(0)$.


Por que escalonar?

KNN, K-Means, SVM, PCA e redes neurais são **sensíveis a escala**. Árvores de decisão e gradient boosting **não precisam** de escalonamento.

Guia de Escolha do Método de Escalonamento

Método	Use quando	Não use quando
Min-Max	Redes neurais; dados sem outliers; range fixo necessário	Dados com outliers significativos
Z-Score	Regressão linear/logística; SVM; PCA	Distribuições muito assimétricas
Robust	Dados com outliers que devem ser mantidos	Algoritmos que exigem $[0, 1]$
Log	Features com distribuição log-normal; contagens; preços	Dados com zeros: use $\log(1 + x)$

Métodos de Seleção de Atributos



Filtro

Avalia cada feature independentemente. Rápido, mas não considera interações entre features.

Wrapper

Usa um algoritmo para avaliar subconjuntos. Mais preciso, mas computacionalmente caro.

Embutido

Seleção durante o treinamento. LASSO zera coeficientes de features irrelevantes automaticamente.

O Problema do Desbalanceamento de Classes

Exemplo: Detecção de Fraude

Dataset com **0.1% de fraudes**: um modelo que sempre prevê “não é fraude” tem **99.9% de acurácia** mas é completamente inútil!

Métricas corretas para dados desbalanceados:

- ▶ Precision e Recall
- ▶ F1-Score
- ▶ AUC-ROC

SMOTE: Como Funciona

Gera exemplos **sintéticos** da classe minoritária interpolando entre instâncias existentes:

$$x_{new} = x_i + \lambda \cdot (x_{nn} - x_i)$$

onde x_{nn} é um vizinho aleatório e $\lambda \sim \mathcal{U}[0, 1]$.

Não copia instâncias existentes: **cria novas** no espaço de features.

Oversampling vs. Undersampling

Estratégia	Vantagens	Desvantagens	Quando Usar
SMOTE	Aumenta diversidade; não perde dados	Pode gerar regiões irreais	Dataset pequeno a médio
ADASYN	Foca nas regiões difíceis	Amplifica ruído	Fronteira de decisão complexa
Random Under	Simples e rápido	Perde informação da classe majoritária	Dataset grande; custo computacional alto
Tomek Links	Limpa a fronteira de decisão	Efeito modesto isoladamente	Pré-processamento complementar


Redução de Dimensionalidade

- ▶ Outra tarefa comum é a redução de dimensionalidade.
- ▶ O objetivo é mapear os dados de um espaço de alta dimensão $\mathbb{R}^d$ para um espaço de menor dimensão $\mathbb{R}^k$, onde $k < d$.
- ▶ Um método popular é a **Análise de Componentes Principais** (PCA), que busca encontrar as direções de máxima variância nos dados.
- ▶ Matematicamente, o PCA resolve o problema de autovalores:


$$\Sigma v = \lambda v,$$

onde Σ é a matriz de covariância dos dados e v são os autovetores.

Ilustração do PCA




Intuição Geométrica




O PCA rotaciona os eixos para que PC_1 capture a maior variância possível. Cada PC seguinte é ortogonal e captura o restante.

Algoritmo Passo a Passo



A centralização (passo 1) é **obrigatória**: sem ela, o PCA captura médias em vez de variâncias. A normalização também é recomendada quando os atributos têm escalas muito diferentes.

Variância Explicada: Scree Plot



$$\sum PC_1 + PC_2 = 70\%$$

$$\sum PC_1 + PC_2 + PC_3 = 84\% \checkmark$$

Como escolher k ?

Regra prática: selecionar o menor k tal que a **variância acumulada** ≥ 80 –95%. No exemplo acima, $k = 3$ captura 84% da variância total com metade dos atributos originais.

Referências Bibliográficas

-  GARCÍA, S. et al. *Data Preprocessing in Data Mining*. Springer, 2015.
-  CHAWLA, N. V. et al. SMOTE: Synthetic Minority Over-sampling Technique. *JAIR*, v. 16, p. 321–357, 2002.
-  VAN BUUREN, S. *Flexible Imputation of Missing Data*. 2. ed. CRC Press, 2018.
-  LIU, F. T. et al. Isolation Forest. *ICDM*, 2008.
-  TUKEY, J. W. *Exploratory Data Analysis*. Addison-Wesley, 1977.
-  TIBSHIRANI, R. Regression Shrinkage and Selection via the Lasso. *JRSS-B*, v. 58, n. 1, 1996.

Consulte o Material Didático

Módulo 2: Pré-processamento de Dados

Para aprofundamento nos conceitos, exemplos em Python, exercícios resolvidos e referências completas.

 github.com/eltonsarmanho

eltonss@ufpa.br