

Módulo 4

Técnicas de Regressão

em Mineração de Dados

Conteúdo do Módulo:

- | | | | |
|--|-----------------------------------|--|---------------------------|
|  | Regressão Linear e Múltipla |  | Ridge, LASSO e ElasticNet |
|  | Regressão Polinomial e Não-linear |  | Ensembles para Regressão |
|  | Redes Neurais para Regressão |  | Diagnóstico e Validação |

Material didático para uso acadêmico. Baseado em Tibshirani (1996), Friedman (2001), Breiman (2001), Chen & Guestrin (2016) e outros.

Sumário

1	Objetivos de Aprendizagem	2
2	Introdução à Regressão	2
2.1	Definição e Distinção com Classificação	2
2.2	Tipos de Regressão	3
2.3	Aplicações em Mineração de Dados	3
3	Regressão Linear Simples e Múltipla	3
3.1	Regressão Linear Simples	3
3.2	Regressão Linear Múltipla	4
3.3	Métricas de Avaliação de Regressão	5
4	Regularização	5
4.1	Ridge Regression (L2 – Tikhonov)	5
4.2	LASSO – Least Absolute Shrinkage and Selection Operator (Tibshirani, 1996)	6
4.3	ElasticNet (Zou & Hastie, 2005)	6
5	Regressão Polinomial e Não-Linear	7
5.1	Regressão Polinomial	7
5.2	Trade-off Viés-Variância	7
5.3	Support Vector Regression (SVR)	7
6	Métodos de Ensemble para Regressão	8
6.1	Random Forest para Regressão	8
6.2	Gradient Boosting (GBM, XGBoost, LightGBM)	8
6.3	Stacking para Regressão	8
7	Redes Neurais para Regressão	9
8	Diagnóstico de Modelos de Regressão	9
8.1	Análise de Resíduos	9
8.2	Testes Estatísticos de Diagnóstico	10
9	Estado da Arte (2020–2024)	10
10	Exercícios	11
11	Referências	12

1 Objetivos de Aprendizagem

Ao concluir este módulo, o estudante será capaz de:

- ✓ **Distinguir** o problema de regressão do problema de classificação, identificando quando a variável de resposta é contínua e quais técnicas são apropriadas para cada cenário prático.
- ✓ **Derivar** os estimadores de Mínimos Quadrados Ordinários (OLS) para regressão linear simples e múltipla, verificando as hipóteses de Gauss-Markov e diagnosticando violações via análise de resíduos.
- ✓ **Implementar e comparar** métodos de regularização (Ridge, LASSO e ElasticNet), compreendendo o efeito geométrico das restrições L1 e L2 sobre os coeficientes e a propriedade de esparsidade do LASSO.
- ✓ **Aplicar** regressão polinomial e diagnosticar sobreajuste usando o trade-off viés-variância, selecionando o grau ótimo do polinômio por validação cruzada.
- ✓ **Utilizar** métodos ensemble para regressão (Random Forest, Gradient Boosting, XGBoost, LightGBM), ajustando hiperparâmetros e interpretando importância de features com SHAP.
- ✓ **Realizar** diagnóstico completo de modelos de regressão: análise de resíduos, gráficos Q-Q, Cook's Distance, testes de Durbin-Watson, Breusch-Pagan e Shapiro-Wilk.
- ✓ **Calcular e interpretar** métricas de avaliação de regressão (MSE, RMSE, MAE, MAPE, R^2 , R^2 ajustado), distinguindo quando cada métrica é mais informativa.
- ✓ **Construir** intervalos de predição com garantias estatísticas usando Predição Conformal (Conformal Prediction) e regressão quantílica, quantificando incerteza de forma calibrada.

2 Introdução à Regressão

2.1 Definição e Distinção com Classificação

O problema de **regressão** consiste em aprender um mapeamento $f : \mathbb{R}^p \rightarrow \mathbb{R}$ que prevê uma variável de resposta **contínua** $y \in \mathbb{R}$ a partir de um vetor de features $\mathbf{x} \in \mathbb{R}^p$. A diferença fundamental com a classificação é a natureza do espaço de saída:

Aspecto	Classificação	Regressão
Saída	Discreta: $y \in \{c_1, \dots, c_k\}$	Contínua: $y \in \mathbb{R}$
Métrica principal	Acurácia, F1, AUC	RMSE, MAE, R^2
Exemplos	Spam/ham, tumor maligno	Preço de imóvel, temperatura
Perda típica	0-1 loss, cross-entropy	MSE, MAE, Huber

2.2 Tipos de Regressão

- **Regressão Linear Simples:** $\hat{y} = \beta_0 + \beta_1 x$ – relação linear entre uma feature e a resposta
- **Regressão Linear Múltipla:** $\hat{y} = \beta_0 + \sum_{j=1}^p \beta_j x_j = \boldsymbol{\beta}^T \mathbf{x}$ – múltiplas features
- **Regressão Polinomial:** inclui termos $x^2, x^3, \dots$ como features – captura não-linearidade
- **Regressão Regularizada:** Ridge (L2), LASSO (L1), ElasticNet – controle de overfitting
- **Regressão Não-Linear:** SVR, GPR, redes neurais – fronteiras de decisão arbitrariamente complexas

2.3 Aplicações em Mineração de Dados

- 🏠 **Previsão de preços imobiliários:** estimar valor de imóveis a partir de localização, área, quartos, etc.
- 🛒 **Previsão de demanda:** prever volume de vendas para gestão de estoque e logística.
- 📈 **Risco financeiro:** modelar spreads de crédito, volatilidade de ativos, Value at Risk.
- ☁ **Previsão climática:** temperatura, precipitação, nível do mar com modelos de série temporal.
- ❤ **Saúde:** prever dosagem de medicamentos, tempo de internação, progressão de doenças.
- ⚙ **Engenharia:** prever consumo energético, eficiência de motores, fadiga de materiais.
- 🗣 **NLP:** regressão para scoring de qualidade de textos, relevância de documentos.

3 Regressão Linear Simples e Múltipla

3.1 Regressão Linear Simples

O modelo de **Regressão Linear Simples** assume relação linear entre x e y :

$$y_i = \beta_0 + \beta_1 x_i + \varepsilon_i, \quad \varepsilon_i \sim \mathcal{N}(0, \sigma^2)$$

Os estimadores de Mínimos Quadrados Ordinários (OLS) minimizam $\sum_i (y_i - \hat{y}_i)^2$:

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2} = \frac{S_{xy}}{S_{xx}}, \quad \hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$$




Figura 1: Regressão linear simples: linha vermelha é $\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x$. Linhas tracejadas laranja indicam resíduos $\varepsilon_i = y_i - \hat{y}_i$.

3.2 Regressão Linear Múltipla

Com p features, o modelo matricial é:

$$\mathbf{y} = X\boldsymbol{\beta} + \boldsymbol{\varepsilon}, \quad X \in \mathbb{R}^{n \times (p+1)}, \quad \boldsymbol{\beta} \in \mathbb{R}^{p+1}$$

A solução OLS em forma fechada (quando $X^T X$ é invertível):

$$\hat{\boldsymbol{\beta}} = (X^T X)^{-1} X^T \mathbf{y}$$

Hipóteses de Gauss-Markov (para OLS ser BLUE – Best Linear Unbiased Estimator):

1. *Linearidade*: $\mathbb{E}[\mathbf{y}] = X\boldsymbol{\beta}$
2. *Exogeneidade*: $\mathbb{E}[\boldsymbol{\varepsilon} \mid X] = \mathbf{0}$
3. *Homocedasticidade*: $\text{Var}(\varepsilon_i) = \sigma^2$ (constante)
4. *Sem autocorrelação*: $\text{Cov}(\varepsilon_i, \varepsilon_j) = 0$ para $i \neq j$
5. *Sem multicolinearidade perfeita*: $\text{posto}(X) = p + 1$

Multicolinearidade ocorre quando features são altamente correlacionadas, inflando a variância dos estimadores. Diagnóstico via VIF (Variance Inflation Factor):

$$VIF_j = \frac{1}{1 - R_j^2}$$

onde R_j^2 é o coeficiente de determinação da regressão de x_j sobre as demais features. $VIF > 10$ indica multicolinearidade severa.

3.3 Métricas de Avaliação de Regressão

Métrica	Fórmula	Observação
MSE	$\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$	Penaliza outliers quadraticamente
RMSE	$\sqrt{MSE}$	Mesma unidade de y
MAE	$\frac{1}{n} \sum_{i=1}^n y_i - \hat{y}_i $	Robusto a outliers
MAPE	$\frac{100\%}{n} \sum_{i=1}^n \left \frac{y_i - \hat{y}_i}{y_i} \right $	Interpretação percentual; evitar se $y_i \approx 0$
R^2	$1 - \frac{\sum (y_i - \hat{y}_i)^2}{\sum (y_i - \bar{y})^2}$	Fração da variância explicada
R^2 ajustado	$1 - (1 - R^2) \frac{n-1}{n-p-1}$	Penaliza features desnecessárias
Huber Loss	$\frac{1}{n} \sum_i \ell_\delta(y_i - \hat{y}_i)$	Combina MSE e MAE

⚠ Cuidados com R^2

R^2 não é uma métrica de bondade de ajuste absoluta: (1) sempre aumenta com mais features (por isso use R^2 ajustado); (2) pode ser alto mesmo com modelo inadequado (e.g., ajustar polinômio de grau $n - 1$); (3) irrelevante para comparar modelos com variáveis resposta diferentes.

4 Regularização

A regularização adiciona uma penalidade à função de perda para controlar a complexidade do modelo e prevenir overfitting.

4.1 Ridge Regression (L2 – Tikhonov)

O objetivo do Ridge adiciona penalidade L2 aos coeficientes:

$$\hat{\boldsymbol{\beta}}_{Ridge} = \arg \min_{\boldsymbol{\beta}} \{ \|\mathbf{y} - X\boldsymbol{\beta}\|_2^2 + \lambda \|\boldsymbol{\beta}\|_2^2 \}$$

Solução analítica:

$$\hat{\boldsymbol{\beta}}_{Ridge} = (X^T X + \lambda I)^{-1} X^T \mathbf{y}$$

A adição de λI torna a matriz sempre invertível (condicionamento melhorado), mesmo com multicolinearidade. Efeito: todos os coeficientes são reduzidos (*shrinkage*) mas **nenhum é zerado exatamente**. Ridge é análise de componentes principais regularizada.

4.2 LASSO – Least Absolute Shrinkage and Selection Operator (Tibshirani, 1996)

Penalidade L1:

$$\hat{\beta}_{LASSO} = \arg \min_{\beta} \{ \|\mathbf{y} - X\beta\|_2^2 + \lambda \|\beta\|_1 \}$$

Sem solução de forma fechada; resolvido por **descida de coordenadas** (coordinate descent). O operador de limiarização suave (soft-thresholding) para coordenada j :

$$\hat{\beta}_j = S_{\lambda/2} \left(\frac{\langle \mathbf{r}_j, \mathbf{x}_j \rangle}{\|\mathbf{x}_j\|_2^2} \right) = \text{sign}(z) \max(|z| - \lambda', 0)$$

Propriedade fundamental: o LASSO produz **soluções esparsas** – alguns coeficientes são exatamente zero, realizando **seleção automática de features**.

4.3 ElasticNet (Zou & Hastie, 2005)

Combina penalidades L1 e L2:

$$\hat{\beta}_{EN} = \arg \min_{\beta} \{ \|\mathbf{y} - X\beta\|_2^2 + \lambda_1 \|\beta\|_1 + \lambda_2 \|\beta\|_2^2 \}$$

Parâmetro $\alpha = \frac{\lambda_1}{\lambda_1 + \lambda_2}$ controla o balanço: $\alpha = 1$ é LASSO puro; $\alpha = 0$ é Ridge puro. ElasticNet é preferível ao LASSO quando há grupos de features correlacionadas (LASSO seleciona apenas uma aleatoriamente).




Figura 2: Regiões de restrição: L2 (esfera, Ridge) vs. L1 (losango, LASSO). O ótimo toca o losango em um vértice onde $\beta_1 = 0$, produzindo esparsidade.

💡 Caminho de Regularização (Regularization Path)

Para diferentes valores de λ (de 0 a ∞): Ridge encolhe todos os coeficientes continuamente para zero; LASSO os zera sequencialmente, um a um. O “regularization path” do LASSO é linear por partes (algoritmo LARS). Escolha de λ via validação cruzada.

5 Regressão Polinomial e Não-Linear

5.1 Regressão Polinomial

Para capturar relações não-lineares entre x e y , expandimos as features com termos polinomiais:

$$\phi(\mathbf{x}) = [1, x, x^2, \dots, x^d]^T$$

O modelo permanece linear nos parâmetros: $\hat{y} = \beta^T \phi(\mathbf{x})$, resolvido com OLS. Para múltiplas features, incluímos também termos de interação: $x_1 x_2, x_1^2 x_2$, etc.

Risco de sobreajuste com grau alto: polinômio de grau $n - 1$ interpola todos os n pontos com erro zero no treino mas generaliza pessimamente (oscilações de Runge).

5.2 Trade-off Viés-Variância

O erro esperado de generalização pode ser decomposto como:

$$\mathbb{E}[(\hat{f}(\mathbf{x}) - y)^2] = \underbrace{(\mathbb{E}[\hat{f}(\mathbf{x})] - f(\mathbf{x}))^2}_{\text{Viés}^2} + \underbrace{\mathbb{E}[(\hat{f}(\mathbf{x}) - \mathbb{E}[\hat{f}(\mathbf{x})])^2]}_{\text{Variância}} + \underbrace{\sigma^2}_{\text{Ruído}}$$




Figura 3: Trade-off viés-variância: à esquerda, modelos simples têm alto viés (under-fitting); à direita, modelos complexos têm alta variância (overfitting). O ponto ótimo minimiza o erro total.

5.3 Support Vector Regression (SVR)

O SVR usa o ε -tubo: apenas erros maiores que ε são penalizados:

$$\min_{\mathbf{w}, b, \xi} \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_i (\xi_i + \xi_i^*) \quad \text{s.a.} \quad y_i - (\mathbf{w} \cdot \mathbf{x}_i + b) \leq \varepsilon + \xi_i$$

Pode utilizar todos os kernels da SVM (RBF, polinomial), tornando-se um regressor não-linear.

6 Métodos de Ensemble para Regressão

6.1 Random Forest para Regressão

O **Random Forest Regressor** é análogo ao classificador: ensemble de T árvores de regressão (CART), onde cada árvore prediz um valor real e a predição final é a **média** das predições individuais:

$$\hat{y}(\mathbf{x}) = \frac{1}{T} \sum_{t=1}^T h_t(\mathbf{x})$$

Out-of-Bag (OOB) Error: para cada árvore t , os exemplos não amostrados no bootstrap ($\approx 36.8\%$) são usados como conjunto de validação sem custo adicional.

Partial Dependence Plots (PDP): mostram a relação marginal entre uma feature e a predição, integrando sobre as demais features:

$$\hat{f}_S(x_S) = \frac{1}{n} \sum_{i=1}^n \hat{f}(x_S, \mathbf{x}_{i,C})$$

onde S é a feature de interesse e C são as demais features.

6.2 Gradient Boosting (GBM, XGBoost, LightGBM)

O **Gradient Boosting Regressor** ajusta sequencialmente árvores de regressão aos pseudo-resíduos. Para MSE loss, os pseudo-resíduos são simplesmente os resíduos: $r_{im} = y_i - F_{m-1}(\mathbf{x}_i)$.

O modelo acumulado:

$$F_m(\mathbf{x}) = F_{m-1}(\mathbf{x}) + \nu \cdot h_m(\mathbf{x})$$

onde $\nu \in (0, 1]$ é a **taxa de aprendizado** (*shrinkage/learning rate*) – valores menores requerem mais árvores mas generalizam melhor.

i Hiperparâmetros-chave do XGBoost para Regressão

- **n_estimators:** número de árvores (100–2000 com early stopping)
- **learning_rate:** ν (0.01–0.3; menor $\Rightarrow$ mais robusto, mais lento)
- **max_depth:** profundidade das árvores (3–6 para dados tabulares)
- **subsample:** fração de exemplos amostrados por árvore (0.6–1.0)
- **colsample_bytree:** fração de features por árvore (0.6–1.0)
- **reg_alpha** (L1) e **reg_lambda** (L2): regularização nos pesos das folhas

6.3 Stacking para Regressão

No Stacking para regressão, o meta-modelo aprende a combinar as predições dos modelos base:

1. Modelos base: Ridge, Random Forest, XGBoost – cada um gera previsões OOF (out-of-fold)
2. Meta-modelo (frequentemente Ridge linear ou Elastic Net): regride y sobre as previsões dos modelos base
3. O meta-modelo aprende os pesos ótimos de cada modelo base, podendo superar todos individualmente

7 Redes Neurais para Regressão

Uma **Rede Neural Multicamadas (MLP)** para regressão difere do classificador apenas na camada de saída: em vez de softmax, usa um **neurônio linear** com saída escalar $\hat{y} \in \mathbb{R}$.

Função de perda: MSE é o mais comum, mas MAE pode ser usado para robustez. A função de perda Huber combina ambas:

$$\ell_{\delta}(r) = \begin{cases} \frac{1}{2}r^2 & |r| \leq \delta \\ \delta|r| - \frac{1}{2}\delta^2 & |r| > \delta \end{cases}$$

Arquiteturas para regressão complexa:

- **Redes residuais (ResNet-like):** conexões skip para evitar vanishing gradient em regressão profunda
- **Transformers para séries temporais:** Temporal Fusion Transformer (TFT, Lim et al. 2021) para regressão multi-horizonte
- **Graph Neural Networks:** regressão sobre propriedades moleculares, tráfego em redes

8 Diagnóstico de Modelos de Regressão

8.1 Análise de Resíduos

Os resíduos $e_i = y_i - \hat{y}_i$ contêm informação sobre violações das hipóteses do modelo:




Figura 4: Quatro gráficos diagnósticos padrão para modelos de regressão.

8.2 Testes Estatísticos de Diagnóstico

- **Durbin-Watson** ($DW \approx 2$: sem autocorrelação; $DW < 1.5$: autocorrelação positiva): detecta autocorrelação serial nos resíduos.
- **Breusch-Pagan** (H_0 : homocedasticidade): testa se a variância dos resíduos é constante. Rejeitar H_0 indica heterocedasticidade – solução: transformação de y ou erros robustos (White).
- **Shapiro-Wilk** (H_0 : normalidade dos resíduos): fundamental para intervalos de confiança paramétricos. Para amostras grandes ($n > 2000$), use teste de Kolmogorov-Smirnov ou Anderson-Darling.

9 Estado da Arte (2020–2024)

🔧 Neural Networks for Tabular Regression

O debate “DL vs. GBDT” em dados tabulares continua ativo:

- **FT-Transformer** (Gorishniy et al., 2021): tokeniza features numéricas com embedding linear + bias; aplica multi-head self-attention. Supera XGBoost em alguns benchmarks com features de alta dimensão.
- **TabNet** (Arik & Pfister, 2021): atenção em K etapas sequenciais selecionando features relevantes em cada passo; interpretabilidade por design.
- **NODE** (Popov et al., 2020): Neural Oblivious Decision Ensembles – diferenciáveis, combinam gradiente de GBDTs com backpropagation.
- **Conclusão**: para regressão em dados tabulares com $n < 100k$ exemplos e features heterogêneas, XGBoost/LightGBM tipicamente superam DL. DL vantagem em features de alta dimensão (embeddings) e grandes volumes.

🔧 Gaussian Process Regression e Métodos Bayesianos

- **GPR (Rasmussen & Williams, 2006)**: modela a distribuição a posteriori sobre funções: $f \sim \mathcal{GP}(\mu(\mathbf{x}), k(\mathbf{x}, \mathbf{x}'))$. Fornece incerteza calibrada, mas escala $O(n^3)$ – inviável para $n > 10^4$.
- **Sparse GPs e GPflux**: inducing points para aproximação $O(nm^2)$ com $m \ll n$ pontos de indução.
- **Bayesian Optimization**: usa GPR como surrogate model para otimização de funções custosas (e.g., tuning de hiperparâmetros, experimentos químicos). Libraries: BoTorch, Optuna, Scikit-Optimize.
- **BART (Bayesian Additive Regression Trees)**: ensemble Bayesiano de árvores de regressão com priors sobre profundidade e estrutura.

 Predição Conformal e Quantificação de Incerteza

- **Conformal Prediction (Vovk et al., 2005):** produz intervalos de predição com garantias marginais de cobertura $1 - \alpha$ sem hipóteses paramétricas. Funciona como wrapper sobre qualquer modelo: $\hat{C}(x) = [\hat{q}_{\alpha/2}(x), \hat{q}_{1-\alpha/2}(x)]$.
- **CQR – Conformalized Quantile Regression** (Romano et al., 2019): combina regressão quantílica (e.g., LightGBM com `objective='quantile'`) com calibração conformal para intervalos adaptativos (mais estreitos onde o modelo é confiante).
- **MAPIE** (scikit-learn compatible): biblioteca Python para conformal prediction em regressão e classificação com diferentes estratégias (Split CP, Cross-conformal, Jackknife+).
- Aplicação prática: intervalos de confiança para previsão de vendas, limites de risco em finanças.

10 Exercícios

- E1. (OLS por Cálculo)** Dado o dataset: $\{(1, 2.5), (2, 4.1), (3, 5.8), (4, 7.2), (5, 9.0)\}$, calcule manualmente $\hat{\beta}_0$ e $\hat{\beta}_1$ pelo método OLS, o coeficiente R^2 , e o RMSE. Interprete cada resultado.
- E2. (Caminho de Regularização)** No dataset Boston Housing (ou California Housing), trace o regularization path do LASSO: plote os coeficientes em função de $\log(\lambda)$ para $\lambda \in [10^{-4}, 10^2]$. Identifique: qual feature é zerada primeiro? Qual persiste até λ mais alto? Interprete em termos da importância de cada feature.
- E3. (Sobreajuste Polinomial)** Gere 20 pontos de $y = \sin(2\pi x) + \varepsilon$ com $\varepsilon \sim \mathcal{N}(0, 0.2)$ e $x \sim U[0, 1]$. Ajuste polinômios de grau $d \in \{1, 3, 5, 9, 15\}$. Para cada grau, calcule o erro de treino e de teste (200 novos pontos). Plote as curvas ajustadas e o gráfico bias-variância. Qual grau minimiza o erro de teste?
- E4. (RMSE vs. MAE)** Cite dois cenários reais onde MAE é preferível ao RMSE e dois onde RMSE é preferível. Implemente ambas as métricas e compare os modelos Ridge e LASSO no dataset California Housing sob ambas as métricas. Os rankings dos modelos diferem?
- E5. (Análise de Resíduos)** Treine um modelo de Regressão Linear Múltipla no dataset Ames Housing. Gere os quatro gráficos diagnósticos (Resíduos vs. Ajustados, Q-Q, Scale-Location, Cook's Distance). Aplique os testes de Durbin-Watson e Breusch-Pagan. Se houver heterocedasticidade, aplique a transformação $\log(y)$ e reavalie.
- E6. (XGBoost para Regressão)** Usando o dataset de energia de edifícios (Energy Efficiency UCI), tuning o XGBRegressor com Optuna (50 trials). Reporte: melhores hiperparâmetros, RMSE no teste, curva de early stopping. Compare com Ridge e Random Forest.

- E7. (Predição com Intervalo)** No dataset California Housing, use LightGBM com `objective='quantile'` para prever os percentis 5, 50 e 95 do preço. Calcule a cobertura empírica (proporção de valores reais dentro do intervalo predito). Use MAPIE para calibrar o intervalo com cobertura garantida de 90%.

11 Referências

Referências

- [1] Tibshirani, R. (1996). Regression shrinkage and selection via the LASSO. *Journal of the Royal Statistical Society Series B*, 58(1), 267–288.
- [2] Zou, H., & Hastie, T. (2005). Regularization and variable selection via the Elastic Net. *Journal of the Royal Statistical Society Series B*, 67(2), 301–320.
- [3] Breiman, L. (2001). Random forests. *Machine Learning*, 45(1), 5–32.
- [4] Chen, T., & Guestrin, C. (2016). XGBoost: A scalable tree boosting system. In *Proceedings of KDD 2016*, 785–794.
- [5] Ke, G., Meng, Q., Finley, T., Wang, T., Chen, W., Ma, W., ... & Liu, T.-Y. (2017). LightGBM: A highly efficient gradient boosting decision tree. In *NeurIPS 2017*.
- [6] Friedman, J. H. (2001). Greedy function approximation: A gradient boosting machine. *Annals of Statistics*, 29(5), 1189–1232.
- [7] Gelman, A., & Hill, J. (2007). *Data Analysis Using Regression and Multilevel/Hierarchical Models*. Cambridge University Press.
- [8] Romano, Y., Patterson, E., & Candès, E. (2019). Conformalized quantile regression. In *NeurIPS 2019*.
- [9] Rasmussen, C. E., & Williams, C. K. I. (2006). *Gaussian Processes for Machine Learning*. MIT Press, Cambridge.
- [10] James, G., Witten, D., Hastie, T., & Tibshirani, R. (2021). *An Introduction to Statistical Learning with Applications in R* (2nd ed.). Springer.
- [11] Gorishniy, Y., Rubachev, I., Khrulkov, V., & Babenko, A. (2021). Revisiting deep learning models for tabular data. In *NeurIPS 2021*.
- [12] Vovk, V., Gammerman, A., & Shafer, G. (2005). *Algorithmic Learning in a Random World*. Springer.