

Mineração de Dados: Conceitos e Aplicações

Módulo 4: Técnicas de Regressão

Prof. Elton Sarmanho¹
eltonss@ufpa.br

¹Faculdade de Sistemas de Informação - UFPA Campus Cametá

26 de junho de 2026

Roteiro da Aula

O Problema de Regressão

Regressão Linear

Regularização

Trade-off Viés-Variância

Regressão Polinomial

Métodos Ensemble para Regressão

Diagnóstico de Modelos

Classificação vs. Regressão

Aspecto	Classificação	Regressão
Saída	Discreta	Contínua
Exemplo	Spam/Ham	Preço
Métrica	Acurácia, F1	RMSE, R^2
Perda	Cross-entropy	MSE, MAE

Exemplos Práticos

- ▶ **Preço de imóvel** — área, localização
- ▶ **Temperatura** — dados climáticos
- ▶ **Demanda** — estoque e logística
- ▶ **Risco financeiro** — spreads, VaR
- ▶ **Dosagem médica** — peso, idade

A saída é **contínua**: $y \in \mathbb{R}$, não uma classe discreta.

Tipos de Regressão

Modelos Lineares

- ▶ **Linear Simples** — $\hat{y} = \beta_0 + \beta_1 x$
- ▶ **Múltipla** — $\hat{y} = \beta^T \mathbf{x}$
- ▶ **Polinomial** — inclui $x^2, x^3, \dots$

Regularizada

- ▶ **Ridge** — penalidade L2
- ▶ **LASSO** — penalidade L1 (esparsidade)
- ▶ **ElasticNet** — L1 + L2

Não-Linear / Ensemble

- ▶ **SVR** — kernel trick
- ▶ **Random Forest** — média de árvores
- ▶ **XGBoost / LightGBM** — boosting
- ▶ **Redes Neurais** — MLP com saída linear

Consulte o Material Didático

Módulo 4 — Seções 1 e 2

Regressão Linear Simples

Objetivo: encontrar a reta que melhor ajusta os dados.

$$\hat{y} = \beta_0 + \beta_1 x$$

Estimadores OLS (Mínimos Quadrados):


$$\hat{\beta}_1 = \frac{S_{xy}}{S_{xx}}, \quad \hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$$

Minimiza $\sum_i (y_i - \hat{y}_i)^2$

Resíduos

$\varepsilon_i = y_i - \hat{y}_i$ (linhas laranjas)

Regressão Linear Simples com Resíduos



Métricas de Avaliação

Métrica	Fórmula	Quando usar
MSE	$\frac{1}{n} \sum (y_i - \hat{y}_i)^2$	Penaliza outliers; otimização
RMSE	$\sqrt{MSE}$	Mesma unidade de y
MAE	$\frac{1}{n} \sum y_i - \hat{y}_i $	Robusto a outliers
R²	$1 - \frac{\sum (y_i - \hat{y}_i)^2}{\sum (y_i - \bar{y})^2}$	Proporção da variância explicada
R² Ajust.	$1 - (1 - R^2) \frac{n-1}{n-p-1}$	Penaliza features desnecessárias

Atenção ao R²

Sempre cresce com mais features! Use R² ajustado para comparar modelos com

Dica Prática

MAE é preferível quando há outliers. RMSE é preferível quando erros grandes são muito

Por que Regularizar?

O Problema: Overfitting

- ▶ Modelo complexo memoriza os dados de treino
- ▶ Erro baixo no treino, alto no teste
- ▶ Coeficientes muito grandes — instáveis

Solução: Penalidade

Adicionar um termo à função de perda que **penaliza coeficientes grandes**:

$$\text{Perda} + \lambda \cdot \text{Penalidade}(\beta)$$

Benefícios

- ▶ Generalização melhor
- ▶ Reduz variância
- ▶ LASSO: seleção de features
- ▶ Ridge: lida com multicolinearidade

λ — hiperparâmetro

$\lambda \uparrow$ mais regularização

$\lambda = 0$ — sem penalidade (OLS)

Escolher via validação cruzada

Ridge vs. LASSO

Ridge (L2)


$$\|y - X\beta\|^2 + \lambda\|\beta\|_2^2$$

Efeito: encolhe todos os coeficientes, mas **nenhum é zero exatamente**


LASSO (L1)

$$\|y - X\beta\|^2 + \lambda\|\beta\|_1$$

Efeito: produz **soluções esparsas**
— alguns coeficientes = 0 (seleção de features)



Ridge (L2)
 $\|\beta\|_2 \leq t$



LASSO (L1)
 $\|\beta\|_1 \leq t$

O ótimo do LASSO toca o losango num **vértice** onde $\beta_1 = 0$, gerando esparsidade.

ElasticNet e Quando Usar Cada Método

ElasticNet = Ridge + LASSO

$$\hat{\beta}_{EN} = \arg \min_{\beta} \{ \|\mathbf{y} - X\beta\|^2 + \lambda_1 \|\beta\|_1 + \lambda_2 \|\beta\|_2^2 \}$$

Método	Use quando...	Vantagem
Ridge	Muitas features correlacionadas	Coeficientes estáveis
LASSO	Quer seleção automática de features	Modelo esparso / interpretável
ElasticNet	Grupos de features correlacionadas	Combina estabilidade + esparsidade

Trade-off Viés-Variância


Decomposição do erro:

$$\text{Erro} = \text{Viés}^2 + \text{Variância} + \sigma^2$$

- ▶ **Underfitting:** modelo simples, alto viés, baixa variância
- ▶ **Overfitting:** modelo complexo, baixo viés, alta variância
- ▶ **Ótimo:** ponto que minimiza o erro total

Implicação

Regularização aumenta o viés mas



Regressão Polinomial

Ideia

Adicionar $x^2, x^3, \dots$ como novas features:

$$\phi(\mathbf{x}) = [1, x, x^2, \dots, x^d]^T$$

O modelo é **linear nos parâmetros**, resolvido por OLS.

Grau d — como escolher?

- ▶ Grau baixo: underfitting (alto viés)
- ▶ Grau alto: overfitting (alta variância)
- ▶ **Solução:** validação cruzada

Risco com Grau Alto

Polinômio de grau $n - 1$ interpola **todos** os pontos do treino com erro zero — mas generaliza pessimamente!

Oscilações de Runge: o polinômio oscila violentamente entre os pontos de treino.

Alternativa

Usar regularização Ridge/LASSO junto com termos polinomiais — controla as oscilações.

Random Forest Regressor

Como funciona

- ▶ Treina T árvores de regressão (CART) com bootstrap
- ▶ Cada árvore usa subconjunto aleatório de features
- ▶ Predição final: **média** das árvores

$$\hat{y}(\mathbf{x}) = \frac{1}{T} \sum_{t=1}^T h_t(\mathbf{x})$$

OOB Error

≈ 36,8% dos exemplos não são sorteados em

Vantagens

- ▶ Robusto a outliers
- ▶ Pouco ajuste de hiperparâmetros
- ▶ Importância de features nativa
- ▶ Paralelo por natureza

Consulte o Colab

Módulo 4 — Notebook com implementação, importância de features e comparação de métricas.

XGBoost / LightGBM para Regressão

Ideia do Boosting

Constrói árvores **sequencialmente**:
cada nova árvore aprende com os erros
(resíduos) da anterior.

$$F_m(\mathbf{x}) = F_{m-1}(\mathbf{x}) + \nu \cdot h_m(\mathbf{x})$$

ν = taxa de aprendizado (shrinkage)

Vantagem prática





Em dados tabulares com $n < 100k$,
XGBoost/LightGBM tipicamente
superam redes neurais.

Hiperparâmetro	Efeito
<code>n_estimators</code>	Nº de árvores (+ early stop)
<code>learning_rate</code>	ν : menor $\Rightarrow$ mais robusto
<code>max_depth</code>	Profundidade (3–6 ideal)
<code>subsample</code>	Fração de exemplos/árvore
<code>colsample_bytree</code>	Fração de features/árvore
<code>reg_alpha</code> (L1)	Regularização nos pesos
<code>reg_lambda</code> (L2)	Regularização nos pesos

Colab — Módulo 4

Tuning com Optuna: XGBRegressor e
LGBMRegressor com early stopping.

Gráficos Diagnósticos



O que Procurar em Cada Gráfico

Resíduos vs. Ajustados

- ▶ ✓ Pontos dispersos aleatoriamente
- ▶ ✗ Padrão em funil $\Rightarrow$ heterocedasticidade
- ▶ ✗ Padrão curvo $\Rightarrow$ não-linearidade não capturada

Q-Q Plot

- ▶ ✓ Pontos sobre a reta $\Rightarrow$ normalidade
- ▶ ✗ Desvios nas caudas $\Rightarrow$ assimetria / caudas pesadas

Scale-Location

- ▶ ✓ Linha horizontal $\Rightarrow$ variância constante
- ▶ ✗ Linha crescente $\Rightarrow$ heterocedasticidade
- ▶ Solução: transformar y (ex.: $\log y$)

Distância de Cook

- ▶ ✓ Todos abaixo do limiar
- ▶ ✗ Pontos acima $\Rightarrow$ influentes (investigar)
- ▶ Limiar usual: $4/n$

Referências Bibliográficas

-  Tibshirani, R. (1996). Regression shrinkage and selection via the LASSO. *JRSS-B*, 58(1), 267–288.
-  Breiman, L. (2001). Random forests. *Machine Learning*, 45(1), 5–32.
-  Chen, T.; Guestrin, C. (2016). XGBoost: A scalable tree boosting system. *KDD 2016*.
-  Friedman, J. H. (2001). Greedy function approximation: A gradient boosting machine. *Annals of Statistics*, 29(5).
-  James, G. et al. (2021). *An Introduction to Statistical Learning* (2nd ed.). Springer.

Consulte o Material Didático

Módulo 4: Técnicas de Regressão

Conteúdo Complementar

Notebook Google Colab com exemplos práticos de
Regressão Linear, Ridge, LASSO, ElasticNet,
Random Forest, XGBoost e Diagnóstico de Modelos

 github.com/eltonsarmanho