

Mineração de Dados: Conceitos e Aplicações

Módulo 4: Técnicas de Regressão

Prof. Elton Sarmanho¹
eltonss@ufpa.br

¹Faculdade de Sistemas de Informação - UFPA Campus Cametá

29 de junho de 2026

Roteiro da Aula

Fundamentos de Regressão

Tipos de Modelos de Regressão

Métricas de Avaliação

Suposições da Regressão Linear

Regressão

Definição

Modelo estatístico para prever uma variável contínua y a partir de uma ou mais variáveis de entrada X .

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \cdots + \beta_n x_n + \varepsilon$$




Figura: Exemplo de regressão linear.

Regressão vs. Classificação

Característica	Regressão	Classificação
Saída	Contínua ($\mathbb{R}$)	Discreta (rótulos)
Exemplo	Preço de imóveis	Diagnóstico médico (doente/saudável)
Métricas	MSE, R^2	Acurácia, F1-Score


Variáveis Independentes vs. Dependentes

Formulação Matemática

$$\mathbf{y} = \mathbf{X}\beta + \epsilon$$

Onde:

- ▶ $\mathbf{X} \in \mathbb{R}^{n \times p}$: Matriz de features
- ▶ $\beta \in \mathbb{R}^p$: Vetor de coeficientes
- ▶ $\epsilon \in \mathbb{R}^n$: Erro aleatório



Regressão Linear Simples


Definição

Modela a relação linear entre uma variável independente x e uma variável dependente y :

$$y = \beta_0 + \beta_1 x + \varepsilon$$

Onde:

- ▶ β_0 : Intercepto (valor de y quando $x = 0$).
- ▶ β_1 : Coeficiente angular (inclinação da reta).
- ▶ ε : Erro aleatório.



Regressão Linear Múltipla

Definição

Estende a regressão linear para múltiplas variáveis independentes:


$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \cdots + \beta_n x_n + \varepsilon$$

Em forma matricial:

$$\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}$$

Onde:

- ▶ $\mathbf{X}$: Matriz de features ($n \times p$).
- ▶ $\boldsymbol{\beta}$: Vetor de coeficientes ($p \times 1$).




Regressão Polinomial

Definição

Modela relações não lineares usando polinômios:

$$y = \beta_0 + \beta_1 x + \beta_2 x^2 + \cdots + \beta_n x^n + \varepsilon$$

Exemplo: $y = \beta_0 + \beta_1 x + \beta_2 x^2$.



Regressão Regularizada

Objetivo

Penalizar coeficientes grandes para evitar overfitting:

- ▶ Ridge (L2):

$$\text{Minimizar } \|\mathbf{y} - \mathbf{X}\boldsymbol{\beta}\|^2 + \lambda\|\boldsymbol{\beta}\|^2$$

- ▶ Lasso (L1):

$$\text{Minimizar } \|\mathbf{y} - \mathbf{X}\boldsymbol{\beta}\|^2 + \lambda\|\boldsymbol{\beta}\|_1$$

- ▶ Elastic Net:

$$\text{Minimizar } \|\mathbf{y} - \mathbf{X}\boldsymbol{\beta}\|^2 + \lambda_1\|\boldsymbol{\beta}\|_1 + \lambda_2\|\boldsymbol{\beta}\|^2$$

Regressão Logística (Contexto de Regressão)


Definição

Usada para problemas de classificação binária, mas fundamentada em regressão:

$$P(y = 1|\mathbf{x}) = \frac{1}{1 + e^{-(\beta_0 + \beta_1 x_1 + \dots + \beta_n x_n)}}$$

Onde:

- ▶ $P(y = 1|\mathbf{x})$: Probabilidade de $y = 1$.
- ▶ Função logística: $\sigma(z) = \frac{1}{1+e^{-z}}$.




Erro Quadrático Médio (MSE)

Definição: O Erro Quadrático Médio é uma métrica que mede a média dos erros ao quadrado entre os valores reais (y_i) e os valores preditos ($\hat{y}_i$):

$$\text{MSE} = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2 \quad (1)$$

Interpretação: Quanto menor o MSE, melhor a performance do modelo.

Visualização:



Raiz do Erro Quadrático Médio (RMSE)

Definição: A Raiz do Erro Quadrático Médio é simplesmente a raiz quadrada do MSE:

$$\text{RMSE} = \sqrt{\text{MSE}} = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2} \quad (2)$$

Interpretação: É uma métrica na mesma unidade dos dados originais, tornando sua interpretação mais intuitiva.

Erro Absoluto Médio (MAE)

Definição: O Erro Absoluto Médio mede a média das diferenças absolutas entre os valores reais e preditos:

$$\text{MAE} = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i| \quad (3)$$

Interpretação: Valores menores indicam que o modelo está mais próximo dos valores reais em média.

Coeficiente de Determinação (R^2) e R^2 Ajustado

Coeficiente de Determinação (R^2):

- ▶ Mede a proporção da variância explicada pelo modelo.
- ▶ Fórmula:

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2} \quad (4)$$

- ▶ Intervalo: $0 \leq R^2 \leq 1$ (quanto mais próximo de 1, melhor).

R^2 Ajustado:

- ▶ Penaliza a adição de variáveis irrelevantes ao modelo.
- ▶ Fórmula:

$$R^2_{\text{ajustado}} = 1 - (1 - R^2) \frac{n - 1}{n - p - 1} \quad (5)$$

- ▶ Onde p é o número de variáveis explicativas.

Linearidade


Definição: A relação entre a variável dependente (y) e a variável independente (X) deve ser linear.

Representação Matemática:

$$y = \beta_0 + \beta_1 X + \epsilon \quad (6)$$

Onde:

- ▶ β_0 é o intercepto;
- ▶ β_1 é o coeficiente angular;
- ▶ ϵ representa o termo de erro.




Independência dos Resíduos

Definição: Os resíduos (ϵ_i) não devem estar correlacionados entre si.

Teste Comum: Teste de Durbin-Watson

$$DW = \frac{\sum_{i=2}^n (\epsilon_i - \epsilon_{i-1})^2}{\sum_{i=1}^n \epsilon_i^2} \quad (7)$$


Valores próximos de 2 indicam independência.



Visualização: Pontos aleatórios indicam independência

Homocedasticidade


Definição: A variância dos resíduos deve ser constante para todos os valores de X .



Visualização:

Homocedasticidade

Interpretacao: A ausência de padrões nos resíduos (em torno do eixo x) indica que o modelo atende à suposição de homocedasticidade.



Visualização:


Normalidade dos Resíduos

Definição: Os resíduos devem seguir uma distribuição aproximadamente normal.

Teste Comum: Teste de Shapiro-Wilk

Visualização:

Frequência



Ausência de Multicolinearidade

Definição: As variáveis independentes não devem ser altamente correlacionadas entre si.

Teste Comum: Fator de Inflacionamento da Variância (VIF)

$$\text{VIF}_j = \frac{1}{1 - R_j^2} \quad (8)$$

Onde R_j^2 é o coeficiente de determinação da regressão da variável j contra as demais.

Interpretação: $\text{VIF} > 10$ indica alta multicolinearidade.

Referências Bibliográficas

-  Tibshirani, R. (1996). Regression shrinkage and selection via the LASSO. *JRSS-B*, 58(1), 267–288.
-  Breiman, L. (2001). Random forests. *Machine Learning*, 45(1), 5–32.
-  Chen, T.; Guestrin, C. (2016). XGBoost: A scalable tree boosting system. *KDD 2016*.
-  Friedman, J. H. (2001). Greedy function approximation: A gradient boosting machine. *Annals of Statistics*, 29(5).
-  James, G. et al. (2021). *An Introduction to Statistical Learning* (2nd ed.). Springer.

Consulte o Material Didático

Módulo 4: Técnicas de Regressão

Conteúdo Complementar

Notebook Google Colab com exemplos práticos de Regressão Linear, Ridge, LASSO, ElasticNet, Random Forest, XGBoost e Diagnóstico de Modelos

 github.com/eltonsarmanho