

Mineração de Dados: Conceitos e Aplicações

Módulo 6: Métodos Estatísticos e Clustering

Prof. Elton Sarmanho¹
eltonss@ufpa.br

¹Faculdade de Sistemas de Informação - UFPA Campus Cametá

28 de junho de 2026

Roteiro da Aula

Fundamentos Estatísticos

- Testes de Hipótese

- Correlação e Dependência

Agrupamento (Clustering)

- Conceitos Gerais

- K-Means

- Clustering Hierárquico

- DBSCAN e HDBSCAN

- Modelos de Mistura Gaussiana (GMM)

- Avaliação de Agrupamentos

Regras de Associação

- Conceitos Fundamentais

- Apriori e FP-Growth

Deteccção de Anomalias

- Tipos e Métodos

Estado da Arte (2020–2024)


O que é um Teste de Hipótese?

Definição

Procedimento para **decidir**, com base em evidências amostrais, se uma afirmação sobre uma população deve ser aceita ou rejeitada.

Componentes Essenciais

- ▶ H_0 (**hipótese nula**): posição padrão a testar
ex. "RF e SVM têm mesma acurácia"
- ▶ H_1 (**alternativa**): o que queremos provar
- ▶ **Nível de significância** α : geralmente 0,05
- ▶ **p-valor**: rejeita H_0 se $p < \alpha$



Tipos de Erro e Poder do Teste

Tipos de Erro

	H_0 verdadeira	H_0 falsa
Não rejeitar	✓ Correto	Erro Tipo II (β)
Rejeitar	Erro Tipo I (α)	✓ Poder ($1 - \beta$)

Atenção

Reduzir α aumenta β . Há um **trade-off** entre os dois tipos de erro. O poder do teste aumenta com maior n (mais dados).

Testes Relevantes em Mineração de Dados

- ▶ **Teste t pareado:** compara 2 classificadores nos mesmos folds
- ▶ **ANOVA:** compara 3 ou mais classificadores simultaneamente
- ▶ **Wilcoxon Signed-Rank:** alternativa não-paramétrica ao teste t
- ▶ **McNemar:** compara classificadores pelas matrizes de confusão

➔ Consulte o Material Didático Módulo 6 para exemplos detalhados

Teste t Pareado: Comparando Dois Algoritmos

Fórmula

$$t = \frac{\bar{d}}{s_d / \sqrt{n}}, \quad \bar{d} = \frac{1}{n} \sum_{i=1}^n (a_i - b_i)$$

Exemplo: RF vs SVM (10 folds)

$\bar{d} = 2,40\%$, $s_d = 0,91$, $n = 10$

$$t = \frac{2,40}{0,91 / \sqrt{10}} \approx 8,33$$

$t_{\text{crítico}}(gl = 9, \alpha = 0,05) = 1,833$

Como $8,33 \gg 1,833$: **rejeitamos** H_0

RF é estatisticamente superior ao SVM ($p < 0,001$)

Quando usar

- ▶ Dois algoritmos avaliados nos *mesmos* folds (amostras pareadas)
- ▶ Diferenças aproximadamente normais
- ▶ Para $n < 30$ verificar normalidade das diferenças

Significância $\neq$ Relevância Prática

$p < 0,05$ indica que a diferença provavelmente não é aleatória, mas $\Delta = 2,4\%$ pode ou não ser relevante dependendo do custo do erro na aplicação.

➔ Exemplo completo: Material Didático e Colab Módulo 6

ANOVA: Comparando Três ou Mais Algoritmos

Objetivo

Comparar **simultaneamente** $k \geq 3$ algoritmos.

H_0 : todas as médias são iguais.

H_1 : pelo menos uma difere.

Exemplo: KNN vs DT vs NaiveBayes

	KNN	DT	NB
Média	83%	79,8%	75%

$$F = MS_{\text{entre}} / MS_{\text{dentro}} = 81,05 / 2,40 \approx 33,77$$

$$F_{\text{crit}}(2, 12) = 3,89: \text{rejeita } H_0 \text{ (} p < 0,001 \text{)}$$

Pós-ANOVA

ANOVA diz que *alguma* diferença existe, mas não *qual par* difere. Use:

- ▶ **Tukey HSD** ou **Bonferroni** para comparações de pares
- ▶ **Friedman + Nemenyi** para abordagem não-paramétrica em k algoritmos

Wilcoxon Signed-Rank

Alternativa ao teste t quando:

- ▶ $n < 30$ sem garantia de normalidade
- ▶ Presença de **outliers** nos dados
- ▶ Dados **ordinais** (scores de ranking)

Ranqueia $|d_i|$ e testa se a mediana das diferenças é 

Correlação de Pearson


Definição

$$r = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum (x_i - \bar{x})^2 \cdot \sum (y_i - \bar{y})^2}} \in [-1, 1]$$

Escala de Interpretação

$ r $	Interpretação
0,90–1,00	Muito forte
0,70–0,89	Forte
0,50–0,69	Moderada
0,30–0,49	Fraca
< 0,30	Desprezível

Horas de Estudo vs Nota ($r = 0,88$)



Correlação $\neq$ Causalidade. Pearson mede apenas relação **linear**. Para relações não lineares, use Spearman ou Informação Mútua.

Spearman, Kendall e Informação Mútua

Correlação de Spearman (ρ)

Aplica Pearson sobre os **postos** (*ranks*) dos dados.

- ▶ Detecta relações **monotônicas** (não só lineares)
- ▶ Robusta a outliers
- ▶ Indicada para dados ordinais ou com distribuição assimétrica

Tau de Kendall (τ)

Baseado em pares **concordantes/discordantes**.

- ▶ Mais robusto que Spearman para amostras pequenas
- ▶ Interpretação probabilística direta

Informação Mútua $I(X; Y)$

$$I(X; Y) = \sum_{x,y} p(x, y) \log \frac{p(x, y)}{p(x) p(y)}$$

- ▶ Mede dependência **geral** (não apenas linear)
- ▶ $I(X; Y) = 0$ somente se X e Y são independentes
- ▶ Amplamente usado em **seleção de features** (MRMR)
- ▶ Captura relações complexas que Pearson ignora

➔ Consulte Material Didático para exemplo prático com cálculo de Pearson


O que é Clustering?

Definição

Tarefa de **aprendizado não-supervisionado** que organiza exemplos similares em grupos (clusters) sem o uso de rótulos pré-definidos.

Aplicações

- ▶ ➔ **Segmentação de clientes:** grupos de comportamento de compra
- ▶ ➔ **Deteção de anomalias:** pontos sem cluster são outliers
- ▶ ➔ **Compressão de imagens:** quantização de cores com K-Means
- ▶ ➔ **Bioinformática:** agrupamento de genes por expressão
- ▶ ➔ **Modelagem de tópicos:** agrupamento de documentos



Avalie resultados com métricas e visualização (PCA, t-SNE, UMAP).

K-Means: Conceito e Objetivo

Objetivo: Minimizar Inércia

$$J = \sum_{k=1}^K \sum_{\mathbf{x}_i \in C_k} \|\mathbf{x}_i - \boldsymbol{\mu}_k\|^2$$


onde $\boldsymbol{\mu}_k$ é o centróide do cluster k .

Resumo do Algoritmo (Lloyd, 1982)


1. Inicializar K centróides (aleatório ou K-Means++)
2. **Atribuição:** cada ponto vai ao centróide mais próximo
3. **Atualização:** mover centróide para a média do cluster
4. Repetir 2–3 até convergência

Propriedades

- ▶ **Complexidade:** $O(n \cdot K \cdot d \cdot i)$, onde d é a dimensão e i o número de iterações
 - ▶ **Convergência:** garantida (mas pode ser ótimo local)
 - ▶ **Limitações:** assume clusters **esféricos e de tamanho similar**; sensível a outliers e inicialização
 - ▶ **Distância:** euclidiana por padrão
- ➔ Consulte Material Didático e Colab para implementação em Python

$$\mu_1 = \frac{1}{5}(14, 17) = (2,8, 3,4)$$


K-Means: Visualização das Etapas



Cada iteração atualiza centróides até que os clusters se estabilizem.

→ Ver algoritmo completo no Material Didático Módulo 6.

Escolha de K: Método do Cotovelo

Ideia


Plota a **inércia** (WCSS) para $K = 1, 2, \dots$. O ponto onde a redução desacelera, formando um “cotovelo”, indica o K ótimo.

$$WCSS(K) = \sum_{k=1}^K \sum_{\mathbf{x}_i \in C_k} \|\mathbf{x}_i - \boldsymbol{\mu}_k\|^2$$

Limitação

O cotovelo pode ser ambíguo em dados sobrepostos. Combine sempre com a **Análise de Silhouette**.

Método do Cotovelo



De $K = 2$ para $K = 3$: queda de —60% na inércia. De $K = 3$ em diante: ganho marginal pequeno.

Escolha de K: Análise de Silhouette

Coeficiente de Silhouette

Para cada ponto x_i no cluster C_k :


$a(i)$ = distância média intra-cluster

$b(i)$ = distância média ao vizinho mais próximo

$$s(i) = \frac{b(i) - a(i)}{\max\{a(i), b(i)\}} \in [-1, 1]$$

Interpretação

- ▶ $s \approx +1$: ponto bem dentro do cluster
- ▶ $s \approx 0$: ponto na fronteira
- ▶ $s \approx -1$: ponto no cluster errado
- ▶ $\bar{s} > 0,5$: clustering de qualidade



Use **Elbow** e **Silhouette** juntos para maior confiabilidade na escolha de K .

Variantes do K-Means

K-Means++

Inicialização inteligente: cada centróide é escolhido com probabilidade proporcional à distância ao centróide mais próximo já escolhido.

- ▶ Evita inicializações ruins
- ▶ Garante aproximação $O(\log K)$ do ótimo
- ▶ **Padrão** no scikit-learn

K-Medoids (PAM)

Usa exemplos reais como centróides (medóides).

- ▶ Mais robusto a outliers que K-Means
- ▶ Interpretável: centróide é um ponto real
- ▶ Mais custoso computacionalmente

Mini-Batch K-Means

Atualiza centróides com mini-lotes aleatórios a cada iteração.

- ▶ Escala para datasets de **milhões** de exemplos
- ▶ Resultado ligeiramente pior que K-Means padrão
- ▶ Ideal para dados em stream

Quando K-Means falha

Clusters não esféricos, de tamanhos muito diferentes, ou com muitos outliers. Nesses casos, prefira DBSCAN, GMM ou Spectral Clustering.

Clustering Hierárquico

Conceito


Cria uma **hierarquia** de agrupamentos em um **dendrograma**, sem necessitar especificar K antecipadamente.

Abordagens

- ▶ **Agglomerativo (bottom-up)**: começa com N clusters e mescla os dois mais próximos iterativamente
- ▶ **Divisivo (top-down)**: começa com um cluster e divide recursivamente

Crítérios de Ligação

- ▶ **Single**: distância mínima, sensível a outliers
- ▶ **Complete**: distância máxima, clusters compactos
- ▶ **Average (UPGMA)**: equilíbrio entre os dois
- ▶ **Ward**: minimiza variação intra-cluster (mais



DBSCAN: Clustering Baseado em Densidade

Conceito


Encontra clusters de **forma arbitrária** e detecta **ruído/outliers** automaticamente. Parâmetros: ϵ (raio) e MinPts (vizinhos mínimos).

Tipos de Pontos

- ▶ **Núcleo:** $\geq$ MinPts vizinhos em raio ϵ
- ▶ **Fronteira:** dentro do raio de um núcleo, mas não é núcleo
- ▶ **Ruído:** não é núcleo nem fronteira

Vantagem sobre K-Means

Não precisa especificar K . Detecta clusters de qualquer forma geométrica e identifica outliers automaticamente.



Clusters: azul e laranja — ruído: vermelho

Estimar ϵ pelo gráfico da k -NN distance (joelho da curva).

HDBSCAN: Extensão Hierárquica do DBSCAN

Limitação do DBSCAN

DBSCAN usa um único ε global. Se os clusters têm **densidades diferentes**, um único limiar não funciona bem.


HDBSCAN (McInnes et al., 2017)

Varia o limiar de densidade automaticamente ao longo de uma hierarquia. Extrai os clusters mais **persistentes**.

- ▶ Apenas `min_cluster_size` é crítico
- ▶ Detecta clusters com densidades variáveis
- ▶ Retorna **probabilidade** de pertencimento
- ▶ Padrão no scikit-learn ≥ 1.3

Pipeline UMAP + HDBSCAN

Abordagem moderna para dados de alta dimensão:



→ Muito eficaz para NLP (embeddings), genômica (scRNA-seq) e BERTopic

Modelos de Mistura Gaussiana (GMM)

Modelo

Os dados são gerados por uma **mistura** de K Gaussianas:

$$p(\mathbf{x}) = \sum_{k=1}^K \pi_k \mathcal{N}(\mathbf{x} \mid \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)$$

π_k : peso da componente k ($\sum_k \pi_k = 1$)

Treinamento: Algoritmo EM

1. **E-step:** calcular responsabilidades r_{ik} (probabilidade de $\mathbf{x}_i$ pertencer ao cluster k)
2. **M-step:** atualizar π_k , $\boldsymbol{\mu}_k$ e $\boldsymbol{\Sigma}_k$
3. Repetir até convergência da log-verossimilhança

GMM vs K-Means

Aspecto	K-Means	GMM
Atribuição	Dura	Suave
Forma cluster	Esférica	Elipsoidal
Pertencimento	0/1	Probabilidade
Seleção de K	Elbow/Sil	BIC/AIC
Parâmetros	Poucos	Mais

Seleção de K no GMM

Minimize o **BIC** (Bayesian Information Criterion):

$$\text{BIC} = -2 \log \hat{L} + p \log N$$

Avaliação de Agrupamentos

Métricas Internas (sem rótulos)

- ▶ **Silhouette Score** $\bar{s}$: coesão interna vs separação externa. $\bar{s} \in [-1, 1]$, maximize.
- ▶ **Davies-Bouldin (DB)**:
$$DB = \frac{1}{K} \sum_k \max_{k' \neq k} \frac{s_k + s_{k'}}{\|c_k - c_{k'}\|}$$

Minimize. Penaliza clusters compactos mas muito próximos.
- ▶ **Calinski-Harabasz**: razão dispersão inter/intra-cluster. Maximize.

Métricas Externas (com rótulos verdadeiros)

- ▶ **ARI (Adjusted Rand Index)**: $\in [-1, 1]$; 1 = perfeito; 0 = aleatório. Ajustado para chance.
- ▶ **NMI (Normalized Mutual Information)**:
$$NMI(U, V) = \frac{2 \cdot I(U; V)}{H(U) + H(V)} \in [0, 1]$$
- ▶ **V-Measure**: média harmônica de *homogeneidade* e *completude*.

Boas Práticas

Nunca use apenas uma métrica. Combine métricas **internas** + **externas** (quando disponíveis) + visualização (PCA, t-SNE, UMAP).

Regras de Associação: Conceitos

O Problema

Dado um banco de transações, encontrar regras do tipo $A \Rightarrow B$ com alta frequência e confiabilidade.

Exemplo: $\{\text{leite}\} \Rightarrow \{\text{pão}\}$

Medidas de Interesse

$$\text{sup}(A \Rightarrow B) = \frac{|\{T: A \cup B \subseteq T\}|}{|\mathcal{T}|}$$

$$\text{conf}(A \Rightarrow B) = \frac{\text{sup}(A \cup B)}{\text{sup}(A)}$$

$$\text{lift}(A \Rightarrow B) = \frac{\text{conf}(A \Rightarrow B)}{\text{sup}(B)}$$

Interpretação do Lift

- ▶ **lift** > 1: correlação positiva; a regra é mais frequente que o esperado por acaso
- ▶ **lift** = 1: A e B independentes
- ▶ **lift** < 1: correlação negativa (anti-regra)

Exemplo: Cesta de Mercado

5 transações. Para $\{\text{leite}\} \Rightarrow \{\text{pão}\}$:

$$\text{sup} = 3/5 = 0,60$$

$$\text{conf} = 0,60/0,80 = 0,75$$

$$\text{lift} = 0,75/0,60 = 1,25$$

✓ Correlação positiva: comprar leite favorece comprar pão.

Algoritmo Apriori

Princípio Anti-Monótono

Se um itemset é **infrequente**, todos os seus superconjuntos também são. Isso permite **podar** o espaço de busca.

Etapas

1. Gerar itemsets frequentes de tamanho 1 (L_1)
2. Gerar candidatos de tamanho $k + 1$ a partir de L_k
3. Varrer transações e contar suporte
4. Filtrar candidatos com suporte $\geq$ minsup
5. Repetir até $L_k = \emptyset$
6. Gerar regras com confiança $\geq$ minconf

Limitações do Apriori


- ▶ Múltiplas varridas na base de dados ($O(|\mathcal{I}|)$ varridas)
- ▶ Grande número de candidatos em datasets densos
- ▶ Ineficiente para bases muito grandes

FP-Growth (Han et al., 2000)

- ▶ Apenas **2 varridas** na base de dados
- ▶ Constrói uma **FP-Tree** (árvore compacta) que compartilha prefixos
- ▶ Sem geração explícita de candidatos
- ▶ Muito mais eficiente que Apriori em datasets grandes

➔ Implemente Apriori e FP-Growth no Colab do Módulo 6

- ▶ **Ponto:** instância individual muito diferente das demais
Ex.: transação de R\$50.000 numa conta comum
- ▶ **Contextual:** instância anômala apenas em contexto específico
Ex.: 35°C em dezembro no RS
- ▶ **Coletiva:** subconjunto de instâncias anômalo em conjunto; individualmente parecem normais
Ex.: padrão de compras incomum ao longo da semana



Métodos de Detecção de Anomalias

Métodos Estatísticos

- ▶ **Z-score:** anomalia se $|z| > 3$. Assume distribuição Gaussiana.
- ▶ **Boxplot:** outlier se $> Q_3 + 1,5 \cdot \text{IQR}$ ou $< Q_1 - 1,5 \cdot \text{IQR}$
- ▶ **Grubbs Test:** teste formal para outlier único em amostra normal

LOF (Breunig et al., 2000)

Compara a **densidade local** de um ponto com a de seus vizinhos. $\text{LOF}(p) \gg 1$ indica anomalia.

- ▶ Detecta outliers locais (não depende de distribuição global)
- ▶ Sensível ao parâmetro k (número de vizinhos)

Isolation Forest (Liu et al., 2008)

Constrói árvores de isolamento aleatórias. Anomalias são isoladas em **caminhos mais curtos**.

$$s(x, n) = 2^{-E[h(x)]/c(n)}$$

- ▶ Eficiente em alta dimensão
- ▶ Não assume forma da distribuição
- ▶ Eficaz para anomalias de ponto

Autoencoder

Treina para reconstruir dados normais. **Alto erro de reconstrução** $\|x - \hat{x}\|^2$ indica anomalia.

→ Consulte Colab para comparação prática de métodos

Estado da Arte: Deep Clustering

DEC (Xie et al., 2016)

Deep Embedded Clustering: autoencoder treinado conjuntamente com objetivo de clustering. Aprende representações otimizadas para agrupamento.

SCAN (Van Gansbeke et al., 2020)

Self-supervised clustering: usa similaridade de vizinhos para treinar sem rótulos. Estado da arte em clustering de imagens.

DINO (Caron et al., 2021)

Vision Transformer (ViT) auto-supervisionado revela estrutura de clustering sem fine-tuning. Propriedade emergente dos Transformers.

Detecção de Outliers Moderna

- ▶ **PyOD** (Zhao et al., 2019): 40+ algoritmos unificados em API sklearn-compatível
- ▶ **COPOD** (Li et al., 2020): baseado em cópulas, sem hiperparâmetros, muito eficiente
- ▶ **ECOD** (Li et al., 2022): baseado em distribuição empírica cumulativa, interpretável
- ▶ **Anomalia em grafos:** GraphSAGE + Isolation Forest para fraudes em redes sociais

➔ Material Didático e Colab trazem experimentos com BERTopic e PyOD

Pipeline Moderno: BERTopic e UMAP+HDBSCAN


BERTopic (Grootendorst, 2022)

Modelagem de tópicos combinando:

1. **BERT embeddings:** representação semântica dos textos
2. **UMAP:** redução de dimensionalidade
3. **HDBSCAN:** agrupamento dos embeddings
4. **TF-IDF por cluster:** extração de palavras-chave representativas

Supera LDA em qualidade de tópicos.

Pipeline UMAP + HDBSCAN tornou-se padrão para NLP, genômica single-cell (scRNA-seq) e análise de



Referências Bibliográficas

-  MacQueen, J. *Some methods for classification and analysis of multivariate observations*. BSMSP, 1967.
-  Arthur, D.; Vassilvitskii, S. *k-means++: The advantages of careful seeding*. SODA, 2007.
-  Ester, M. et al. *A density-based algorithm for discovering clusters in large spatial databases with noise*. KDD, 1996.
-  McInnes, L. et al. *hdbscan: Hierarchical density based clustering*. JOSS, 2017.
-  Han, J.; Pei, J.; Yin, Y. *Mining frequent patterns without candidate generation*. ACM SIGMOD, 2000.
-  Liu, F. T. et al. *Isolation Forest*. ICDM, 2008.
-  Bergstra, J.; Bengio, Y. *Random Search for Hyper-Parameter Optimization*. JMLR, 2012.
-  **Material Didático Módulo 6** e Notebook Colab disponíveis no repositório da disciplina.