

# Mineração de Dados: Conceitos e Aplicações

## Módulo 6: Métodos Estatísticos e Clustering

Prof. Elton Sarmanho<sup>1</sup>  
eltonss@ufpa.br

<sup>1</sup>Faculdade de Sistemas de Informação - UFPA Campus Cametá

29 de junho de 2026

## Roteiro da Aula

- Fundamentos Estatísticos

  - Testes de Hipótese

  - Correlação e Dependência

- Agrupamento (Clustering)

  - Conceitos Gerais

  - K-Means

  - Clustering Hierárquico

  - DBSCAN e HDBSCAN

  - Modelos de Mistura Gaussiana (GMM)

  - Avaliação de Agrupamentos

## Roteiro da Aula

- Regras de Associação

  - Conceitos Fundamentais

  - Apriori e FP-Growth

- Detecção de Anomalias

  - Tipos e Métodos

- Estado da Arte (2020–2024)


# O que é um Teste de Hipótese?

## Definição

Procedimento para **decidir**, com base em evidências amostrais, se uma afirmação sobre uma população deve ser aceita ou rejeitada.

## Componentes Essenciais

- ▶  $H_0$  (**hipótese nula**): posição padrão  
ex. “RF e SVM têm mesma acurácia”
- ▶  $H_1$  (**alternativa**): o que queremos provar
- ▶ **Nível de significância  $\alpha$** : geralmente 0.05
  - ▶ Probabilidade de rejeitar  $H_0$  quando  $H_0$  é verdadeira (Erro Tipo I)
- ▶ **p-valor**: rejeita  $H_0$  se  $p < \alpha$ 
  - ▶ Probabilidade de observar os dados assumindo  $H_0$  verdadeira




# O que é um Teste de Hipótese?

## Definição

Procedimento para **decidir**, com base em evidências amostrais, se uma afirmação sobre uma população deve ser aceita ou rejeitada.

## Componentes Essenciais

- ▶  $H_0$  (**hipótese nula**): posição padrão  
ex. “RF e SVM têm mesma acurácia”
- ▶  $H_1$  (**alternativa**): o que queremos provar
- ▶ **Nível de significância**  $\alpha$ : geralmente 0.05
  - ▶ Probabilidade de rejeitar  $H_0$  quando  $H_0$  é verdadeira (Erro Tipo I)
- ▶ **p-valor**: rejeita  $H_0$  se  $p < \alpha$ 
  - ▶ Probabilidade de observar os dados assumindo  $H_0$  verdadeira




# O que é um Teste de Hipótese?

## Definição

Procedimento para **decidir**, com base em evidências amostrais, se uma afirmação sobre uma população deve ser aceita ou rejeitada.

## Componentes Essenciais

- ▶  $H_0$  (**hipótese nula**): posição padrão  
ex. “RF e SVM têm mesma acurácia”
- ▶  $H_1$  (**alternativa**): o que queremos provar
- ▶ **Nível de significância**  $\alpha$ : geralmente 0.05
  - ▶ Probabilidade de rejeitar  $H_0$  quando  $H_0$  é verdadeira (Erro Tipo I)
- ▶ **p-valor**: rejeita  $H_0$  se  $p < \alpha$ 
  - ▶ Probabilidade de observar os dados assumindo  $H_0$  verdadeira



# Tipos de Erro e Poder do Teste

## Tabela de Decisão

|              | $H_0$ verdadeira         | $H_0$ falsa              |
|--------------|--------------------------|--------------------------|
| Não rejeitar | ✓ Correto                | Erro Tipo II ( $\beta$ ) |
| Rejeitar     | Erro Tipo I ( $\alpha$ ) | ✓ Poder ( $1 - \beta$ )  |

## Erros

- ▶ Erro Tipo I ( $\alpha$ ): rejeitar  $H_0$  quando  $H_0$  é verdadeira
- ▶ Erro Tipo II ( $\beta$ ): não rejeitar  $H_0$  quando  $H_0$  é falsa
- ▶ Poder do teste ( $1 - \beta$ ): probabilidade de rejeitar  $H_0$  quando  $H_0$  é falsa

## Tipos de Erro e Poder do Teste

### Tabela de Decisão

|              | $H_0$ verdadeira         | $H_0$ falsa              |
|--------------|--------------------------|--------------------------|
| Não rejeitar | ✓ Correto                | Erro Tipo II ( $\beta$ ) |
| Rejeitar     | Erro Tipo I ( $\alpha$ ) | ✓ Poder ( $1 - \beta$ )  |

### Erros

- ▶ **Erro Tipo I ( $\alpha$ ):** rejeitar  $H_0$  quando  $H_0$  é verdadeira
- ▶ **Erro Tipo II ( $\beta$ ):** não rejeitar  $H_0$  quando  $H_0$  é falsa
- ▶ **Poder do teste ( $1 - \beta$ ):** probabilidade de rejeitar  $H_0$  quando  $H_0$  é falsa

## Tipos de Erro e Poder do Teste

### Testes Relevantes em Mineração de Dados

- ▶ **Teste  $t$  pareado:** compara 2 classificadores nos mesmos folds
- ▶ **ANOVA:** compara 3 ou mais classificadores simultaneamente
- ▶ **Wilcoxon Signed-Rank:** alternativa não-paramétrica ao teste  $t$
- ▶ **McNemar:** compara classificadores pelas matrizes de confusão

## Teste $t$ Pareado: Fórmula e Quando Usar

### Fórmula

$$t = \frac{\bar{d}}{s_d/\sqrt{n}}, \quad \bar{d} = \frac{1}{n} \sum_{i=1}^n (a_i - b_i)$$

$\bar{d}$ : média das diferenças por fold;  $s_d$ : desvio padrão.

### Quando Usar

- ▶ Dois algoritmos nos *mesmos* folds (amostras pareadas)
- ▶ Diferenças aproximadamente normais
- ▶ Para  $n < 30$ , verificar normalidade das diferenças

### Passos

1. Formular  $H_0$ ,  $H_1$  e escolher  $\alpha$
2. Calcular  $d_i = a_i - b_i$  para cada fold
3. Calcular  $\bar{d}$ ,  $s_d$  e a estatística  $t$
4. Comparar com  $t_{\text{crítico}}(gl = n - 1, \alpha)$

## Teste $t$ Pareado: Fórmula e Quando Usar

### Fórmula

$$t = \frac{\bar{d}}{s_d/\sqrt{n}}, \quad \bar{d} = \frac{1}{n} \sum_{i=1}^n (a_i - b_i)$$

$\bar{d}$ : média das diferenças por fold;  $s_d$ : desvio padrão.

### Quando Usar

- ▶ Dois algoritmos nos *mesmos* folds (amostras pareadas)
- ▶ Diferenças aproximadamente normais
- ▶ Para  $n < 30$ , verificar normalidade das diferenças

### Passos

1. Formular  $H_0$ ,  $H_1$  e escolher  $\alpha$
2. Calcular  $d_i = a_i - b_i$  para cada fold
3. Calcular  $\bar{d}$ ,  $s_d$  e a estatística  $t$
4. Comparar com  $t_{\text{crítico}}(gl = n - 1, \alpha)$

## Teste $t$ Pareado: Fórmula e Quando Usar

### Fórmula

$$t = \frac{\bar{d}}{s_d / \sqrt{n}}, \quad \bar{d} = \frac{1}{n} \sum_{i=1}^n (a_i - b_i)$$

$\bar{d}$ : média das diferenças por fold;  $s_d$ : desvio padrão.

### Quando Usar

- ▶ Dois algoritmos nos *mesmos* folds (amostras pareadas)
- ▶ Diferenças aproximadamente normais
- ▶ Para  $n < 30$ , verificar normalidade das diferenças

### Passos

1. Formular  $H_0$ ,  $H_1$  e escolher  $\alpha$
2. Calcular  $d_i = a_i - b_i$  para cada fold
3. Calcular  $\bar{d}$ ,  $s_d$  e a estatística  $t$
4. Comparar com  $t_{\text{crítico}}(gl = n - 1, \alpha)$

## O que determina o tipo de teste?

### A Hipótese Alternativa ( $H_1$ )

A escolha é definida **antes** da coleta de dados, baseada na pergunta de pesquisa:

- ▶ **Teste Bilateral (Two-tailed):** Quando queremos detectar qualquer diferença, sem direção preferencial.
  - ▶  $H_1 : \mu \neq \mu_0$
- ▶ **Teste Unilateral (One-tailed):** Quando a teoria indica que o efeito só pode (ou só interessa) ocorrer em um sentido.
  - ▶  $H_1 : \mu > \mu_0$  (Direita) ou  $H_1 : \mu < \mu_0$  (Esquerda)

## Diferenças: Bilateral vs. Unilateral

| Característica        | Bilateral                        | Unilateral                     |
|-----------------------|----------------------------------|--------------------------------|
| Direção               | Indiferente ( $\neq$ )           | Específica ( $>$ ou $<$ )      |
| Distribuição $\alpha$ | Dividido ( $\alpha/2$ cada lado) | Total em uma cauda             |
| Rigor                 | Mais conservador                 | Menos conservador              |
| Poder                 | Menor poder estatístico          | Maior poder (na direção certa) |

### Importante

No teste bilateral, o valor crítico de  $t$  ou  $z$  é sempre **maior**, pois a área de rejeição é empurrada para os extremos.

## Exemplo 1 — RF vs SVM: Dados e Hipóteses

### Cenário

**Random Forest** vs **SVM** em detecção de spam — 10 folds de validação cruzada.

| Fold | RF (%) | SVM (%) |
|------|--------|---------|
| 1    | 92.1   | 89.3    |
| 2    | 88.7   | 86.0    |
| 3    | 91.4   | 90.1    |
| 4    | 93.0   | 88.5    |
| 5    | 89.5   | 87.9    |
| 6    | 94.2   | 91.6    |
| 7    | 90.3   | 89.0    |
| 8    | 88.0   | 85.5    |
| 9    | 92.8   | 90.4    |
| 10   | 91.0   | 88.7    |

### Hipóteses (unilateral)

- ▶  $H_0: \mu_{RF} = \mu_{SVM}$
- ▶  $H_1: \mu_{RF} > \mu_{SVM}$  (RF é melhor)
- ▶  $\alpha = 0.05$

### Teste Escolhido

Mesmos folds  $\Rightarrow$  **Teste  $t$  pareado** (amostras dependentes).

## Exemplo 1 — RF vs SVM: Dados e Hipóteses

### Cenário

**Random Forest** vs **SVM** em detecção de spam — 10 folds de validação cruzada.

| Fold | RF (%) | SVM (%) |
|------|--------|---------|
| 1    | 92.1   | 89.3    |
| 2    | 88.7   | 86.0    |
| 3    | 91.4   | 90.1    |
| 4    | 93.0   | 88.5    |
| 5    | 89.5   | 87.9    |
| 6    | 94.2   | 91.6    |
| 7    | 90.3   | 89.0    |
| 8    | 88.0   | 85.5    |
| 9    | 92.8   | 90.4    |
| 10   | 91.0   | 88.7    |

### Hipóteses (unilateral)

- ▶  $H_0: \mu_{RF} = \mu_{SVM}$
- ▶  $H_1: \mu_{RF} > \mu_{SVM}$  (RF é melhor)
- ▶  $\alpha = 0.05$

### Teste Escolhido

Mesmos folds  $\Rightarrow$  **Teste  $t$  pareado** (amostras dependentes).

## Exemplo 1 — RF vs SVM: Dados e Hipóteses

### Cenário

**Random Forest** vs **SVM** em detecção de spam — 10 folds de validação cruzada.

| Fold | RF (%) | SVM (%) |
|------|--------|---------|
| 1    | 92.1   | 89.3    |
| 2    | 88.7   | 86.0    |
| 3    | 91.4   | 90.1    |
| 4    | 93.0   | 88.5    |
| 5    | 89.5   | 87.9    |
| 6    | 94.2   | 91.6    |
| 7    | 90.3   | 89.0    |
| 8    | 88.0   | 85.5    |
| 9    | 92.8   | 90.4    |
| 10   | 91.0   | 88.7    |

### Hipóteses (unilateral)

- ▶  $H_0: \mu_{RF} = \mu_{SVM}$
- ▶  $H_1: \mu_{RF} > \mu_{SVM}$  (RF é melhor)
- ▶  $\alpha = 0.05$

### Teste Escolhido

Mesmos folds  $\Rightarrow$  **Teste  $t$  pareado** (amostras dependentes).

## Exemplo 1 — RF vs SVM: Dados e Hipóteses

### Cenário

**Random Forest** vs **SVM** em detecção de spam — 10 folds de validação cruzada.

| Fold | RF (%) | SVM (%) |
|------|--------|---------|
| 1    | 92.1   | 89.3    |
| 2    | 88.7   | 86.0    |
| 3    | 91.4   | 90.1    |
| 4    | 93.0   | 88.5    |
| 5    | 89.5   | 87.9    |
| 6    | 94.2   | 91.6    |
| 7    | 90.3   | 89.0    |
| 8    | 88.0   | 85.5    |
| 9    | 92.8   | 90.4    |
| 10   | 91.0   | 88.7    |

### Hipóteses (unilateral)

- ▶  $H_0: \mu_{RF} = \mu_{SVM}$
- ▶  $H_1: \mu_{RF} > \mu_{SVM}$  (RF é melhor)
- ▶  $\alpha = 0.05$

### Teste Escolhido

Mesmos folds  $\Rightarrow$  **Teste  $t$  pareado** (amostras dependentes).

Exemplo 1 - RF vs SVM: Cálculo de  $t$ 

| Fold                | RF   | SVM  | $d_i = \text{RF} - \text{SVM}$ |
|---------------------|------|------|--------------------------------|
| 1                   | 92.1 | 89.3 | +2.8                           |
| 2                   | 88.7 | 86.0 | +2.7                           |
| 3                   | 91.4 | 90.1 | +1.3                           |
| 4                   | 93.0 | 88.5 | +4.5                           |
| 5                   | 89.5 | 87.9 | +1.6                           |
| 6                   | 94.2 | 91.6 | +2.6                           |
| 7                   | 90.3 | 89.0 | +1.3                           |
| 8                   | 88.0 | 85.5 | +2.5                           |
| 9                   | 92.8 | 90.4 | +2.4                           |
| 10                  | 91.0 | 88.7 | +2.3                           |
| Média $\bar{d}$     |      |      | 2.40                           |
| Desvio padrão $s_d$ |      |      | 0.91                           |

$$t = \frac{\bar{d}}{s_d/\sqrt{n}} = \frac{2.40}{0.91/\sqrt{10}} = \frac{2.40}{0.288} \approx 8.33$$

## Decisão

$t_{\text{crítico}}(gl = 9, \alpha = 0.05) = 1.833$ . Como  $8.33 \gg 1.833$  e  $p < 0.001$  (computado)  $\rightarrow$  rejeitamos  $H_0$  ( $p < \alpha$ ).  
RF é estatisticamente superior ao SVM.  $\Delta = 2.4\%$ , logo avalie relevância prática no domínio.

Exemplo 1 - RF vs SVM: Cálculo de  $t$ 

| Fold                | RF   | SVM  | $d_i = \text{RF} - \text{SVM}$ |
|---------------------|------|------|--------------------------------|
| 1                   | 92.1 | 89.3 | +2.8                           |
| 2                   | 88.7 | 86.0 | +2.7                           |
| 3                   | 91.4 | 90.1 | +1.3                           |
| 4                   | 93.0 | 88.5 | +4.5                           |
| 5                   | 89.5 | 87.9 | +1.6                           |
| 6                   | 94.2 | 91.6 | +2.6                           |
| 7                   | 90.3 | 89.0 | +1.3                           |
| 8                   | 88.0 | 85.5 | +2.5                           |
| 9                   | 92.8 | 90.4 | +2.4                           |
| 10                  | 91.0 | 88.7 | +2.3                           |
| Média $\bar{d}$     |      |      | 2.40                           |
| Desvio padrão $s_d$ |      |      | 0.91                           |

$$t = \frac{\bar{d}}{s_d/\sqrt{n}} = \frac{2.40}{0.91/\sqrt{10}} = \frac{2.40}{0.288} \approx 8.33$$

## Decisão

$t_{\text{crítico}}(gl = 9, \alpha = 0.05) = 1.833$ . Como  $8.33 \gg 1.833$  e  $p < 0.001$  (computado)  $\rightarrow$  rejeitamos  $H_0$  ( $p < \alpha$ ).  
 RF é estatisticamente superior ao SVM.  $\Delta = 2.4\%$ , logo avalie relevância prática no domínio.

Exemplo 1 - RF vs SVM: Cálculo de  $t$ 

| Fold                | RF   | SVM  | $d_i = \text{RF} - \text{SVM}$ |
|---------------------|------|------|--------------------------------|
| 1                   | 92.1 | 89.3 | +2.8                           |
| 2                   | 88.7 | 86.0 | +2.7                           |
| 3                   | 91.4 | 90.1 | +1.3                           |
| 4                   | 93.0 | 88.5 | +4.5                           |
| 5                   | 89.5 | 87.9 | +1.6                           |
| 6                   | 94.2 | 91.6 | +2.6                           |
| 7                   | 90.3 | 89.0 | +1.3                           |
| 8                   | 88.0 | 85.5 | +2.5                           |
| 9                   | 92.8 | 90.4 | +2.4                           |
| 10                  | 91.0 | 88.7 | +2.3                           |
| Média $\bar{d}$     |      |      | 2.40                           |
| Desvio padrão $s_d$ |      |      | 0.91                           |

$$t = \frac{\bar{d}}{s_d/\sqrt{n}} = \frac{2.40}{0.91/\sqrt{10}} = \frac{2.40}{0.288} \approx 8.33$$

## Decisão

$t_{\text{crítico}}(gl = 9, \alpha = 0.05) = 1.833$ . Como  $8.33 \gg 1.833$  e  $p < 0.001$  (*computado*)  $\rightarrow$  **rejeitamos  $H_0$**  ( $p < \alpha$ ).  
RF é estatisticamente superior ao SVM.  $\Delta = 2.4\%$ , logo avalie relevância prática no domínio.

Exemplo 2 — MLP vs Reg. Log.: Baixo Poder com  $n = 5$ 

## Cenário

MLP vs Regressão Logística, 5 folds, diagnóstico médico.

 $H_0 : \mu_d = 0$  vs  $H_1 : \mu_d \neq 0$  (bilateral,  $\alpha = 0.05$ )

| Fold      | MLP  | Reg. Log. | $d_i$ |
|-----------|------|-----------|-------|
| 1         | 85.0 | 80.0      | +5.0  |
| 2         | 90.0 | 85.0      | +5.0  |
| 3         | 78.0 | 80.0      | -2.0  |
| 4         | 92.0 | 87.0      | +5.0  |
| 5         | 88.0 | 85.0      | +3.0  |
| $\bar{d}$ |      |           | 3.20  |
| $s_d$     |      |           | 2.77  |

$$t = \frac{3.20}{2.77/\sqrt{5}} \approx 2.58$$

## Resultado

 $t_{\text{crit}}(gl = 4, \alpha = 0.025) = 2.776$ .2.58 < 2.776: **não rejeitamos**  $H_0$  ( $p \approx 0.06$ ).

## Lição: Poder do Teste

Com apenas  $n = 5$  folds, o teste tem **poder reduzido**. O resultado é *borderline*, repetir com 10+ folds pode revelar diferença significativa.

Exemplo 2 — MLP vs Reg. Log.: Baixo Poder com  $n = 5$ 

## Cenário

MLP vs Regressão Logística, 5 folds, diagnóstico médico.

 $H_0 : \mu_d = 0$  vs  $H_1 : \mu_d \neq 0$  (bilateral,  $\alpha = 0.05$ )

| Fold      | MLP  | Reg. Log. | $d_i$ |
|-----------|------|-----------|-------|
| 1         | 85.0 | 80.0      | +5.0  |
| 2         | 90.0 | 85.0      | +5.0  |
| 3         | 78.0 | 80.0      | -2.0  |
| 4         | 92.0 | 87.0      | +5.0  |
| 5         | 88.0 | 85.0      | +3.0  |
| $\bar{d}$ |      |           | 3.20  |
| $s_d$     |      |           | 2.77  |

$$t = \frac{3.20}{2.77/\sqrt{5}} \approx 2.58$$

## Resultado

 $t_{\text{crit}}(gl = 4, \alpha = 0.025) = 2.776$ .2.58 < 2.776: não rejeitamos  $H_0$  ( $p \approx 0.06$ ).

## Lição: Poder do Teste

Com apenas  $n = 5$  folds, o teste tem **poder reduzido**. O resultado é *borderline*, repetir com 10+ folds pode revelar diferença significativa.

Exemplo 2 — MLP vs Reg. Log.: Baixo Poder com  $n = 5$ 

## Cenário

MLP vs Regressão Logística, 5 folds, diagnóstico médico.

 $H_0 : \mu_d = 0$  vs  $H_1 : \mu_d \neq 0$  (bilateral,  $\alpha = 0.05$ )

$$t = \frac{3.20}{2.77/\sqrt{5}} \approx 2.58$$

| Fold      | MLP  | Reg. Log. | $d_i$ |
|-----------|------|-----------|-------|
| 1         | 85.0 | 80.0      | +5.0  |
| 2         | 90.0 | 85.0      | +5.0  |
| 3         | 78.0 | 80.0      | -2.0  |
| 4         | 92.0 | 87.0      | +5.0  |
| 5         | 88.0 | 85.0      | +3.0  |
| $\bar{d}$ |      |           | 3.20  |
| $s_d$     |      |           | 2.77  |

## Resultado

 $t_{\text{crit}}(gl = 4, \alpha = 0.025) = 2.776$ .2.58 < 2.776: não rejeitamos  $H_0$  ( $p \approx 0.06$ ).

## Lição: Poder do Teste

Com apenas  $n = 5$  folds, o teste tem **poder reduzido**. O resultado é *borderline*, repetir com 10+ folds pode revelar diferença significativa.

Exemplo 2 — MLP vs Reg. Log.: Baixo Poder com  $n = 5$ 

## Cenário

MLP vs Regressão Logística, 5 folds, diagnóstico médico.

 $H_0 : \mu_d = 0$  vs  $H_1 : \mu_d \neq 0$  (bilateral,  $\alpha = 0.05$ )

$$t = \frac{3.20}{2.77/\sqrt{5}} \approx 2.58$$

| Fold      | MLP  | Reg. Log. | $d_i$ |
|-----------|------|-----------|-------|
| 1         | 85.0 | 80.0      | +5.0  |
| 2         | 90.0 | 85.0      | +5.0  |
| 3         | 78.0 | 80.0      | -2.0  |
| 4         | 92.0 | 87.0      | +5.0  |
| 5         | 88.0 | 85.0      | +3.0  |
| $\bar{d}$ |      |           | 3.20  |
| $s_d$     |      |           | 2.77  |

## Resultado

 $t_{\text{crit}}(gl = 4, \alpha = 0.025) = 2.776$ .2.58 < 2.776: **não rejeitamos**  $H_0$  ( $p \approx 0.06$ ).

## Lição: Poder do Teste

Com apenas  $n = 5$  folds, o teste tem **poder reduzido**. O resultado é *borderline*, repetir com 10+ folds pode revelar diferença significativa.

Exemplo 2 — MLP vs Reg. Log.: Baixo Poder com  $n = 5$ 

## Cenário

MLP vs Regressão Logística, 5 folds, diagnóstico médico.

 $H_0 : \mu_d = 0$  vs  $H_1 : \mu_d \neq 0$  (bilateral,  $\alpha = 0.05$ )

| Fold      | MLP  | Reg. Log. | $d_i$ |
|-----------|------|-----------|-------|
| 1         | 85.0 | 80.0      | +5.0  |
| 2         | 90.0 | 85.0      | +5.0  |
| 3         | 78.0 | 80.0      | -2.0  |
| 4         | 92.0 | 87.0      | +5.0  |
| 5         | 88.0 | 85.0      | +3.0  |
| $\bar{d}$ |      |           | 3.20  |
| $s_d$     |      |           | 2.77  |

$$t = \frac{3.20}{2.77/\sqrt{5}} \approx 2.58$$

## Resultado

 $t_{\text{crit}}(gl = 4, \alpha = 0.025) = 2.776$ . $2.58 < 2.776$ : **não rejeitamos**  $H_0$  ( $p \approx 0.06$ ).

## Lição: Poder do Teste

Com apenas  $n = 5$  folds, o teste tem **poder reduzido**. O resultado é *borderline*, repetir com 10+ folds pode revelar diferença significativa.

## Exemplo 3 — ANOVA: KNN vs DT vs Naive Bayes

### Cenário e Hipóteses

Três algoritmos, 5 folds. Existe diferença entre eles?

$H_0 : \mu_{\text{KNN}} = \mu_{\text{DT}} = \mu_{\text{NB}}$      $H_1$ : ao menos uma média difere.

| Fold                                | KNN  | Decision Tree | Naive Bayes |
|-------------------------------------|------|---------------|-------------|
| 1                                   | 82.0 | 78.0          | 75.0        |
| 2                                   | 84.0 | 80.0          | 76.0        |
| 3                                   | 81.0 | 79.0          | 74.0        |
| 4                                   | 85.0 | 82.0          | 77.0        |
| 5                                   | 83.0 | 80.0          | 73.0        |
| <b>Média <math>\bar{x}_j</math></b> | 83.0 | 79.8          | 75.0        |

Média global:  $\bar{x} = (83.0 + 79.8 + 75.0)/3 = 79.27$

## Exemplo 3 — ANOVA: KNN vs DT vs Naive Bayes

### Cenário e Hipóteses

Três algoritmos, 5 folds. Existe diferença entre eles?

$H_0 : \mu_{\text{KNN}} = \mu_{\text{DT}} = \mu_{\text{NB}}$      $H_1$ : ao menos uma média difere.

| Fold                                | KNN  | Decision Tree | Naive Bayes |
|-------------------------------------|------|---------------|-------------|
| 1                                   | 82.0 | 78.0          | 75.0        |
| 2                                   | 84.0 | 80.0          | 76.0        |
| 3                                   | 81.0 | 79.0          | 74.0        |
| 4                                   | 85.0 | 82.0          | 77.0        |
| 5                                   | 83.0 | 80.0          | 73.0        |
| <b>Média <math>\bar{x}_j</math></b> | 83.0 | 79.8          | 75.0        |

Média global:  $\bar{x} = (83.0 + 79.8 + 75.0)/3 = 79.27$

## Exemplo 3 — ANOVA: KNN vs DT vs Naive Bayes

### Cenário e Hipóteses

Três algoritmos, 5 folds. Existe diferença entre eles?

$H_0 : \mu_{\text{KNN}} = \mu_{\text{DT}} = \mu_{\text{NB}}$      $H_1$ : ao menos uma média difere.

| Fold                                | KNN  | Decision Tree | Naive Bayes |
|-------------------------------------|------|---------------|-------------|
| 1                                   | 82.0 | 78.0          | 75.0        |
| 2                                   | 84.0 | 80.0          | 76.0        |
| 3                                   | 81.0 | 79.0          | 74.0        |
| 4                                   | 85.0 | 82.0          | 77.0        |
| 5                                   | 83.0 | 80.0          | 73.0        |
| <b>Média <math>\bar{x}_j</math></b> | 83.0 | 79.8          | 75.0        |

Média global:  $\bar{x} = (83.0 + 79.8 + 75.0)/3 = 79.27$

## Exemplo 3 — ANOVA: Cálculo da Estatística $F$

$$SS_{\text{entre}} = n \sum_j (\bar{x}_j - \bar{x})^2 = 5[(83-79.27)^2 + (79.8-79.27)^2 + (75-79.27)^2] = 162.1$$

$$SS_{\text{dentro}} = \sum_j \sum_i (x_{ij} - \bar{x}_j)^2 = \underbrace{10}_{\text{KNN}} + \underbrace{8.8}_{\text{DT}} + \underbrace{10}_{\text{NB}} = 28.8$$

| Fonte         | $SS$  | $gl$ | $MS$  | $F$          |
|---------------|-------|------|-------|--------------|
| Entre grupos  | 162.1 | 2    | 81.05 | <b>33.77</b> |
| Dentro grupos | 28.8  | 12   | 2.40  |              |
| Total         | 190.9 | 14   |       |              |

### Decisão e Post-hoc

$F_{\text{crit}}(2, 12) = 3.89$ . Como  $F = 33.77 \gg 3.89$ : **rejeitamos  $H_0$**  ( $p < 0.001$ ).

ANOVA indica diferença, mas **não diz qual par difere**. Use **Tukey HSD** ou **Bonferroni**.

KNN (83%) supera NB (75%) por 8 p.p. Diferença estatística e prática.

Exemplo 3 — ANOVA: Cálculo da Estatística  $F$ 

$$SS_{\text{entre}} = n \sum_j (\bar{x}_j - \bar{x})^2 = 5 [(83 - 79.27)^2 + (79.8 - 79.27)^2 + (75 - 79.27)^2] = 162.1$$

$$SS_{\text{dentro}} = \sum_j \sum_i (x_{ij} - \bar{x}_j)^2 = \underbrace{10}_{\text{KNN}} + \underbrace{8.8}_{\text{DT}} + \underbrace{10}_{\text{NB}} = 28.8$$

| Fonte         | $SS$  | $gl$ | $MS$  | $F$          |
|---------------|-------|------|-------|--------------|
| Entre grupos  | 162.1 | 2    | 81.05 | <b>33.77</b> |
| Dentro grupos | 28.8  | 12   | 2.40  |              |
| Total         | 190.9 | 14   |       |              |

## Decisão e Post-hoc

$F_{\text{crit}}(2, 12) = 3.89$ . Como  $F = 33.77 \gg 3.89$ : **rejeitamos  $H_0$**  ( $p < 0.001$ ).

ANOVA indica diferença, mas **não diz qual par difere**. Use **Tukey HSD** ou **Bonferroni**.

KNN (83%) supera NB (75%) por 8 p.p. Diferença estatística e prática.

## Exemplo 3 — ANOVA: Cálculo da Estatística $F$

$$SS_{\text{entre}} = n \sum_j (\bar{x}_j - \bar{x})^2 = 5[(83-79.27)^2 + (79.8-79.27)^2 + (75-79.27)^2] = 162.1$$

$$SS_{\text{dentro}} = \sum_j \sum_i (x_{ij} - \bar{x}_j)^2 = \underbrace{10}_{\text{KNN}} + \underbrace{8.8}_{\text{DT}} + \underbrace{10}_{\text{NB}} = 28.8$$

| Fonte         | $SS$  | $gl$ | $MS$  | $F$          |
|---------------|-------|------|-------|--------------|
| Entre grupos  | 162.1 | 2    | 81.05 | <b>33.77</b> |
| Dentro grupos | 28.8  | 12   | 2.40  |              |
| Total         | 190.9 | 14   |       |              |

### Decisão e Post-hoc

$F_{\text{crit}}(2, 12) = 3.89$ . Como  $F = 33.77 \gg 3.89$ : **rejeitamos  $H_0$**  ( $p < 0.001$ ).

ANOVA indica diferença, mas **não diz qual par difere**. Use **Tukey HSD** ou **Bonferroni**.

KNN (83%) supera NB (75%) por 8 p.p. Diferença estatística e prática.

## Exemplo 3 — ANOVA: Cálculo da Estatística $F$

$$SS_{\text{entre}} = n \sum_j (\bar{x}_j - \bar{x})^2 = 5[(83-79.27)^2 + (79.8-79.27)^2 + (75-79.27)^2] = 162.1$$

$$SS_{\text{dentro}} = \sum_j \sum_i (x_{ij} - \bar{x}_j)^2 = \underbrace{10}_{\text{KNN}} + \underbrace{8.8}_{\text{DT}} + \underbrace{10}_{\text{NB}} = 28.8$$

| Fonte         | $SS$  | $gl$ | $MS$  | $F$          |
|---------------|-------|------|-------|--------------|
| Entre grupos  | 162.1 | 2    | 81.05 | <b>33.77</b> |
| Dentro grupos | 28.8  | 12   | 2.40  |              |
| Total         | 190.9 | 14   |       |              |

### Decisão e Post-hoc

$F_{\text{crit}}(2, 12) = 3.89$ . Como  $F = 33.77 \gg 3.89$ : **rejeitamos  $H_0$**  ( $p < 0.001$ ).

ANOVA indica diferença, mas **não diz qual par** difere. Use **Tukey HSD** ou **Bonferroni**.

KNN (83%) supera NB (75%) por 8 p.p. Diferença estatística e prática.

## Correlação de Pearson: Definição

### Fórmula

$$r = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2 \cdot \sum_{i=1}^n (y_i - \bar{y})^2}} \in [-1, 1]$$

### Escala de Interpretação

| $ r $     | Interpretação |
|-----------|---------------|
| 0.90–1.00 | Muito forte   |
| 0.70–0.89 | Forte         |
| 0.50–0.69 | Moderada      |
| 0.30–0.49 | Fraca         |
| $< 0.30$  | Desprezível   |

### Limitações

- ▶ Mede apenas relação **linear**
- ▶ Sensível a outliers
- ▶ **Correlação  $\neq$  Causalidade**
- ▶ Para relações não-lineares: use Spearman ou Informação Mútua

## Correlação de Pearson: Definição

### Fórmula

$$r = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2 \cdot \sum_{i=1}^n (y_i - \bar{y})^2}} \in [-1, 1]$$

### Escala de Interpretação

| $ r $     | Interpretação |
|-----------|---------------|
| 0.90–1.00 | Muito forte   |
| 0.70–0.89 | Forte         |
| 0.50–0.69 | Moderada      |
| 0.30–0.49 | Fraca         |
| < 0.30    | Desprezível   |

### Limitações

- ▶ Mede apenas relação **linear**
- ▶ Sensível a outliers
- ▶ **Correlação  $\neq$  Causalidade**
- ▶ Para relações não-lineares: use Spearman ou Informação Mútua

## Correlação de Pearson: Definição

### Fórmula

$$r = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2 \cdot \sum_{i=1}^n (y_i - \bar{y})^2}} \in [-1, 1]$$

### Escala de Interpretação

| $ r $     | Interpretação |
|-----------|---------------|
| 0.90–1.00 | Muito forte   |
| 0.70–0.89 | Forte         |
| 0.50–0.69 | Moderada      |
| 0.30–0.49 | Fraca         |
| < 0.30    | Desprezível   |

### Limitações

- ▶ Mede apenas relação **linear**
- ▶ Sensível a outliers
- ▶ **Correlação**  $\neq$  **Causalidade**
- ▶ Para relações não-lineares: use Spearman ou Informação Mútua

## Exemplo — Pearson: Horas de Estudo vs Nota Final

### Cenário

8 alunos. Existe correlação linear entre horas de estudo semanal e nota final (0–10)?

| Aluno | $x_i$ (h)        | $y_i$ (nota)     | $(x_i - \bar{x})$ | $(y_i - \bar{y})$ | $(x_i - \bar{x})(y_i - \bar{y})$ |
|-------|------------------|------------------|-------------------|-------------------|----------------------------------|
| 1     | 2.0              | 4.5              | -3.25             | -2.88             | 9.36                             |
| 2     | 3.0              | 5.0              | -2.25             | -2.38             | 5.36                             |
| 3     | 4.0              | 5.5              | -1.25             | -1.88             | 2.35                             |
| 4     | 5.0              | 6.0              | -0.25             | -1.38             | 0.35                             |
| 5     | 6.0              | 7.5              | +0.75             | +0.12             | 0.09                             |
| 6     | 7.0              | 8.0              | +1.75             | +0.62             | 1.09                             |
| 7     | 9.0              | 9.0              | +3.75             | +1.62             | 6.08                             |
| 8     | 10.0             | 9.5              | +4.75             | +2.12             | 10.07                            |
| Média | $\bar{x} = 5.25$ | $\bar{y} = 7.38$ | $\sum = 34.75$    |                   |                                  |

## Exemplo — Pearson: Horas de Estudo vs Nota Final

### Cenário

8 alunos. Existe correlação linear entre horas de estudo semanal e nota final (0–10)?

| Aluno        | $x_i$ (h)        | $y_i$ (nota)     | $(x_i - \bar{x})$ | $(y_i - \bar{y})$ | $(x_i - \bar{x})(y_i - \bar{y})$ |
|--------------|------------------|------------------|-------------------|-------------------|----------------------------------|
| 1            | 2.0              | 4.5              | -3.25             | -2.88             | 9.36                             |
| 2            | 3.0              | 5.0              | -2.25             | -2.38             | 5.36                             |
| 3            | 4.0              | 5.5              | -1.25             | -1.88             | 2.35                             |
| 4            | 5.0              | 6.0              | -0.25             | -1.38             | 0.35                             |
| 5            | 6.0              | 7.5              | +0.75             | +0.12             | 0.09                             |
| 6            | 7.0              | 8.0              | +1.75             | +0.62             | 1.09                             |
| 7            | 9.0              | 9.0              | +3.75             | +1.62             | 6.08                             |
| 8            | 10.0             | 9.5              | +4.75             | +2.12             | 10.07                            |
| <b>Média</b> | $\bar{x} = 5.25$ | $\bar{y} = 7.38$ |                   |                   | $\sum = 34.75$                   |

## Pearson — Cálculo Passo a Passo

$$\sum (x_i - \bar{x})^2 = 10.56 + 5.06 + 1.56 + 0.06 + 0.56 + 3.06 + 14.06 + 22.56 = 57.50$$

$$\sum (y_i - \bar{y})^2 = 8.29 + 5.66 + 3.53 + 1.90 + 0.01 + 0.38 + 2.62 + 4.49 = 26.88$$

$$r = \frac{34.75}{\sqrt{57.50 \times 26.88}} = \frac{34.75}{39.31} \approx \mathbf{0.884} \quad (\text{correlação forte positiva})$$

### Significância estatística

$$t = r \sqrt{\frac{n-2}{1-r^2}} = 0.884 \times \sqrt{\frac{6}{1-0.781}} \approx 4.62$$

$t_{\text{crit}}(gl = 6, \alpha = 0.05) = 2.447$ . Como  $4.62 > 2.447$ : **correlação estatisticamente significativa** ( $p \approx 0.004$ ).

## Pearson — Cálculo Passo a Passo

$$\sum (x_i - \bar{x})^2 = 10.56 + 5.06 + 1.56 + 0.06 + 0.56 + 3.06 + 14.06 + 22.56 = 57.50$$

$$\sum (y_i - \bar{y})^2 = 8.29 + 5.66 + 3.53 + 1.90 + 0.01 + 0.38 + 2.62 + 4.49 = 26.88$$

$$r = \frac{34.75}{\sqrt{57.50 \times 26.88}} = \frac{34.75}{39.31} \approx \mathbf{0.884} \quad (\text{correlação forte positiva})$$

### Significância estatística

$$t = r \sqrt{\frac{n-2}{1-r^2}} = 0.884 \times \sqrt{\frac{6}{1-0.781}} \approx 4.62$$

$t_{\text{crit}}(gl = 6, \alpha = 0.05) = 2.447$ . Como  $4.62 > 2.447$ : **correlação estatisticamente significativa** ( $p \approx 0.004$ ).

## Pearson — Cálculo Passo a Passo

$$\sum (x_i - \bar{x})^2 = 10.56 + 5.06 + 1.56 + 0.06 + 0.56 + 3.06 + 14.06 + 22.56 = 57.50$$

$$\sum (y_i - \bar{y})^2 = 8.29 + 5.66 + 3.53 + 1.90 + 0.01 + 0.38 + 2.62 + 4.49 = 26.88$$

$$r = \frac{34.75}{\sqrt{57.50 \times 26.88}} = \frac{34.75}{39.31} \approx \mathbf{0.884} \quad (\text{correlação forte positiva})$$

### Significância estatística

$$t = r \sqrt{\frac{n-2}{1-r^2}} = 0.884 \times \sqrt{\frac{6}{1-0.781}} \approx 4.62$$

$t_{\text{crit}}(g/ = 6, \alpha = 0.05) = 2.447$ . Como  $4.62 > 2.447$ : **correlação estatisticamente significativa** ( $p \approx 0.004$ ).

## Pearson — Cálculo Passo a Passo

$$\sum (x_i - \bar{x})^2 = 10.56 + 5.06 + 1.56 + 0.06 + 0.56 + 3.06 + 14.06 + 22.56 = 57.50$$

$$\sum (y_i - \bar{y})^2 = 8.29 + 5.66 + 3.53 + 1.90 + 0.01 + 0.38 + 2.62 + 4.49 = 26.88$$


$$r = \frac{34.75}{\sqrt{57.50 \times 26.88}} = \frac{34.75}{39.31} \approx \mathbf{0.884} \quad (\text{correlação forte positiva})$$

### Significância estatística

$$t = r \sqrt{\frac{n-2}{1-r^2}} = 0.884 \times \sqrt{\frac{6}{1-0.781}} \approx 4.62$$

$t_{\text{crit}}(gl = 6, \alpha = 0.05) = 2.447$ . Como  $4.62 > 2.447$ : **correlação estatisticamente significativa** ( $p \approx 0.004$ ).

# Pearson — Visualização e Interpretação



## Interpretação

- ▶  $r = 0.884 \Rightarrow$  correlação forte positiva
- ▶ Quanto mais horas de estudo, maior tende a ser a nota
- ▶ Correlação é significativa ( $p = 0.004$ )


## Atenção

**Correlação  $\neq$  Causalidade.**

Outro fator (dedicação geral) pode explicar ambas as variáveis.

Pearson não detecta relações curvilíneas.

# Pearson — Visualização e Interpretação



## Interpretação

- ▶  $r = 0.884 \Rightarrow$  **correlação forte** positiva
- ▶ Quanto mais horas de estudo, maior tende a ser a nota
- ▶ Correlação é significativa ( $p = 0.004$ )


## Atenção

**Correlação  $\neq$  Causalidade.**

Outro fator (dedicação geral) pode explicar ambas as variáveis.

Pearson não detecta relações curvilíneas.

# Pearson — Visualização e Interpretação



## Interpretação

- ▶  $r = 0.884 \Rightarrow$  **correlação forte** positiva
- ▶ Quanto mais horas de estudo, maior tende a ser a nota
- ▶ Correlação é significativa ( $p = 0.004$ )

## Atenção

**Correlação  $\neq$  Causalidade.**

Outro fator (dedicação geral) pode explicar ambas as variáveis.

Pearson não detecta relações curvilíneas.

## Tabela de Interpretação Prática

| $r$       | Interpretação        | Exemplo               | Uso                  |
|-----------|----------------------|-----------------------|----------------------|
| 0.90–1.00 | Muito forte positiva | Altura vs envergadura | Previsão direta      |
| 0.70–0.89 | Forte positiva       | Horas estudo vs nota  | Seleção de features  |
| 0.50–0.69 | Moderada positiva    | Renda vs consumo      | Análise exploratória |
| 0.30–0.49 | Fraca positiva       | Temperatura vs vendas | Usar com cuidado     |
| 0.00–0.29 | Desprezível          | Nº letras vs nota     | Descartar            |
| $< 0$     | Negativa             | Horas TV vs nota      | Mesma escala         |

### Regras Práticas para Seleção de Features

- ▶ Remova features com  $|r| < 0.10$  em relação ao alvo (sinal fraco)
- ▶ Features com  $|r| > 0.95$  entre si são redundantes, mantenha apenas uma
- ▶ Pearson é pré-filtro rápido; confirme com Informação Mútua para relações não-lineares

## Tabela de Interpretação Prática

| $r$       | Interpretação        | Exemplo               | Uso                  |
|-----------|----------------------|-----------------------|----------------------|
| 0.90–1.00 | Muito forte positiva | Altura vs envergadura | Previsão direta      |
| 0.70–0.89 | Forte positiva       | Horas estudo vs nota  | Seleção de features  |
| 0.50–0.69 | Moderada positiva    | Renda vs consumo      | Análise exploratória |
| 0.30–0.49 | Fraca positiva       | Temperatura vs vendas | Usar com cuidado     |
| 0.00–0.29 | Desprezível          | Nº letras vs nota     | Descartar            |
| $< 0$     | Negativa             | Horas TV vs nota      | Mesma escala         |

### Regras Práticas para Seleção de Features

- ▶ Remova features com  $|r| < 0.10$  em relação ao alvo (sinal fraco)
- ▶ Features com  $|r| > 0.95$  entre si são redundantes, mantenha apenas uma
- ▶ Pearson é pré-filtro rápido; confirme com Informação Mútua para relações não-lineares

# Spearman, Kendall e Informação Mútua

## Correlação de Spearman ( $\rho$ )

Aplica Pearson sobre os **postos** (*ranks*) dos dados.

- ▶ Detecta relações **monotônicas** (não só lineares)
- ▶ Robusta a outliers
- ▶ Indicada para dados ordinais ou distribuição assimétrica

## Tau de Kendall ( $\tau$ )

Baseado em pares **concordantes/discordantes**.

- ▶ Mais robusto que Spearman para  $n$  pequeno
- ▶ Interpretação probabilística direta

## Informação Mútua $I(X; Y)$

$$I(X; Y) = \sum_{x,y} p(x, y) \log \frac{p(x, y)}{p(x) p(y)}$$

- ▶ Mede dependência **geral** (não apenas linear)
- ▶  $I(X; Y) = 0$  somente se  $X$  e  $Y$  são independentes
- ▶ Usado em seleção de features: **MRMR**
- ▶ Captura relações complexas que Pearson ignora

Prefira Spearman ou IM quando há suspeita de relação não-linear ou presença de outliers.

# Spearman, Kendall e Informação Mútua

## Correlação de Spearman ( $\rho$ )

Aplica Pearson sobre os **postos** (*ranks*) dos dados.

- ▶ Detecta relações **monotônicas** (não só lineares)
- ▶ Robusta a outliers
- ▶ Indicada para dados ordinais ou distribuição assimétrica

## Tau de Kendall ( $\tau$ )

Baseado em pares **concordantes/discordantes**.

- ▶ Mais robusto que Spearman para  $n$  pequeno
- ▶ Interpretação probabilística direta

## Informação Mútua $I(X; Y)$

$$I(X; Y) = \sum_{x,y} p(x, y) \log \frac{p(x, y)}{p(x) p(y)}$$

- ▶ Mede dependência **geral** (não apenas linear)
- ▶  $I(X; Y) = 0$  somente se  $X$  e  $Y$  são independentes
- ▶ Usado em seleção de features: **MRMR**
- ▶ Captura relações complexas que Pearson ignora

Prefira Spearman ou IM quando há suspeita de relação não-linear ou presença de outliers.

# Spearman, Kendall e Informação Mútua

## Correlação de Spearman ( $\rho$ )

Aplica Pearson sobre os **postos** (*ranks*) dos dados.

- ▶ Detecta relações **monotônicas** (não só lineares)
- ▶ Robusta a outliers
- ▶ Indicada para dados ordinais ou distribuição assimétrica

## Tau de Kendall ( $\tau$ )

Baseado em pares **concordantes/discordantes**.

- ▶ Mais robusto que Spearman para  $n$  pequeno
- ▶ Interpretação probabilística direta

## Informação Mútua $I(X; Y)$

$$I(X; Y) = \sum_{x,y} p(x, y) \log \frac{p(x, y)}{p(x) p(y)}$$

- ▶ Mede dependência **geral** (não apenas linear)
- ▶  $I(X; Y) = 0$  somente se  $X$  e  $Y$  são independentes
- ▶ Usado em seleção de features: **MRMR**
- ▶ Captura relações complexas que Pearson ignora

Prefira Spearman ou IM quando há suspeita de relação não-linear ou presença de outliers.

# Spearman, Kendall e Informação Mútua

## Correlação de Spearman ( $\rho$ )

Aplica Pearson sobre os **postos** (*ranks*) dos dados.

- ▶ Detecta relações **monotônicas** (não só lineares)
- ▶ Robusta a outliers
- ▶ Indicada para dados ordinais ou distribuição assimétrica

## Tau de Kendall ( $\tau$ )

Baseado em pares **concordantes/discordantes**.

- ▶ Mais robusto que Spearman para  $n$  pequeno
- ▶ Interpretação probabilística direta

## Informação Mútua $I(X; Y)$

$$I(X; Y) = \sum_{x,y} p(x, y) \log \frac{p(x, y)}{p(x) p(y)}$$

- ▶ Mede dependência **geral** (não apenas linear)
- ▶  $I(X; Y) = 0$  somente se  $X$  e  $Y$  são independentes
- ▶ Usado em seleção de features: **MRMR**
- ▶ Captura relações complexas que Pearson ignora

Prefira Spearman ou IM quando há suspeita de relação não-linear ou presença de outliers.

## Distribuições Relevantes em Mineração de Dados

| Distribuição        | Suporte           | Uso em DM                                        |
|---------------------|-------------------|--------------------------------------------------|
| <b>Normal</b>       | $\mathbb{R}$      | Ruído, GMM, testes paramétricos                  |
| <b>Bernoulli</b>    | $\{0, 1\}$        | Classificação binária, Naive Bayes               |
| <b>Binomial</b>     | $\{0, \dots, n\}$ | Contagem de acertos, limiar de confiança         |
| <b>Poisson</b>      | $\mathbb{N}_0$    | Contagem de eventos raros, anomalias             |
| <b>Exponencial</b>  | $[0, +\infty)$    | Tempo entre eventos, outliers                    |
| <b>t-Student</b>    | $\mathbb{R}$      | Testes estatísticos com amostras pequenas        |
| <b>Qui-Quadrado</b> | $[0, +\infty)$    | Teste de independência (tabelas de contingência) |

### Antes de Aplicar Testes Paramétricos

Verifique normalidade com **Shapiro-Wilk** ou **Q-Q plot**. Se  $n > 30$ , o Teorema Central do Limite garante aproximação normal, mesmo sem normalidade das populações.

## Distribuições Relevantes em Mineração de Dados

| Distribuição        | Suporte           | Uso em DM                                        |
|---------------------|-------------------|--------------------------------------------------|
| <b>Normal</b>       | $\mathbb{R}$      | Ruído, GMM, testes paramétricos                  |
| <b>Bernoulli</b>    | $\{0, 1\}$        | Classificação binária, Naive Bayes               |
| <b>Binomial</b>     | $\{0, \dots, n\}$ | Contagem de acertos, limiar de confiança         |
| <b>Poisson</b>      | $\mathbb{N}_0$    | Contagem de eventos raros, anomalias             |
| <b>Exponencial</b>  | $[0, +\infty)$    | Tempo entre eventos, outliers                    |
| <b>t-Student</b>    | $\mathbb{R}$      | Testes estatísticos com amostras pequenas        |
| <b>Qui-Quadrado</b> | $[0, +\infty)$    | Teste de independência (tabelas de contingência) |

### Antes de Aplicar Testes Paramétricos

Verifique normalidade com **Shapiro-Wilk** ou **Q-Q plot**. Se  $n > 30$ , o Teorema Central do Limite garante aproximação normal, mesmo sem normalidade das populações.


# O que é Clustering?

## Definição

Tarefa de **aprendizado não-supervisionado** que organiza exemplos similares em grupos (clusters) sem o uso de rótulos pré-definidos.

## Aplicações

- ▶ ➔ **Segmentação de clientes:** grupos de comportamento de compra
- ▶ ➔ **Deteção de anomalias:** pontos sem cluster são outliers
- ▶ ➔ **Compressão de imagens:** quantização de cores com K-Means
- ▶ ➔ **Bioinformática:** agrupamento de genes por expressão
- ▶ ➔ **Modelagem de tópicos:** agrupamento de documentos



Avalie resultados com métricas e visualização (PCA, t-SNE, UMAP).

## K-Means: Conceito e Objetivo

Objetivo: Minimizar Inércia

$$J = \sum_{k=1}^K \sum_{\mathbf{x}_i \in C_k} \|\mathbf{x}_i - \boldsymbol{\mu}_k\|^2$$

onde  $\boldsymbol{\mu}_k$  é o centróide do cluster  $k$ .

Resumo do Algoritmo (Lloyd, 1982)

1. Inicializar  $K$  centróides (aleatório ou K-Means++)
2. **Atribuição:** cada ponto vai ao centróide mais próximo
3. **Atualização:** mover centróide para a média do cluster
4. Repetir 2–3 até convergência

Propriedades

- ▶ **Complexidade:**  $O(n \cdot K \cdot d \cdot i)$ , onde  $d$  é a dimensão e  $i$  o número de iterações
  - ▶ **Convergência:** garantida (mas pode ser ótimo local)
  - ▶ **Limitações:** assume clusters **esféricos e de tamanho similar**; sensível a outliers e inicialização
  - ▶ **Distância:** euclidiana por padrão
- ➔ Consulte Material Didático e Colab para implementação em Python

## K-Means: Passo a Passo com Exemplo

Exemplo:  $K = 2$ , ponto  $\mathbf{x} = (5, 3)$

Centróides iniciais:  $C_1 = (2, 4)$  e  $C_2 = (6, 1)$

**Passo 3: Atribuição**

$$d(\mathbf{x}, C_1) = \sqrt{9 + 1} \approx 3.16$$


$$d(\mathbf{x}, C_2) = \sqrt{1 + 4} \approx 2.24$$

$\Rightarrow$  atribuir  $(5, 3)$  ao cluster  $C_2$


**Passo 4: Recalcular centróide**

Pontos em  $C_1$ :  $(3, 4), (4, 1), (2, 3), (2, 6), (3, 3)$

$$\mu_1 = \frac{1}{5}(14, 17) = (2.8, 3.4)$$



## K-Means: Visualização das Etapas



Cada iteração atualiza centróides até que os clusters se estabilizem.

→ Ver algoritmo completo no Material Didático Módulo 6.

## Escolha de K: Método do Cotovelo

### Ideia


Plota a **inércia** (WCSS) para  $K = 1, 2, \dots$ . O ponto onde a redução desacelera, formando um “cotovelo”, indica o  $K$  ótimo.

$$WCSS(K) = \sum_{k=1}^K \sum_{\mathbf{x}_i \in C_k} \|\mathbf{x}_i - \boldsymbol{\mu}_k\|^2$$

### Limitação

O cotovelo pode ser ambíguo em dados sobrepostos. Combine sempre com a **Análise de Silhouette**.

### Método do Cotovelo



De  $K = 2$  para  $K = 3$ : queda de  $-60\%$  na inércia. De  $K = 3$  em diante: ganho marginal pequeno.

## Escolha de K: Análise de Silhouette

### Coeficiente de Silhouette

Para cada ponto  $x_i$  no cluster  $C_k$ :


$a(i)$  = distância média intra-cluster

$b(i)$  = distância média ao vizinho mais próximo

$$s(i) = \frac{b(i) - a(i)}{\max\{a(i), b(i)\}} \in [-1, 1]$$

### Interpretação

- ▶  $s \approx +1$ : ponto bem dentro do cluster
- ▶  $s \approx 0$ : ponto na fronteira
- ▶  $s \approx -1$ : ponto no cluster errado
- ▶  $\bar{s} > 0.5$ : clustering de qualidade



Use **Elbow** e **Silhouette** juntos para maior confiabilidade na escolha de  $K$ .

## Variantes do K-Means

### K-Means++

Inicialização inteligente: cada centróide é escolhido com probabilidade proporcional à distância ao centróide mais próximo já escolhido.

- ▶ Evita inicializações ruins
- ▶ Garante aproximação  $O(\log K)$  do ótimo
- ▶ **Padrão** no scikit-learn

### K-Medoids (PAM)

Usa exemplos reais como centróides (medóides).

- ▶ Mais robusto a outliers que K-Means
- ▶ Interpretável: centróide é um ponto real
- ▶ Mais custoso computacionalmente

### Mini-Batch K-Means

Atualiza centróides com mini-lotes aleatórios a cada iteração.

- ▶ Escala para datasets de **milhões** de exemplos
- ▶ Resultado ligeiramente pior que K-Means padrão
- ▶ Ideal para dados em stream

### Quando K-Means falha

Clusters não esféricos, de tamanhos muito diferentes, ou com muitos outliers. Nesses casos, prefira DBSCAN, GMM ou Spectral Clustering.

# Clustering Hierárquico

## Conceito


Cria uma **hierarquia** de agrupamentos em um **dendrograma**, sem necessitar especificar  $K$  antecipadamente.

## Abordagens

- ▶ **Agglomerativo (bottom-up)**: começa com  $N$  clusters e mescla os dois mais próximos iterativamente
- ▶ **Divisivo (top-down)**: começa com um cluster e divide recursivamente

## CrITÉrios de Ligação

- ▶ **Single**: distância mínima, sensível a outliers
- ▶ **Complete**: distância máxima, clusters compactos
- ▶ **Average (UPGMA)**: equilíbrio entre os dois
- ▶ **Ward**: minimiza variância intra-cluster (+popular)



# DBSCAN: Clustering Baseado em Densidade

## Conceito


Encontra clusters de **forma arbitrária** e detecta **ruído/outliers** automaticamente. Parâmetros:  $\epsilon$  (raio) e MinPts (vizinhos mínimos).

## Tipos de Pontos

- ▶ **Núcleo:**  $\geq$  MinPts vizinhos em raio  $\epsilon$
- ▶ **Fronteira:** dentro do raio de um núcleo, mas não é núcleo
- ▶ **Ruído:** não é núcleo nem fronteira

## Vantagem sobre K-Means

Não precisa especificar  $K$ . Detecta clusters de qualquer forma geométrica e identifica outliers automaticamente.



Clusters: azul e laranja — ruído: vermelho

Estimar  $\epsilon$  pelo gráfico da  $k$ -NN distance (joelho da curva).

## HDBSCAN: Extensão Hierárquica do DBSCAN

### Limitação do DBSCAN

DBSCAN usa um único  $\varepsilon$  global. Se os clusters têm **densidades diferentes**, um único limiar não funciona bem.


### HDBSCAN (McInnes et al., 2017)

Varia o limiar de densidade automaticamente ao longo de uma hierarquia. Extrai os clusters mais **persistentes**.

- ▶ Apenas `min_cluster_size` é crítico
- ▶ Detecta clusters com densidades variáveis
- ▶ Retorna **probabilidade** de pertencimento
- ▶ Padrão no scikit-learn  $\geq 1.3$

### Pipeline UMAP + HDBSCAN

Abordagem moderna para dados de alta dimensão:



→ Muito eficaz para NLP (embeddings), genômica (scRNA-seq) e BERTopic

## Modelos de Mistura Gaussiana (GMM)

### Modelo

Os dados são gerados por uma **mistura** de  $K$  Gaussianas:

$$p(\mathbf{x}) = \sum_{k=1}^K \pi_k \mathcal{N}(\mathbf{x} \mid \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)$$

$\pi_k$ : peso da componente  $k$  ( $\sum_k \pi_k = 1$ )

### Treinamento: Algoritmo EM

1. **E-step:** calcular responsabilidades  $r_{ik}$  (probabilidade de  $\mathbf{x}_i$  pertencer ao cluster  $k$ )
2. **M-step:** atualizar  $\pi_k$ ,  $\boldsymbol{\mu}_k$  e  $\boldsymbol{\Sigma}_k$
3. Repetir até convergência da log-verossimilhança

### GMM vs K-Means

| Aspecto        | K-Means   | GMM           |
|----------------|-----------|---------------|
| Atribuição     | Dura      | Suave         |
| Forma cluster  | Esférica  | Elipsoidal    |
| Pertencimento  | 0/1       | Probabilidade |
| Seleção de $K$ | Elbow/Sil | BIC/AIC       |
| Parâmetros     | Poucos    | Mais          |

### Seleção de $K$ no GMM

Minimize o **BIC** (Bayesian Information Criterion):

$$\text{BIC} = -2 \log \hat{L} + p \log N$$

## Avaliação de Agrupamentos

### Métricas Internas (sem rótulos)

- ▶ **Silhouette Score**  $\bar{s}$ : coesão interna vs separação externa.  $\bar{s} \in [-1, 1]$ , maximize.
- ▶ **Davies-Bouldin (DB)**:  
$$DB = \frac{1}{K} \sum_k \max_{k' \neq k} \frac{s_k + s_{k'}}{\|c_k - c_{k'}\|}$$
  
Minimize. Penaliza clusters compactos mas muito próximos.
- ▶ **Calinski-Harabasz**: razão dispersão inter/intra-cluster. Maximize.

### Métricas Externas (com rótulos verdadeiros)

- ▶ **ARI (Adjusted Rand Index)**:  $\in [-1, 1]$ ; 1 = perfeito; 0 = aleatório. Ajustado para chance.
- ▶ **NMI (Normalized Mutual Information)**:  
$$NMI(U, V) = \frac{2 \cdot I(U; V)}{H(U) + H(V)} \in [0, 1]$$
- ▶ **V-Measure**: média harmônica de *homogeneidade* e *completude*.

### Boas Práticas

Nunca use apenas uma métrica. Combine métricas **internas** + **externas** (quando disponíveis) + visualização (PCA, t-SNE, UMAP).

## Regras de Associação: Conceitos

### O Problema

Dado um banco de transações, encontrar regras do tipo  $A \Rightarrow B$  com alta frequência e confiabilidade.

**Exemplo:**  $\{\text{leite}\} \Rightarrow \{\text{pão}\}$

### Medidas de Interesse

$$\text{sup}(A \Rightarrow B) = \frac{|\{T: A \cup B \subseteq T\}|}{|\mathcal{T}|}$$

$$\text{conf}(A \Rightarrow B) = \frac{\text{sup}(A \cup B)}{\text{sup}(A)}$$

$$\text{lift}(A \Rightarrow B) = \frac{\text{conf}(A \Rightarrow B)}{\text{sup}(B)}$$

### Interpretação do Lift

- ▶ **lift** > 1: correlação positiva; a regra é mais frequente que o esperado por acaso
- ▶ **lift** = 1:  $A$  e  $B$  independentes
- ▶ **lift** < 1: correlação negativa (anti-regra)

### Exemplo: Cesta de Mercado

5 transações. Para  $\{\text{leite}\} \Rightarrow \{\text{pão}\}$ :

$$\text{sup} = 3/5 = 0.60$$

$$\text{conf} = 0.60/0.80 = 0.75$$

$$\text{lift} = 0.75/0.60 = 1.25$$

✓ Correlação positiva: comprar leite favorece comprar pão.

# Algoritmo Apriori

## Princípio Anti-Monótono

Se um itemset é **infrequente**, todos os seus superconjuntos também são. Isso permite **podar** o espaço de busca.

## Etapas

1. Gerar itemsets frequentes de tamanho 1 ( $L_1$ )
2. Gerar candidatos de tamanho  $k + 1$  a partir de  $L_k$
3. Varrer transações e contar suporte
4. Filtrar candidatos com suporte  $\geq$  minsup
5. Repetir até  $L_k = \emptyset$
6. Gerar regras com confiança  $\geq$  minconf

## Limitações do Apriori


- ▶ Múltiplas varridas na base de dados ( $O(|\mathcal{I}|)$  varridas)
- ▶ Grande número de candidatos em datasets densos
- ▶ Ineficiente para bases muito grandes

## FP-Growth (Han et al., 2000)

- ▶ Apenas **2 varridas** na base de dados
- ▶ Constrói uma **FP-Tree** (árvore compacta) que compartilha prefixos
- ▶ Sem geração explícita de candidatos
- ▶ Muito mais eficiente que Apriori em datasets grandes

➔ Implemente Apriori e FP-Growth no Colab do Módulo 6

- ▶ **Ponto:** instância individual muito diferente das demais  
*Ex.: transação de R\$50.000 numa conta comum*
- ▶ **Contextual:** instância anômala apenas em contexto específico  
*Ex.: 35°C em dezembro no RS*
- ▶ **Coletiva:** subconjunto de instâncias anômalo em conjunto; individualmente parecem normais  
*Ex.: padrão de compras incomum ao longo da semana*



# Métodos de Detecção de Anomalias

## Métodos Estatísticos

- ▶ **Z-score:** anomalia se  $|z| > 3$ . Assume distribuição Gaussiana.
- ▶ **Boxplot:** outlier se  $> Q_3 + 1.5 \cdot \text{IQR}$  ou  $< Q_1 - 1.5 \cdot \text{IQR}$
- ▶ **Grubbs Test:** teste formal para outlier único em amostra normal

## LOF (Breunig et al., 2000)

Compara a **densidade local** de um ponto com a de seus vizinhos.  $\text{LOF}(p) \gg 1$  indica anomalia.

- ▶ Detecta outliers locais (não depende de distribuição global)
- ▶ Sensível ao parâmetro  $k$  (número de vizinhos)

## Isolation Forest (Liu et al., 2008)

Constrói árvores de isolamento aleatórias. Anomalias são isoladas em **caminhos mais curtos**.

$$s(x, n) = 2^{-E[h(x)]/c(n)}$$

- ▶ Eficiente em alta dimensão
- ▶ Não assume forma da distribuição
- ▶ Eficaz para anomalias de ponto

## Autoencoder

Treina para reconstruir dados normais. **Alto erro de reconstrução**  $\|x - \hat{x}\|^2$  indica anomalia.

→ Consulte Colab para comparação prática de métodos

## Estado da Arte: Deep Clustering

### DEC (Xie et al., 2016)

**Deep Embedded Clustering:** autoencoder treinado conjuntamente com objetivo de clustering. Aprende representações otimizadas para agrupamento.

### SCAN (Van Gansbeke et al., 2020)

**Self-supervised clustering:** usa similaridade de vizinhos para treinar sem rótulos. Estado da arte em clustering de imagens.

### DINO (Caron et al., 2021)

Vision Transformer (ViT) auto-supervisionado revela estrutura de clustering sem fine-tuning. Propriedade emergente dos Transformers.

### Detecção de Outliers Moderna

- ▶ **PyOD** (Zhao et al., 2019): 40+ algoritmos unificados em API sklearn-compatível
- ▶ **COPOD** (Li et al., 2020): baseado em cópulas, sem hiperparâmetros, muito eficiente
- ▶ **ECOD** (Li et al., 2022): baseado em distribuição empírica cumulativa, interpretável
- ▶ **Anomalia em grafos:** GraphSAGE + Isolation Forest para fraudes em redes sociais

➔ Material Didático e Colab trazem experimentos com BERTopic e PyOD

## Pipeline Moderno: BERTopic e UMAP+HDBSCAN


### BERTopic (Grootendorst, 2022)

Modelagem de tópicos combinando:

1. **BERT embeddings:** representação semântica dos textos
2. **UMAP:** redução de dimensionalidade
3. **HDBSCAN:** agrupamento dos embeddings
4. **TF-IDF por cluster:** extração de palavras-chave representativas

Supera LDA em qualidade de tópicos.

Pipeline UMAP + HDBSCAN tornou-se padrão para NLP, genômica single-cell (scRNA-seq) e análise de



## Referências Bibliográficas

-  MacQueen, J. *Some methods for classification and analysis of multivariate observations*. BSMSP, 1967.
-  Arthur, D.; Vassilvitskii, S. *k-means++: The advantages of careful seeding*. SODA, 2007.
-  Ester, M. et al. *A density-based algorithm for discovering clusters in large spatial databases with noise*. KDD, 1996.
-  McInnes, L. et al. *hdbscan: Hierarchical density based clustering*. JOSS, 2017.
-  Han, J.; Pei, J.; Yin, Y. *Mining frequent patterns without candidate generation*. ACM SIGMOD, 2000.
-  Liu, F. T. et al. *Isolation Forest*. ICDM, 2008.
-  Bergstra, J.; Bengio, Y. *Random Search for Hyper-Parameter Optimization*. JMLR, 2012.
-  **Material Didático Módulo 6** e Notebook Colab disponíveis no repositório da disciplina.