

Mineração de Dados: Conceitos e Aplicações

Módulo 6: Métodos Estatísticos e Clustering

Prof. Elton Sarmanho¹
eltonss@ufpa.br

¹Faculdade de Sistemas de Informação - UFPA Campus Cametá

29 de junho de 2026

Roteiro da Aula

- Fundamentos Estatísticos

 - Testes de Hipótese

 - Correlação e Dependência

- Agrupamento (Clustering)

 - Conceitos Gerais

 - K-Means

 - Clustering Hierárquico

 - DBSCAN e HDBSCAN

 - Modelos de Mistura Gaussiana (GMM)

 - Avaliação de Agrupamentos

Roteiro da Aula

- Regras de Associação

 - Conceitos Fundamentais

 - Apriori e FP-Growth

- Detecção de Anomalias

 - Tipos e Métodos

- Estado da Arte (2020–2024)


O que é um Teste de Hipótese?

Definição

Procedimento para **decidir**, com base em evidências amostrais, se uma afirmação sobre uma população deve ser aceita ou rejeitada.

Componentes Essenciais

- ▶ H_0 (**hipótese nula**): posição padrão
ex. “RF e SVM têm mesma acurácia”
- ▶ H_1 (**alternativa**): o que queremos provar
- ▶ **Nível de significância α** : geralmente 0.05
 - ▶ Probabilidade de rejeitar H_0 quando H_0 é verdadeira (Erro Tipo I)
- ▶ **p-valor**: rejeita H_0 se $p < \alpha$
 - ▶ Probabilidade de observar os dados assumindo H_0 verdadeira




O que é um Teste de Hipótese?

Definição

Procedimento para **decidir**, com base em evidências amostrais, se uma afirmação sobre uma população deve ser aceita ou rejeitada.

Componentes Essenciais

- ▶ H_0 (**hipótese nula**): posição padrão
ex. “RF e SVM têm mesma acurácia”
- ▶ H_1 (**alternativa**): o que queremos provar
- ▶ **Nível de significância** α : geralmente 0.05
 - ▶ Probabilidade de rejeitar H_0 quando H_0 é verdadeira (Erro Tipo I)
- ▶ **p-valor**: rejeita H_0 se $p < \alpha$
 - ▶ Probabilidade de observar os dados assumindo H_0 verdadeira




O que é um Teste de Hipótese?

Definição

Procedimento para **decidir**, com base em evidências amostrais, se uma afirmação sobre uma população deve ser aceita ou rejeitada.

Componentes Essenciais

- ▶ H_0 (**hipótese nula**): posição padrão
ex. "RF e SVM têm mesma acurácia"
- ▶ H_1 (**alternativa**): o que queremos provar
- ▶ **Nível de significância** α : geralmente 0.05
 - ▶ Probabilidade de rejeitar H_0 quando H_0 é verdadeira (Erro Tipo I)
- ▶ **p-valor**: rejeita H_0 se $p < \alpha$
 - ▶ Probabilidade de observar os dados assumindo H_0 verdadeira



Tipos de Erro e Poder do Teste

Tabela de Decisão

	H_0 verdadeira	H_0 falsa
Não rejeitar	✓ Correto	Erro Tipo II (β)
Rejeitar	Erro Tipo I (α)	✓ Poder ($1 - \beta$)

Erros

- ▶ Erro Tipo I (α): rejeitar H_0 quando H_0 é verdadeira
- ▶ Erro Tipo II (β): não rejeitar H_0 quando H_0 é falsa
- ▶ Poder do teste ($1 - \beta$): probabilidade de rejeitar H_0 quando H_0 é falsa

Tipos de Erro e Poder do Teste

Tabela de Decisão

	H_0 verdadeira	H_0 falsa
Não rejeitar	✓ Correto	Erro Tipo II (β)
Rejeitar	Erro Tipo I (α)	✓ Poder ($1 - \beta$)

Erros

- ▶ **Erro Tipo I (α):** rejeitar H_0 quando H_0 é verdadeira
- ▶ **Erro Tipo II (β):** não rejeitar H_0 quando H_0 é falsa
- ▶ **Poder do teste ($1 - \beta$):** probabilidade de rejeitar H_0 quando H_0 é falsa

Tipos de Erro e Poder do Teste

Testes Relevantes em Mineração de Dados

- ▶ **Teste t pareado:** compara 2 classificadores nos mesmos folds
- ▶ **ANOVA:** compara 3 ou mais classificadores simultaneamente
- ▶ **Wilcoxon Signed-Rank:** alternativa não-paramétrica ao teste t
- ▶ **McNemar:** compara classificadores pelas matrizes de confusão

Teste t Pareado: Fórmula e Quando Usar

Fórmula

$$t = \frac{\bar{d}}{s_d/\sqrt{n}}, \quad \bar{d} = \frac{1}{n} \sum_{i=1}^n (a_i - b_i)$$

$\bar{d}$: média das diferenças por fold; s_d : desvio padrão.

Quando Usar

- ▶ Dois algoritmos nos *mesmos* folds (amostras pareadas)
- ▶ Diferenças aproximadamente normais
- ▶ Para $n < 30$, verificar normalidade das diferenças

Passos

1. Formular H_0 , H_1 e escolher α
2. Calcular $d_i = a_i - b_i$ para cada fold
3. Calcular $\bar{d}$, s_d e a estatística t
4. Comparar com $t_{\text{crítico}}(gl = n - 1, \alpha)$

Teste t Pareado: Fórmula e Quando Usar

Fórmula

$$t = \frac{\bar{d}}{s_d/\sqrt{n}}, \quad \bar{d} = \frac{1}{n} \sum_{i=1}^n (a_i - b_i)$$

$\bar{d}$: média das diferenças por fold; s_d : desvio padrão.

Quando Usar

- ▶ Dois algoritmos nos *mesmos* folds (amostras pareadas)
- ▶ Diferenças aproximadamente normais
- ▶ Para $n < 30$, verificar normalidade das diferenças

Passos

1. Formular H_0 , H_1 e escolher α
2. Calcular $d_i = a_i - b_i$ para cada fold
3. Calcular $\bar{d}$, s_d e a estatística t
4. Comparar com $t_{\text{crítico}}(gl = n - 1, \alpha)$

Teste t Pareado: Fórmula e Quando Usar

Fórmula

$$t = \frac{\bar{d}}{s_d / \sqrt{n}}, \quad \bar{d} = \frac{1}{n} \sum_{i=1}^n (a_i - b_i)$$

$\bar{d}$: média das diferenças por fold; s_d : desvio padrão.

Quando Usar

- ▶ Dois algoritmos nos *mesmos* folds (amostras pareadas)
- ▶ Diferenças aproximadamente normais
- ▶ Para $n < 30$, verificar normalidade das diferenças

Passos

1. Formular H_0 , H_1 e escolher α
2. Calcular $d_i = a_i - b_i$ para cada fold
3. Calcular $\bar{d}$, s_d e a estatística t
4. Comparar com $t_{\text{crítico}}(gl = n - 1, \alpha)$

O que determina o tipo de teste?

A Hipótese Alternativa (H_1)

A escolha é definida **antes** da coleta de dados, baseada na pergunta de pesquisa:

- ▶ **Teste Bilateral (Two-tailed):** Quando queremos detectar qualquer diferença, sem direção preferencial.
 - ▶ $H_1 : \mu \neq \mu_0$
- ▶ **Teste Unilateral (One-tailed):** Quando a teoria indica que o efeito só pode (ou só interessa) ocorrer em um sentido.
 - ▶ $H_1 : \mu > \mu_0$ (Direita) ou $H_1 : \mu < \mu_0$ (Esquerda)

Diferenças: Bilateral vs. Unilateral

Característica	Bilateral	Unilateral
Direção	Indiferente ($\neq$)	Específica ($>$ ou $<$)
Distribuição α	Dividido ($\alpha/2$ cada lado)	Total em uma cauda
Rigor	Mais conservador	Menos conservador
Poder	Menor poder estatístico	Maior poder (na direção certa)

Importante

No teste bilateral, o valor crítico de t ou z é sempre **maior**, pois a área de rejeição é empurrada para os extremos.

Exemplo 1 — RF vs SVM: Dados e Hipóteses

Cenário

Random Forest vs **SVM** em detecção de spam — 10 folds de validação cruzada.

Fold	RF (%)	SVM (%)
1	92.1	89.3
2	88.7	86.0
3	91.4	90.1
4	93.0	88.5
5	89.5	87.9
6	94.2	91.6
7	90.3	89.0
8	88.0	85.5
9	92.8	90.4
10	91.0	88.7

Hipóteses (unilateral)

- ▶ $H_0: \mu_{RF} = \mu_{SVM}$
- ▶ $H_1: \mu_{RF} > \mu_{SVM}$ (RF é melhor)
- ▶ $\alpha = 0.05$

Teste Escolhido

Mesmos folds $\Rightarrow$ **Teste t pareado** (amostras dependentes).

Exemplo 1 — RF vs SVM: Dados e Hipóteses

Cenário

Random Forest vs **SVM** em detecção de spam — 10 folds de validação cruzada.

Fold	RF (%)	SVM (%)
1	92.1	89.3
2	88.7	86.0
3	91.4	90.1
4	93.0	88.5
5	89.5	87.9
6	94.2	91.6
7	90.3	89.0
8	88.0	85.5
9	92.8	90.4
10	91.0	88.7

Hipóteses (unilateral)

- ▶ $H_0: \mu_{RF} = \mu_{SVM}$
- ▶ $H_1: \mu_{RF} > \mu_{SVM}$ (RF é melhor)
- ▶ $\alpha = 0.05$

Teste Escolhido

Mesmos folds $\Rightarrow$ **Teste t pareado** (amostras dependentes).

Exemplo 1 — RF vs SVM: Dados e Hipóteses

Cenário

Random Forest vs **SVM** em detecção de spam — 10 folds de validação cruzada.

Fold	RF (%)	SVM (%)
1	92.1	89.3
2	88.7	86.0
3	91.4	90.1
4	93.0	88.5
5	89.5	87.9
6	94.2	91.6
7	90.3	89.0
8	88.0	85.5
9	92.8	90.4
10	91.0	88.7

Hipóteses (unilateral)

- ▶ $H_0: \mu_{RF} = \mu_{SVM}$
- ▶ $H_1: \mu_{RF} > \mu_{SVM}$ (RF é melhor)
- ▶ $\alpha = 0.05$

Teste Escolhido

Mesmos folds $\Rightarrow$ **Teste t pareado** (amostras dependentes).

Exemplo 1 — RF vs SVM: Dados e Hipóteses

Cenário

Random Forest vs **SVM** em detecção de spam — 10 folds de validação cruzada.

Fold	RF (%)	SVM (%)
1	92.1	89.3
2	88.7	86.0
3	91.4	90.1
4	93.0	88.5
5	89.5	87.9
6	94.2	91.6
7	90.3	89.0
8	88.0	85.5
9	92.8	90.4
10	91.0	88.7

Hipóteses (unilateral)

- ▶ $H_0: \mu_{RF} = \mu_{SVM}$
- ▶ $H_1: \mu_{RF} > \mu_{SVM}$ (RF é melhor)
- ▶ $\alpha = 0.05$

Teste Escolhido

Mesmos folds $\Rightarrow$ **Teste t pareado** (amostras dependentes).

Exemplo 1 - RF vs SVM: Cálculo de t

Fold	RF	SVM	$d_i = \text{RF} - \text{SVM}$
1	92.1	89.3	+2.8
2	88.7	86.0	+2.7
3	91.4	90.1	+1.3
4	93.0	88.5	+4.5
5	89.5	87.9	+1.6
6	94.2	91.6	+2.6
7	90.3	89.0	+1.3
8	88.0	85.5	+2.5
9	92.8	90.4	+2.4
10	91.0	88.7	+2.3
Média $\bar{d}$			2.40
Desvio padrão s_d			0.91

$$t = \frac{\bar{d}}{s_d/\sqrt{n}} = \frac{2.40}{0.91/\sqrt{10}} = \frac{2.40}{0.288} \approx 8.33$$

Decisão

$t_{\text{crítico}}(gl = 9, \alpha = 0.05) = 1.833$. Como $8.33 \gg 1.833$ e $p < 0.001$ (computado) $\rightarrow$ rejeitamos H_0 ($p < \alpha$).
RF é estatisticamente superior ao SVM. $\Delta = 2.4\%$, logo avalie relevância prática no domínio.

Exemplo 1 - RF vs SVM: Cálculo de t

Fold	RF	SVM	$d_i = \text{RF} - \text{SVM}$
1	92.1	89.3	+2.8
2	88.7	86.0	+2.7
3	91.4	90.1	+1.3
4	93.0	88.5	+4.5
5	89.5	87.9	+1.6
6	94.2	91.6	+2.6
7	90.3	89.0	+1.3
8	88.0	85.5	+2.5
9	92.8	90.4	+2.4
10	91.0	88.7	+2.3
Média $\bar{d}$			2.40
Desvio padrão s_d			0.91

$$t = \frac{\bar{d}}{s_d/\sqrt{n}} = \frac{2.40}{0.91/\sqrt{10}} = \frac{2.40}{0.288} \approx 8.33$$

Decisão

$t_{\text{crítico}}(gl = 9, \alpha = 0.05) = 1.833$. Como $8.33 \gg 1.833$ e $p < 0.001$ (computado) $\rightarrow$ rejeitamos H_0 ($p < \alpha$).
RF é estatisticamente superior ao SVM. $\Delta = 2.4\%$, logo avalie relevância prática no domínio.

Exemplo 1 - RF vs SVM: Cálculo de t

Fold	RF	SVM	$d_i = \text{RF} - \text{SVM}$
1	92.1	89.3	+2.8
2	88.7	86.0	+2.7
3	91.4	90.1	+1.3
4	93.0	88.5	+4.5
5	89.5	87.9	+1.6
6	94.2	91.6	+2.6
7	90.3	89.0	+1.3
8	88.0	85.5	+2.5
9	92.8	90.4	+2.4
10	91.0	88.7	+2.3
Média $\bar{d}$			2.40
Desvio padrão s_d			0.91

$$t = \frac{\bar{d}}{s_d/\sqrt{n}} = \frac{2.40}{0.91/\sqrt{10}} = \frac{2.40}{0.288} \approx 8.33$$

Decisão

$t_{\text{crítico}}(gl = 9, \alpha = 0.05) = 1.833$. Como $8.33 \gg 1.833$ e $p < 0.001$ (computado) $\rightarrow$ **rejeitamos H_0** ($p < \alpha$).
RF é estatisticamente superior ao SVM. $\Delta = 2.4\%$, logo avalie relevância prática no domínio.

Exemplo 2 — MLP vs Reg. Log.: Baixo Poder com $n = 5$

Cenário

MLP vs Regressão Logística, 5 folds, diagnóstico médico.

 $H_0 : \mu_d = 0$ vs $H_1 : \mu_d \neq 0$ (bilateral, $\alpha = 0.05$)

Fold	MLP	Reg. Log.	d_i
1	85.0	80.0	+5.0
2	90.0	85.0	+5.0
3	78.0	80.0	-2.0
4	92.0	87.0	+5.0
5	88.0	85.0	+3.0
$\bar{d}$			3.20
s_d			2.77

$$t = \frac{3.20}{2.77/\sqrt{5}} \approx 2.58$$

Resultado

 $t_{\text{crit}}(gl = 4, \alpha = 0.025) = 2.776$.2.58 < 2.776: **não rejeitamos** H_0 ($p \approx 0.06$).

Lição: Poder do Teste

Com apenas $n = 5$ folds, o teste tem **poder reduzido**. O resultado é *borderline*, repetir com 10+ folds pode revelar diferença significativa.

Exemplo 2 — MLP vs Reg. Log.: Baixo Poder com $n = 5$

Cenário

MLP vs Regressão Logística, 5 folds, diagnóstico médico.

$H_0 : \mu_d = 0$ vs $H_1 : \mu_d \neq 0$ (bilateral, $\alpha = 0.05$)

Fold	MLP	Reg. Log.	d_i
1	85.0	80.0	+5.0
2	90.0	85.0	+5.0
3	78.0	80.0	-2.0
4	92.0	87.0	+5.0
5	88.0	85.0	+3.0
$\bar{d}$			3.20
s_d			2.77

$$t = \frac{3.20}{2.77/\sqrt{5}} \approx 2.58$$

Resultado

$t_{\text{crit}}(gl = 4, \alpha = 0.025) = 2.776$.

$2.58 < 2.776$: não rejeitamos H_0 ($p \approx 0.06$).

Lição: Poder do Teste

Com apenas $n = 5$ folds, o teste tem **poder reduzido**. O resultado é *borderline*, repetir com 10+ folds pode revelar diferença significativa.

Exemplo 2 — MLP vs Reg. Log.: Baixo Poder com $n = 5$

Cenário

MLP vs Regressão Logística, 5 folds, diagnóstico médico.

 $H_0 : \mu_d = 0$ vs $H_1 : \mu_d \neq 0$ (bilateral, $\alpha = 0.05$)

$$t = \frac{3.20}{2.77/\sqrt{5}} \approx 2.58$$

Fold	MLP	Reg. Log.	d_i
1	85.0	80.0	+5.0
2	90.0	85.0	+5.0
3	78.0	80.0	-2.0
4	92.0	87.0	+5.0
5	88.0	85.0	+3.0
$\bar{d}$			3.20
s_d			2.77

Resultado

 $t_{\text{crit}}(gl = 4, \alpha = 0.025) = 2.776$.2.58 < 2.776: não rejeitamos H_0 ($p \approx 0.06$).

Lição: Poder do Teste

Com apenas $n = 5$ folds, o teste tem **poder reduzido**. O resultado é *borderline*, repetir com 10+ folds pode revelar diferença significativa.

Exemplo 2 — MLP vs Reg. Log.: Baixo Poder com $n = 5$

Cenário

MLP vs Regressão Logística, 5 folds, diagnóstico médico.

$H_0 : \mu_d = 0$ vs $H_1 : \mu_d \neq 0$ (bilateral, $\alpha = 0.05$)

Fold	MLP	Reg. Log.	d_i
1	85.0	80.0	+5.0
2	90.0	85.0	+5.0
3	78.0	80.0	-2.0
4	92.0	87.0	+5.0
5	88.0	85.0	+3.0
$\bar{d}$			3.20
s_d			2.77

$$t = \frac{3.20}{2.77/\sqrt{5}} \approx 2.58$$

Resultado

$t_{\text{crit}}(gl = 4, \alpha = 0.025) = 2.776$.

$2.58 < 2.776$: **não rejeitamos** H_0 ($p \approx 0.06$).

Lição: Poder do Teste

Com apenas $n = 5$ folds, o teste tem **poder reduzido**. O resultado é *borderline*, repetir com 10+ folds pode revelar diferença significativa.

Exemplo 2 — MLP vs Reg. Log.: Baixo Poder com $n = 5$

Cenário

MLP vs Regressão Logística, 5 folds, diagnóstico médico.

 $H_0 : \mu_d = 0$ vs $H_1 : \mu_d \neq 0$ (bilateral, $\alpha = 0.05$)

Fold	MLP	Reg. Log.	d_i
1	85.0	80.0	+5.0
2	90.0	85.0	+5.0
3	78.0	80.0	-2.0
4	92.0	87.0	+5.0
5	88.0	85.0	+3.0
$\bar{d}$			3.20
s_d			2.77

$$t = \frac{3.20}{2.77/\sqrt{5}} \approx 2.58$$

Resultado

 $t_{\text{crit}}(gl = 4, \alpha = 0.025) = 2.776$.2.58 < 2.776: **não rejeitamos** H_0 ($p \approx 0.06$).

Lição: Poder do Teste

Com apenas $n = 5$ folds, o teste tem **poder reduzido**. O resultado é *borderline*, repetir com 10+ folds pode revelar diferença significativa.

Exemplo 3 — ANOVA: KNN vs DT vs Naive Bayes

Cenário e Hipóteses

Três algoritmos, 5 folds. Existe diferença entre eles?

$H_0 : \mu_{\text{KNN}} = \mu_{\text{DT}} = \mu_{\text{NB}}$ H_1 : ao menos uma média difere.

Fold	KNN	Decision Tree	Naive Bayes
1	82.0	78.0	75.0
2	84.0	80.0	76.0
3	81.0	79.0	74.0
4	85.0	82.0	77.0
5	83.0	80.0	73.0
Média $\bar{x}_j$	83.0	79.8	75.0

Média global: $\bar{x} = (83.0 + 79.8 + 75.0)/3 = 79.27$

Exemplo 3 — ANOVA: KNN vs DT vs Naive Bayes

Cenário e Hipóteses

Três algoritmos, 5 folds. Existe diferença entre eles?

$H_0 : \mu_{\text{KNN}} = \mu_{\text{DT}} = \mu_{\text{NB}}$ H_1 : ao menos uma média difere.

Fold	KNN	Decision Tree	Naive Bayes
1	82.0	78.0	75.0
2	84.0	80.0	76.0
3	81.0	79.0	74.0
4	85.0	82.0	77.0
5	83.0	80.0	73.0
Média $\bar{x}_j$	83.0	79.8	75.0

Média global: $\bar{x} = (83.0 + 79.8 + 75.0)/3 = 79.27$

Exemplo 3 — ANOVA: KNN vs DT vs Naive Bayes

Cenário e Hipóteses

Três algoritmos, 5 folds. Existe diferença entre eles?

$H_0 : \mu_{\text{KNN}} = \mu_{\text{DT}} = \mu_{\text{NB}}$ H_1 : ao menos uma média difere.

Fold	KNN	Decision Tree	Naive Bayes
1	82.0	78.0	75.0
2	84.0	80.0	76.0
3	81.0	79.0	74.0
4	85.0	82.0	77.0
5	83.0	80.0	73.0
Média $\bar{x}_j$	83.0	79.8	75.0

Média global: $\bar{x} = (83.0 + 79.8 + 75.0)/3 = 79.27$

Exemplo 3 — ANOVA: Cálculo da Estatística F

$$SS_{\text{entre}} = n \sum_j (\bar{x}_j - \bar{x})^2 = 5[(83-79.27)^2 + (79.8-79.27)^2 + (75-79.27)^2] = 162.1$$

$$SS_{\text{dentro}} = \sum_j \sum_i (x_{ij} - \bar{x}_j)^2 = \underbrace{10}_{\text{KNN}} + \underbrace{8.8}_{\text{DT}} + \underbrace{10}_{\text{NB}} = 28.8$$

Fonte	SS	gl	MS	F
Entre grupos	162.1	2	81.05	33.77
Dentro grupos	28.8	12	2.40	
Total	190.9	14		

Decisão e Post-hoc

$F_{\text{crit}}(2, 12) = 3.89$. Como $F = 33.77 \gg 3.89$: **rejeitamos H_0** ($p < 0.001$).

ANOVA indica diferença, mas **não diz qual par difere**. Use **Tukey HSD** ou **Bonferroni**.

KNN (83%) supera NB (75%) por 8 p.p. Diferença estatística e prática.

Exemplo 3 — ANOVA: Cálculo da Estatística F

$$SS_{\text{entre}} = n \sum_j (\bar{x}_j - \bar{x})^2 = 5 [(83 - 79.27)^2 + (79.8 - 79.27)^2 + (75 - 79.27)^2] = 162.1$$

$$SS_{\text{dentro}} = \sum_j \sum_i (x_{ij} - \bar{x}_j)^2 = \underbrace{10}_{\text{KNN}} + \underbrace{8.8}_{\text{DT}} + \underbrace{10}_{\text{NB}} = 28.8$$

Fonte	SS	gl	MS	F
Entre grupos	162.1	2	81.05	33.77
Dentro grupos	28.8	12	2.40	
Total	190.9	14		

Decisão e Post-hoc

$F_{\text{crit}}(2, 12) = 3.89$. Como $F = 33.77 \gg 3.89$: **rejeitamos H_0** ($p < 0.001$).

ANOVA indica diferença, mas **não diz qual par difere**. Use **Tukey HSD** ou **Bonferroni**.

KNN (83%) supera NB (75%) por 8 p.p. Diferença estatística e prática.

Exemplo 3 — ANOVA: Cálculo da Estatística F

$$SS_{\text{entre}} = n \sum_j (\bar{x}_j - \bar{x})^2 = 5[(83-79.27)^2 + (79.8-79.27)^2 + (75-79.27)^2] = 162.1$$

$$SS_{\text{dentro}} = \sum_j \sum_i (x_{ij} - \bar{x}_j)^2 = \underbrace{10}_{\text{KNN}} + \underbrace{8.8}_{\text{DT}} + \underbrace{10}_{\text{NB}} = 28.8$$

Fonte	SS	gl	MS	F
Entre grupos	162.1	2	81.05	33.77
Dentro grupos	28.8	12	2.40	
Total	190.9	14		

Decisão e Post-hoc

$F_{\text{crit}}(2, 12) = 3.89$. Como $F = 33.77 \gg 3.89$: **rejeitamos H_0** ($p < 0.001$).

ANOVA indica diferença, mas **não diz qual par difere**. Use **Tukey HSD** ou **Bonferroni**.

KNN (83%) supera NB (75%) por 8 p.p. Diferença estatística e prática.

Exemplo 3 — ANOVA: Cálculo da Estatística F

$$SS_{\text{entre}} = n \sum_j (\bar{x}_j - \bar{x})^2 = 5[(83-79.27)^2 + (79.8-79.27)^2 + (75-79.27)^2] = 162.1$$

$$SS_{\text{dentro}} = \sum_j \sum_i (x_{ij} - \bar{x}_j)^2 = \underbrace{10}_{\text{KNN}} + \underbrace{8.8}_{\text{DT}} + \underbrace{10}_{\text{NB}} = 28.8$$

Fonte	SS	gl	MS	F
Entre grupos	162.1	2	81.05	33.77
Dentro grupos	28.8	12	2.40	
Total	190.9	14		

Decisão e Post-hoc

$F_{\text{crit}}(2, 12) = 3.89$. Como $F = 33.77 \gg 3.89$: **rejeitamos H_0** ($p < 0.001$).

ANOVA indica diferença, mas **não diz qual par** difere. Use **Tukey HSD** ou **Bonferroni**.

KNN (83%) supera NB (75%) por 8 p.p. Diferença estatística e prática.

Correlação de Pearson: Definição

Fórmula

$$r = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2 \cdot \sum_{i=1}^n (y_i - \bar{y})^2}} \in [-1, 1]$$

Escala de Interpretação

$ r $	Interpretação
0.90–1.00	Muito forte
0.70–0.89	Forte
0.50–0.69	Moderada
0.30–0.49	Fraca
< 0.30	Desprezível

Limitações

- ▶ Mede apenas relação **linear**
- ▶ Sensível a outliers
- ▶ **Correlação $\neq$ Causalidade**
- ▶ Para relações não-lineares: use Spearman ou Informação Mútua

Correlação de Pearson: Definição

Fórmula

$$r = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2 \cdot \sum_{i=1}^n (y_i - \bar{y})^2}} \in [-1, 1]$$

Escala de Interpretação

$ r $	Interpretação
0.90–1.00	Muito forte
0.70–0.89	Forte
0.50–0.69	Moderada
0.30–0.49	Fraca
< 0.30	Desprezível

Limitações

- ▶ Mede apenas relação **linear**
- ▶ Sensível a outliers
- ▶ **Correlação $\neq$ Causalidade**
- ▶ Para relações não-lineares: use Spearman ou Informação Mútua

Correlação de Pearson: Definição

Fórmula

$$r = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2 \cdot \sum_{i=1}^n (y_i - \bar{y})^2}} \in [-1, 1]$$

Escala de Interpretação

$ r $	Interpretação
0.90–1.00	Muito forte
0.70–0.89	Forte
0.50–0.69	Moderada
0.30–0.49	Fraca
< 0.30	Desprezível

Limitações

- ▶ Mede apenas relação **linear**
- ▶ Sensível a outliers
- ▶ **Correlação $\neq$ Causalidade**
- ▶ Para relações não-lineares: use Spearman ou Informação Mútua

Exemplo — Pearson: Horas de Estudo vs Nota Final

Cenário

8 alunos. Existe correlação linear entre horas de estudo semanal e nota final (0–10)?

Aluno	x_i (h)	y_i (nota)	$(x_i - \bar{x})$	$(y_i - \bar{y})$	$(x_i - \bar{x})(y_i - \bar{y})$
1	2.0	4.5	-3.25	-2.88	9.36
2	3.0	5.0	-2.25	-2.38	5.36
3	4.0	5.5	-1.25	-1.88	2.35
4	5.0	6.0	-0.25	-1.38	0.35
5	6.0	7.5	+0.75	+0.12	0.09
6	7.0	8.0	+1.75	+0.62	1.09
7	9.0	9.0	+3.75	+1.62	6.08
8	10.0	9.5	+4.75	+2.12	10.07
Média	$\bar{x} = 5.25$	$\bar{y} = 7.38$			$\sum = 34.75$

Exemplo — Pearson: Horas de Estudo vs Nota Final

Cenário

8 alunos. Existe correlação linear entre horas de estudo semanal e nota final (0–10)?

Aluno	x_i (h)	y_i (nota)	$(x_i - \bar{x})$	$(y_i - \bar{y})$	$(x_i - \bar{x})(y_i - \bar{y})$
1	2.0	4.5	-3.25	-2.88	9.36
2	3.0	5.0	-2.25	-2.38	5.36
3	4.0	5.5	-1.25	-1.88	2.35
4	5.0	6.0	-0.25	-1.38	0.35
5	6.0	7.5	+0.75	+0.12	0.09
6	7.0	8.0	+1.75	+0.62	1.09
7	9.0	9.0	+3.75	+1.62	6.08
8	10.0	9.5	+4.75	+2.12	10.07
Média	$\bar{x} = 5.25$	$\bar{y} = 7.38$			$\sum = 34.75$

Pearson — Cálculo Passo a Passo

$$\sum (x_i - \bar{x})^2 = 10.56 + 5.06 + 1.56 + 0.06 + 0.56 + 3.06 + 14.06 + 22.56 = 57.50$$

$$\sum (y_i - \bar{y})^2 = 8.29 + 5.66 + 3.53 + 1.90 + 0.01 + 0.38 + 2.62 + 4.49 = 26.88$$

$$r = \frac{34.75}{\sqrt{57.50 \times 26.88}} = \frac{34.75}{39.31} \approx \mathbf{0.884} \quad (\text{correlação forte positiva})$$

Significância estatística

$$t = r \sqrt{\frac{n-2}{1-r^2}} = 0.884 \times \sqrt{\frac{6}{1-0.781}} \approx 4.62$$

$t_{\text{crit}}(gl = 6, \alpha = 0.05) = 2.447$. Como $4.62 > 2.447$: **correlação estatisticamente significativa** ($p \approx 0.004$).

Pearson — Cálculo Passo a Passo

$$\sum (x_i - \bar{x})^2 = 10.56 + 5.06 + 1.56 + 0.06 + 0.56 + 3.06 + 14.06 + 22.56 = 57.50$$

$$\sum (y_i - \bar{y})^2 = 8.29 + 5.66 + 3.53 + 1.90 + 0.01 + 0.38 + 2.62 + 4.49 = 26.88$$

$$r = \frac{34.75}{\sqrt{57.50 \times 26.88}} = \frac{34.75}{39.31} \approx \mathbf{0.884} \quad (\text{correlação forte positiva})$$

Significância estatística

$$t = r \sqrt{\frac{n-2}{1-r^2}} = 0.884 \times \sqrt{\frac{6}{1-0.781}} \approx 4.62$$

$t_{\text{crit}}(gl = 6, \alpha = 0.05) = 2.447$. Como $4.62 > 2.447$: **correlação estatisticamente significativa** ($p \approx 0.004$).

Pearson — Cálculo Passo a Passo

$$\sum (x_i - \bar{x})^2 = 10.56 + 5.06 + 1.56 + 0.06 + 0.56 + 3.06 + 14.06 + 22.56 = 57.50$$

$$\sum (y_i - \bar{y})^2 = 8.29 + 5.66 + 3.53 + 1.90 + 0.01 + 0.38 + 2.62 + 4.49 = 26.88$$

$$r = \frac{34.75}{\sqrt{57.50 \times 26.88}} = \frac{34.75}{39.31} \approx \mathbf{0.884} \quad (\text{correlação forte positiva})$$

Significância estatística

$$t = r \sqrt{\frac{n-2}{1-r^2}} = 0.884 \times \sqrt{\frac{6}{1-0.781}} \approx 4.62$$

$t_{\text{crit}}(gl = 6, \alpha = 0.05) = 2.447$. Como $4.62 > 2.447$: **correlação estatisticamente significativa** ($p \approx 0.004$).

Pearson — Cálculo Passo a Passo

$$\sum (x_i - \bar{x})^2 = 10.56 + 5.06 + 1.56 + 0.06 + 0.56 + 3.06 + 14.06 + 22.56 = 57.50$$

$$\sum (y_i - \bar{y})^2 = 8.29 + 5.66 + 3.53 + 1.90 + 0.01 + 0.38 + 2.62 + 4.49 = 26.88$$


$$r = \frac{34.75}{\sqrt{57.50 \times 26.88}} = \frac{34.75}{39.31} \approx \mathbf{0.884} \quad (\text{correlação forte positiva})$$

Significância estatística

$$t = r \sqrt{\frac{n-2}{1-r^2}} = 0.884 \times \sqrt{\frac{6}{1-0.781}} \approx 4.62$$

$t_{\text{crit}}(gl = 6, \alpha = 0.05) = 2.447$. Como $4.62 > 2.447$: **correlação estatisticamente significativa** ($p \approx 0.004$).

Pearson — Visualização e Interpretação



Interpretação

- ▶ $r = 0.884 \Rightarrow$ correlação forte positiva
- ▶ Quanto mais horas de estudo, maior tende a ser a nota
- ▶ Correlação é significativa ($p = 0.004$)


Atenção

Correlação $\neq$ Causalidade.

Outro fator (dedicação geral) pode explicar ambas as variáveis.

Pearson não detecta relações curvilíneas.

Pearson — Visualização e Interpretação



Interpretação

- ▶ $r = 0.884 \Rightarrow$ **correlação forte** positiva
- ▶ Quanto mais horas de estudo, maior tende a ser a nota
- ▶ Correlação é significativa ($p = 0.004$)


Atenção

Correlação $\neq$ Causalidade.

Outro fator (dedicação geral) pode explicar ambas as variáveis.

Pearson não detecta relações curvilíneas.

Pearson — Visualização e Interpretação



Interpretação

- ▶ $r = 0.884 \Rightarrow$ **correlação forte** positiva
- ▶ Quanto mais horas de estudo, maior tende a ser a nota
- ▶ Correlação é significativa ($p = 0.004$)

Atenção

Correlação $\neq$ Causalidade.

Outro fator (dedicação geral) pode explicar ambas as variáveis.

Pearson não detecta relações curvilíneas.

Tabela de Interpretação Prática

r	Interpretação	Exemplo	Uso
0.90–1.00	Muito forte positiva	Altura vs envergadura	Previsão direta
0.70–0.89	Forte positiva	Horas estudo vs nota	Seleção de features
0.50–0.69	Moderada positiva	Renda vs consumo	Análise exploratória
0.30–0.49	Fraca positiva	Temperatura vs vendas	Usar com cuidado
0.00–0.29	Desprezível	Nº letras vs nota	Descartar
< 0	Negativa	Horas TV vs nota	Mesma escala

Regras Práticas para Seleção de Features

- ▶ Remova features com $|r| < 0.10$ em relação ao alvo (sinal fraco)
- ▶ Features com $|r| > 0.95$ entre si são redundantes, mantenha apenas uma
- ▶ Pearson é pré-filtro rápido; confirme com Informação Mútua para relações não-lineares

Tabela de Interpretação Prática

r	Interpretação	Exemplo	Uso
0.90–1.00	Muito forte positiva	Altura vs envergadura	Previsão direta
0.70–0.89	Forte positiva	Horas estudo vs nota	Seleção de features
0.50–0.69	Moderada positiva	Renda vs consumo	Análise exploratória
0.30–0.49	Fraca positiva	Temperatura vs vendas	Usar com cuidado
0.00–0.29	Desprezível	Nº letras vs nota	Descartar
< 0	Negativa	Horas TV vs nota	Mesma escala

Regras Práticas para Seleção de Features

- ▶ Remova features com $|r| < 0.10$ em relação ao alvo (sinal fraco)
- ▶ Features com $|r| > 0.95$ entre si são redundantes, mantenha apenas uma
- ▶ Pearson é pré-filtro rápido; confirme com Informação Mútua para relações não-lineares

Spearman, Kendall e Informação Mútua

Correlação de Spearman (ρ)

Aplica Pearson sobre os **postos** (*ranks*) dos dados.

- ▶ Detecta relações **monotônicas** (não só lineares)
- ▶ Robusta a outliers
- ▶ Indicada para dados ordinais ou distribuição assimétrica

Tau de Kendall (τ)

Baseado em pares **concordantes/discordantes**.

- ▶ Mais robusto que Spearman para n pequeno
- ▶ Interpretação probabilística direta

Informação Mútua $I(X; Y)$

$$I(X; Y) = \sum_{x,y} p(x, y) \log \frac{p(x, y)}{p(x) p(y)}$$

- ▶ Mede dependência **geral** (não apenas linear)
- ▶ $I(X; Y) = 0$ somente se X e Y são independentes
- ▶ Usado em seleção de features: **MRMR**
- ▶ Captura relações complexas que Pearson ignora

Prefira Spearman ou IM quando há suspeita de relação não-linear ou presença de outliers.

Spearman, Kendall e Informação Mútua

Correlação de Spearman (ρ)

Aplica Pearson sobre os **postos** (*ranks*) dos dados.

- ▶ Detecta relações **monotônicas** (não só lineares)
- ▶ Robusta a outliers
- ▶ Indicada para dados ordinais ou distribuição assimétrica

Tau de Kendall (τ)

Baseado em pares **concordantes/discordantes**.

- ▶ Mais robusto que Spearman para n pequeno
- ▶ Interpretação probabilística direta

Informação Mútua $I(X; Y)$

$$I(X; Y) = \sum_{x,y} p(x, y) \log \frac{p(x, y)}{p(x) p(y)}$$

- ▶ Mede dependência **geral** (não apenas linear)
- ▶ $I(X; Y) = 0$ somente se X e Y são independentes
- ▶ Usado em seleção de features: **MRMR**
- ▶ Captura relações complexas que Pearson ignora

Prefira Spearman ou IM quando há suspeita de relação não-linear ou presença de outliers.

Spearman, Kendall e Informação Mútua

Correlação de Spearman (ρ)

Aplica Pearson sobre os **postos** (*ranks*) dos dados.

- ▶ Detecta relações **monotônicas** (não só lineares)
- ▶ Robusta a outliers
- ▶ Indicada para dados ordinais ou distribuição assimétrica

Tau de Kendall (τ)

Baseado em pares **concordantes/discordantes**.

- ▶ Mais robusto que Spearman para n pequeno
- ▶ Interpretação probabilística direta

Informação Mútua $I(X; Y)$

$$I(X; Y) = \sum_{x,y} p(x, y) \log \frac{p(x, y)}{p(x) p(y)}$$

- ▶ Mede dependência **geral** (não apenas linear)
- ▶ $I(X; Y) = 0$ somente se X e Y são independentes
- ▶ Usado em seleção de features: **MRMR**
- ▶ Captura relações complexas que Pearson ignora

Prefira Spearman ou IM quando há suspeita de relação não-linear ou presença de outliers.

Spearman, Kendall e Informação Mútua

Correlação de Spearman (ρ)

Aplica Pearson sobre os **postos** (*ranks*) dos dados.

- ▶ Detecta relações **monotônicas** (não só lineares)
- ▶ Robusta a outliers
- ▶ Indicada para dados ordinais ou distribuição assimétrica

Tau de Kendall (τ)

Baseado em pares **concordantes/discordantes**.

- ▶ Mais robusto que Spearman para n pequeno
- ▶ Interpretação probabilística direta

Informação Mútua $I(X; Y)$

$$I(X; Y) = \sum_{x,y} p(x, y) \log \frac{p(x, y)}{p(x) p(y)}$$

- ▶ Mede dependência **geral** (não apenas linear)
- ▶ $I(X; Y) = 0$ somente se X e Y são independentes
- ▶ Usado em seleção de features: **MRMR**
- ▶ Captura relações complexas que Pearson ignora

Prefira Spearman ou IM quando há suspeita de relação não-linear ou presença de outliers.

Distribuições Relevantes em Mineração de Dados

Distribuição	Suporte	Uso em DM
Normal	$\mathbb{R}$	Ruído, GMM, testes paramétricos
Bernoulli	$\{0, 1\}$	Classificação binária, Naive Bayes
Binomial	$\{0, \dots, n\}$	Contagem de acertos, limiar de confiança
Poisson	$\mathbb{N}_0$	Contagem de eventos raros, anomalias
Exponencial	$[0, +\infty)$	Tempo entre eventos, outliers
t-Student	$\mathbb{R}$	Testes estatísticos com amostras pequenas
Qui-Quadrado	$[0, +\infty)$	Teste de independência (tabelas de contingência)

Antes de Aplicar Testes Paramétricos

Verifique normalidade com **Shapiro-Wilk** ou **Q-Q plot**. Se $n > 30$, o Teorema Central do Limite garante aproximação normal, mesmo sem normalidade das populações.

Distribuições Relevantes em Mineração de Dados

Distribuição	Suporte	Uso em DM
Normal	$\mathbb{R}$	Ruído, GMM, testes paramétricos
Bernoulli	$\{0, 1\}$	Classificação binária, Naive Bayes
Binomial	$\{0, \dots, n\}$	Contagem de acertos, limiar de confiança
Poisson	$\mathbb{N}_0$	Contagem de eventos raros, anomalias
Exponencial	$[0, +\infty)$	Tempo entre eventos, outliers
t-Student	$\mathbb{R}$	Testes estatísticos com amostras pequenas
Qui-Quadrado	$[0, +\infty)$	Teste de independência (tabelas de contingência)

Antes de Aplicar Testes Paramétricos

Verifique normalidade com **Shapiro-Wilk** ou **Q-Q plot**. Se $n > 30$, o Teorema Central do Limite garante aproximação normal, mesmo sem normalidade das populações.


O que é Clustering?

Definição

Tarefa de **aprendizado não-supervisionado** que organiza exemplos similares em grupos (clusters) sem o uso de rótulos pré-definidos.

Aplicações

- ▶ ➔ **Segmentação de clientes:** grupos de comportamento de compra
- ▶ ➔ **Deteção de anomalias:** pontos sem cluster são outliers
- ▶ ➔ **Compressão de imagens:** quantização de cores com K-Means
- ▶ ➔ **Bioinformática:** agrupamento de genes por expressão
- ▶ ➔ **Modelagem de tópicos:** agrupamento de documentos



Avalie resultados com métricas e visualização (PCA, t-SNE, UMAP).

K-Means: Conceito e Objetivo

Objetivo: Minimizar Inércia

$$J = \sum_{k=1}^K \sum_{\mathbf{x}_i \in C_k} \|\mathbf{x}_i - \boldsymbol{\mu}_k\|^2$$

onde $\boldsymbol{\mu}_k$ é o centróide do cluster k .

Resumo do Algoritmo (Lloyd, 1982)

1. Inicializar K centróides (aleatório ou K-Means++)
2. **Atribuição:** cada ponto vai ao centróide mais próximo
3. **Atualização:** mover centróide para a média do cluster
4. Repetir 2–3 até convergência

Propriedades

- ▶ **Complexidade:** $O(n \cdot K \cdot d \cdot i)$, onde d é a dimensão e i o número de iterações
 - ▶ **Convergência:** garantida (mas pode ser ótimo local)
 - ▶ **Limitações:** assume clusters **esféricos e de tamanho similar**; sensível a outliers e inicialização
 - ▶ **Distância:** euclidiana por padrão
- ➔ Consulte Material Didático e Colab para implementação em Python

K-Means: Passo a Passo com Exemplo

Exemplo: $K = 2$, ponto $\mathbf{x} = (5, 3)$

Centróides iniciais: $C_1 = (2, 4)$ e $C_2 = (6, 1)$

Passo 3: Atribuição

$$d(\mathbf{x}, C_1) = \sqrt{9 + 1} \approx 3.16$$


$$d(\mathbf{x}, C_2) = \sqrt{1 + 4} \approx 2.24$$

$\Rightarrow$ atribuir $(5, 3)$ ao cluster C_2


Passo 4: Recalcular centróide

Pontos em C_1 : $(3, 4), (4, 1), (2, 3), (2, 6), (3, 3)$

$$\mu_1 = \frac{1}{5}(14, 17) = (2.8, 3.4)$$



K-Means: Visualização das Etapas



Cada iteração atualiza centróides até que os clusters se estabilizem.

→ Ver algoritmo completo no Material Didático Módulo 6.

Escolha de K: Método do Cotovelo

Ideia


Plota a **inércia** (WCSS) para $K = 1, 2, \dots$. O ponto onde a redução desacelera, formando um “cotovelo”, indica o K ótimo.

$$WCSS(K) = \sum_{k=1}^K \sum_{\mathbf{x}_i \in C_k} \|\mathbf{x}_i - \boldsymbol{\mu}_k\|^2$$

Limitação

O cotovelo pode ser ambíguo em dados sobrepostos. Combine sempre com a **Análise de Silhouette**.

Método do Cotovelo



De $K = 2$ para $K = 3$: queda de $\sim 60\%$ na inércia. De $K = 3$ em diante: ganho marginal pequeno.

Escolha de K: Análise de Silhouette

Coeficiente de Silhouette

Para cada ponto x_i no cluster C_k :


$a(i)$ = distância média intra-cluster

$b(i)$ = distância média ao vizinho mais próximo

$$s(i) = \frac{b(i) - a(i)}{\max\{a(i), b(i)\}} \in [-1, 1]$$

Interpretação

- ▶ $s \approx +1$: ponto bem dentro do cluster
- ▶ $s \approx 0$: ponto na fronteira
- ▶ $s \approx -1$: ponto no cluster errado
- ▶ $\bar{s} > 0.5$: clustering de qualidade



Use **Elbow** e **Silhouette** juntos para maior confiabilidade na escolha de K .

Variantes do K-Means

K-Means++

Inicialização inteligente: cada centróide é escolhido com probabilidade proporcional à distância ao centróide mais próximo já escolhido.

- ▶ Evita inicializações ruins
- ▶ Garante aproximação $O(\log K)$ do ótimo
- ▶ **Padrão** no scikit-learn

K-Medoids (PAM)

Usa exemplos reais como centróides (medóides).

- ▶ Mais robusto a outliers que K-Means
- ▶ Interpretável: centróide é um ponto real
- ▶ Mais custoso computacionalmente

Mini-Batch K-Means

Atualiza centróides com mini-lotes aleatórios a cada iteração.

- ▶ Escala para datasets de **milhões** de exemplos
- ▶ Resultado ligeiramente pior que K-Means padrão
- ▶ Ideal para dados em stream

Quando K-Means falha

Clusters não esféricos, de tamanhos muito diferentes, ou com muitos outliers. Nesses casos, prefira DBSCAN, GMM ou Spectral Clustering.

Clustering Hierárquico

Conceito


Cria uma **hierarquia** de agrupamentos em um **dendrograma**, sem necessitar especificar K antecipadamente.

Abordagens

- ▶ **Agglomerativo (bottom-up):** começa com N clusters e mescla os dois mais próximos iterativamente
- ▶ **Divisivo (top-down):** começa com um cluster e divide recursivamente

Critérios de Ligação

- ▶ **Single:** distância mínima, sensível a outliers
- ▶ **Complete:** distância máxima, clusters compactos
- ▶ **Average (UPGMA):** equilíbrio entre os dois
- ▶ **Ward:** minimiza variância intra-cluster (+popular)



DBSCAN: Clustering Baseado em Densidade

Conceito


Encontra clusters de **forma arbitrária** e detecta **ruído/outliers** automaticamente. Parâmetros: ϵ (raio) e MinPts (vizinhos mínimos).

Tipos de Pontos

- ▶ **Núcleo:** $\geq$ MinPts vizinhos em raio ϵ (distância $\leq \epsilon$ a pelo menos MinPts outros pontos)
- ▶ **Fronteira:** distância $\leq \epsilon$ de um ponto núcleo, mas não é núcleo (tem $<$ MinPts vizinhos)
- ▶ **Ruído:** não é núcleo nem fronteira (isolado)

Vantagem sobre K-Means

Não precisa especificar K . Detecta clusters de qualquer forma geométrica e identifica outliers



Clusters: azul e laranja — ruído: vermelho

Estimar ϵ pelo gráfico da k -NN distance (joelho da curva).

HDBSCAN: Extensão Hierárquica do DBSCAN

Limitação do DBSCAN

DBSCAN usa um único ε global. Se os clusters têm **densidades diferentes**, um único limiar não funciona bem.


HDBSCAN (McInnes et al., 2017)

Varia o limiar de densidade automaticamente ao longo de uma hierarquia. Extrai os clusters mais **persistentes**.

- ▶ Apenas `min_cluster_size` é crítico
- ▶ Detecta clusters com densidades variáveis
- ▶ Retorna **probabilidade** de pertencimento
- ▶ Padrão no scikit-learn ≥ 1.3

Pipeline UMAP + HDBSCAN

Abordagem moderna para dados de alta dimensão:



→ Muito eficaz para NLP (embeddings), genômica (scRNA-seq) e BERTopic

Modelos de Mistura Gaussiana (GMM)

Modelo

Os dados são gerados por uma **mistura** de K Gaussianas:

$$p(\mathbf{x}) = \sum_{k=1}^K \pi_k \mathcal{N}(\mathbf{x} \mid \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)$$

π_k : peso da componente k ($\sum_k \pi_k = 1$)

Treinamento: Algoritmo EM

1. **E-step:** calcular responsabilidades r_{ik} (probabilidade de $\mathbf{x}_i$ pertencer ao cluster k)
2. **M-step:** atualizar π_k , $\boldsymbol{\mu}_k$ e $\boldsymbol{\Sigma}_k$
3. Repetir até convergência da log-verossimilhança

GMM vs K-Means

Aspecto	K-Means	GMM
Atribuição	Dura	Suave
Forma cluster	Esférica	Elipsoidal
Pertencimento	0/1	Probabilidade
Seleção de K	Elbow/Sil	BIC/AIC
Parâmetros	Poucos	Mais

Seleção de K no GMM

Minimize o **BIC** (Bayesian Information Criterion):

$$\text{BIC} = -2 \log \hat{L} + p \log N$$

Avaliação de Agrupamentos

Métricas Internas (sem rótulos)

- ▶ **Silhouette Score** $\bar{s}$: coesão interna vs separação externa. $\bar{s} \in [-1, 1]$, maximize.
- ▶ **Davies-Bouldin (DB)**:
$$DB = \frac{1}{K} \sum_k \max_{k' \neq k} \frac{s_k + s_{k'}}{\|c_k - c_{k'}\|}$$

Minimize. Penaliza clusters compactos mas muito próximos.
- ▶ **Calinski-Harabasz**: razão dispersão inter/intra-cluster. Maximize.

Métricas Externas (com rótulos verdadeiros)

- ▶ **ARI (Adjusted Rand Index)**: $\in [-1, 1]$; 1 = perfeito; 0 = aleatório. Ajustado para chance.
- ▶ **NMI (Normalized Mutual Information)**:
$$NMI(U, V) = \frac{2 \cdot I(U; V)}{H(U) + H(V)} \in [0, 1]$$
- ▶ **V-Measure**: média harmônica de *homogeneidade* e *completude*.

Boas Práticas

Nunca use apenas uma métrica. Combine métricas **internas** + **externas** (quando disponíveis) + visualização (PCA, t-SNE, UMAP).

Regras de Associação: Conceitos

O Problema

Dado um banco de transações, encontrar regras do tipo $A \Rightarrow B$ com alta frequência e confiabilidade.

Exemplo: $\{\text{leite}\} \Rightarrow \{\text{pão}\}$

Medidas de Interesse

$$\text{sup}(A \Rightarrow B) = \frac{|\{T: A \cup B \subseteq T\}|}{|\mathcal{T}|}$$

$$\text{conf}(A \Rightarrow B) = \frac{\text{sup}(A \cup B)}{\text{sup}(A)}$$

$$\text{lift}(A \Rightarrow B) = \frac{\text{conf}(A \Rightarrow B)}{\text{sup}(B)}$$

Interpretação do Lift

- ▶ **lift** > 1: correlação positiva; a regra é mais frequente que o esperado por acaso
- ▶ **lift** = 1: A e B independentes
- ▶ **lift** < 1: correlação negativa (anti-regra)

Exemplo: Cesta de Mercado

5 transações. Para $\{\text{leite}\} \Rightarrow \{\text{pão}\}$:

$$\text{sup} = 3/5 = 0.60$$

$$\text{conf} = 0.60/0.80 = 0.75$$

$$\text{lift} = 0.75/0.60 = 1.25$$

✓ Correlação positiva: comprar leite favorece comprar pão.

Algoritmo Apriori

Princípio Anti-Monótono

Se um itemset é **infrequente**, todos os seus superconjuntos também são. Isso permite **podar** o espaço de busca.

Etapas

1. Gerar itemsets frequentes de tamanho 1 (L_1)
2. Gerar candidatos de tamanho $k + 1$ a partir de L_k
3. Varrer transações e contar suporte
4. Filtrar candidatos com suporte $\geq$ minsup
5. Repetir até $L_k = \emptyset$
6. Gerar regras com confiança $\geq$ minconf

Limitações do Apriori


- ▶ Múltiplas varridas na base de dados ($O(|\mathcal{I}|)$ varridas)
- ▶ Grande número de candidatos em datasets densos
- ▶ Ineficiente para bases muito grandes

FP-Growth (Han et al., 2000)

- ▶ Apenas **2 varridas** na base de dados
- ▶ Constrói uma **FP-Tree** (árvore compacta) que compartilha prefixos
- ▶ Sem geração explícita de candidatos
- ▶ Muito mais eficiente que Apriori em datasets grandes

➔ Implemente Apriori e FP-Growth no Colab do Módulo 6

- ▶ **Ponto:** instância individual muito diferente das demais
Ex.: transação de R\$50.000 numa conta comum
- ▶ **Contextual:** instância anômala apenas em contexto específico
Ex.: 35°C em dezembro no RS
- ▶ **Coletiva:** subconjunto de instâncias anômalo em conjunto; individualmente parecem normais
Ex.: padrão de compras incomum ao longo da semana



Métodos de Detecção de Anomalias

Métodos Estatísticos

- ▶ **Z-score:** anomalia se $|z| > 3$. Assume distribuição Gaussiana.
- ▶ **Boxplot:** outlier se $> Q_3 + 1.5 \cdot \text{IQR}$ ou $< Q_1 - 1.5 \cdot \text{IQR}$
- ▶ **Grubbs Test:** teste formal para outlier único em amostra normal

LOF (Breunig et al., 2000)

Compara a **densidade local** de um ponto com a de seus vizinhos. $\text{LOF}(p) \gg 1$ indica anomalia.

- ▶ Detecta outliers locais (não depende de distribuição global)
- ▶ Sensível ao parâmetro k (número de vizinhos)

Isolation Forest (Liu et al., 2008)

Constrói árvores de isolamento aleatórias. Anomalias são isoladas em **caminhos mais curtos**.

$$s(x, n) = 2^{-E[h(x)]/c(n)}$$

- ▶ Eficiente em alta dimensão
- ▶ Não assume forma da distribuição
- ▶ Eficaz para anomalias de ponto

Autoencoder

Treina para reconstruir dados normais. **Alto erro de reconstrução** $\|x - \hat{x}\|^2$ indica anomalia.

→ Consulte Colab para comparação prática de métodos

Estado da Arte: Deep Clustering

DEC (Xie et al., 2016)

Deep Embedded Clustering: autoencoder treinado conjuntamente com objetivo de clustering. Aprende representações otimizadas para agrupamento.

SCAN (Van Gansbeke et al., 2020)

Self-supervised clustering: usa similaridade de vizinhos para treinar sem rótulos. Estado da arte em clustering de imagens.

DINO (Caron et al., 2021)

Vision Transformer (ViT) auto-supervisionado revela estrutura de clustering sem fine-tuning. Propriedade emergente dos Transformers.

Detecção de Outliers Moderna

- ▶ **PyOD** (Zhao et al., 2019): 40+ algoritmos unificados em API sklearn-compatível
- ▶ **COPOD** (Li et al., 2020): baseado em cópulas, sem hiperparâmetros, muito eficiente
- ▶ **ECOD** (Li et al., 2022): baseado em distribuição empírica cumulativa, interpretável
- ▶ **Anomalia em grafos:** GraphSAGE + Isolation Forest para fraudes em redes sociais

➔ Material Didático e Colab trazem experimentos com BERTopic e PyOD

Pipeline Moderno: BERTopic e UMAP+HDBSCAN


BERTopic (Grootendorst, 2022)

Modelagem de tópicos combinando:

1. **BERT embeddings:** representação semântica dos textos
2. **UMAP:** redução de dimensionalidade
3. **HDBSCAN:** agrupamento dos embeddings
4. **TF-IDF por cluster:** extração de palavras-chave representativas

Supera LDA em qualidade de tópicos.

Pipeline UMAP + HDBSCAN tornou-se padrão para NLP, genômica single-cell (scRNA-seq) e análise de



Referências Bibliográficas

-  MacQueen, J. *Some methods for classification and analysis of multivariate observations*. BSMSP, 1967.
-  Arthur, D.; Vassilvitskii, S. *k-means++: The advantages of careful seeding*. SODA, 2007.
-  Ester, M. et al. *A density-based algorithm for discovering clusters in large spatial databases with noise*. KDD, 1996.
-  McInnes, L. et al. *hdbscan: Hierarchical density based clustering*. JOSS, 2017.
-  Han, J.; Pei, J.; Yin, Y. *Mining frequent patterns without candidate generation*. ACM SIGMOD, 2000.
-  Liu, F. T. et al. *Isolation Forest*. ICDM, 2008.
-  Bergstra, J.; Bengio, Y. *Random Search for Hyper-Parameter Optimization*. JMLR, 2012.
-  **Material Didático Módulo 6** e Notebook Colab disponíveis no repositório da disciplina.