

Módulo 7

Aplicações de Mineração de Dados: Social CRM, Web e Análise de Sentimentos

1 Objetivos de Aprendizagem

Ao concluir este módulo, o estudante será capaz de:

- ✔ 1. Compreender e diferenciar as três vertentes da Mineração na Web: Web Content Mining, Web Structure Mining e Web Usage Mining.
- ✔ 2. Aplicar algoritmos de extração de informação, web scraping e análise de logs para obtenção de conhecimento a partir de fontes web.
- ✔ 3. Entender o conceito de Social CRM e como técnicas de mineração de dados potencializam o relacionamento com o cliente.
- ✔ 4. Implementar modelos de segmentação de clientes com RFM e K-Means, previsão de churn e cálculo de Valor do Ciclo de Vida (CLV).
- ✔ 5. Construir sistemas de recomendação baseados em filtragem colaborativa (SVD, Matrix Factorization), filtragem por conteúdo e métodos híbridos.
- ✔ 6. Distinguir e implementar abordagens léxicas, baseadas em aprendizado de máquina e baseadas em Transformers para análise de sentimentos.
- ✔ 7. Analisar redes sociais usando métricas de centralidade, detecção de comunidades e modelos de propagação de informação.
- ✔ 8. Avaliar implicações éticas, de privacidade e de conformidade com a LGPD em projetos de mineração de dados aplicados.

2 Mineração na Web (Web Mining)

A **Web Mining** consiste na aplicação de técnicas de mineração de dados ao conteúdo, à estrutura e ao uso da World Wide Web. Com mais de 5 bilhões de usuários ativos e exabytes de dados gerados diariamente, a web tornou-se a maior fonte não estruturada de informação disponível para análise.

Web Mining

Processo de descoberta e análise de informação útil a partir de dados da World Wide Web, incluindo conteúdo de páginas, estrutura de hiperlinks e padrões de navegação de usuários.

2.1 Taxonomia da Web Mining

A Web Mining divide-se em três grandes categorias, cada uma com objetivos, fontes de dados e técnicas distintas:




Tabela 1: Comparação das três vertentes da Web Mining

Tipo	Fonte de Dados	Técnicas	Resultado
Content Mining	HTML, texto, multimídia	NLP, IE, classificação	Conhecimento semântico
Structure Mining	Hiperlinks, grafos	PageRank, HITS, GNN	Autoridade, hubs
Usage Mining	Logs, cookies, sessões	Padrões sequenciais	Comportamento usuário

2.2 Web Content Mining

O **Web Content Mining** foca na extração de conhecimento a partir do conteúdo de páginas web, que pode ser texto, imagens, vídeos ou dados estruturados.

2.2.1 Extração de Informação (Information Extraction, IE)

- **NER (Named Entity Recognition):** identificação de entidades como pessoas, organizações, locais e datas em texto não estruturado.
- **Extração de Relações:** descoberta de relações semânticas entre entidades (e.g., “João trabalha em UEPA”).
- **Extração de Eventos:** identificação de eventos e seus participantes em textos jornalísticos ou redes sociais.

2.2.2 Web Scraping

Listing 1: Web scraping com BeautifulSoup

```

1 import requests
2 from bs4 import BeautifulSoup
3
4 url = "https://exemplo.com/noticias"
5 response = requests.get(url, headers={"User-Agent": "Mozilla/5.0"})
6 soup = BeautifulSoup(response.text, "html.parser")
7
8 # Extrair todos os títulos de notícias
  
```

```
9  titulos = [h.get_text(strip=True) for h in soup.find_all("h2", class_="
    titulo")]
10 paragrafos = [p.get_text() for p in soup.find_all("p")]
```

- **BeautifulSoup:** parsing simples de HTML/XML, ideal para projetos de pequena escala.
- **Scrapy:** framework completo para crawling, com suporte a pipelines, middlewares e exportação de dados.
- **Seletores:** DOM tree, XPath (e.g., `//div[@class='content']/p`) e CSS selectors.

2.2.3 Pré-processamento de Texto

O pipeline típico de pré-processamento inclui:

1. **Tokenização:** divisão do texto em tokens (palavras, subpalavras).
2. **Remoção de stopwords:** eliminação de palavras de alta frequência e baixo valor informativo (“de”, “a”, “o”).
3. **Stemming:** redução de palavras à sua forma raiz (e.g., “correndo” → “corr”).
4. **Lematização:** redução à forma canônica com base no contexto (“correndo” → “correr”).
5. **Normalização:** conversão para minúsculas, remoção de acentos, pontuação.

2.2.4 TF-IDF: Ponderação de Termos

O **TF-IDF** (Term Frequency, Inverse Document Frequency) é a medida de relevância mais utilizada em recuperação de informação:

$$\text{TF-IDF}(t, d) = \text{tf}(t, d) \times \log \frac{N}{df(t)} \quad (1)$$

onde $\text{tf}(t, d)$ é a frequência do termo t no documento d , N é o número total de documentos e $df(t)$ é o número de documentos que contêm o termo t .

2.3 Web Structure Mining

O **Web Structure Mining** analisa a estrutura de hiperlinks da web como um grafo dirigido $G = (V, E)$, onde V são páginas e E são hiperlinks.

2.3.1 PageRank (Page et al., 1999)

O algoritmo PageRank, que fundamenta o Google Search, calcula a importância de uma página com base na quantidade e qualidade dos links que apontam para ela:

$$PR(p) = \frac{1-d}{N} + d \sum_{q \in B_p} \frac{PR(q)}{|F_q|} \quad (2)$$

onde d é o fator de amortecimento (tipicamente 0,85), N é o número total de páginas, B_p é o conjunto de páginas que apontam para p e $|F_q|$ é o número de links de saída de q .

i Interpretação do PageRank

O PageRank pode ser interpretado como a probabilidade de um “surfador aleatório” visitar uma página: com probabilidade d ele segue um link aleatório da página atual, e com probabilidade $1 - d$ ele pula para uma página aleatória qualquer.

2.3.2 HITS (Kleinberg, 1999)

O algoritmo **HITS** (Hyperlink-Induced Topic Search) define dois escores complementares:

- **Authority score** $a(p)$: páginas que recebem muitos links de bons hubs.
- **Hub score** $h(p)$: páginas que apontam para muitas boas authorities.

As atualizações iterativas são:

$$a(p) \leftarrow \sum_{q:q \rightarrow p} h(q), \quad h(p) \leftarrow \sum_{q:p \rightarrow q} a(q) \quad (3)$$

2.3.3 Análise de Estrutura de Redes Sociais Online

As mesmas técnicas de Structure Mining aplicam-se a redes de seguidores (Twitter/X), conexões profissionais (LinkedIn) e grupos (Facebook), possibilitando a identificação de influenciadores, comunidades e padrões de difusão de informação.

2.4 Web Usage Mining

O **Web Usage Mining** extrai padrões de comportamento a partir de logs de servidores web, dados de sessões e interações de usuários.

2.4.1 Análise de Clickstream

O clickstream registra a sequência de páginas visitadas por um usuário em uma sessão. A reconstrução de sessões envolve:

1. Identificação de usuário (IP + User-Agent ou cookie).
2. Delimitação de sessão (timeout de 30 minutos é o padrão).
3. Filtragem de recursos estáticos (CSS, imagens, JS).

2.4.2 Mineração de Padrões Sequenciais

O algoritmo **GSP** (Srikant & Agrawal, 1996) estende o Apriori para sequências: encontra padrões de navegação frequentes como $\langle \text{Home} \rightarrow \text{Produtos} \rightarrow \text{Carrinho} \rightarrow \text{Checkout} \rangle$.

2.4.3 Web Analytics

Métricas fundamentais em plataformas como Google Analytics:

- **Taxa de rejeição (Bounce Rate):** percentual de sessões de uma única página.
- **Funil de conversão (Funnel Analysis):** identificação de etapas onde usuários abandonam o processo.
- **Tempo médio na página e páginas por sessão.**
- **Cohorte de usuários:** acompanhamento de grupos de usuários ao longo do tempo.

3 Social CRM (Customer Relationship Management)

O **Social CRM** integra dados de redes sociais, plataformas digitais e canais tradicionais para construir uma visão 360° do cliente, potencializando estratégias de relacionamento com técnicas de mineração de dados.

Social CRM

Extensão do CRM tradicional que incorpora dados não estruturados de mídias sociais (posts, comentários, avaliações, menções) para enriquecer o perfil do cliente, monitorar a reputação da marca e personalizar a comunicação em tempo real.

3.1 CRM Tradicional vs Social CRM

Tabela 2: Comparação entre CRM Tradicional e Social CRM

Dimensão	CRM Tradicional	Social CRM
Fonte de dados	Transações, chamados, vendas	Redes sociais, fóruns, reviews
Tipo de dado	Estruturado	Não estruturado / semiestruturado
Origem	Interna (ERP, callcenter)	Externa + interna integradas
Atualização	Periódica (batch)	Em tempo real (streaming)
Volume	Moderado	Massivo (Big Data)
Voz	Empresa para cliente	Cliente para empresa e entre clientes
Canal	E-mail, telefone, loja	Facebook, Twitter, WhatsApp, reviews
Objetivo	Gestão de transações	Gestão de relacionamentos

3.2 Aplicações de DM em CRM

3.2.1 Segmentação de Clientes

Modelo RFM O modelo RFM é a base clássica de segmentação em e-commerce e varejo:

- **Recency (R):** quantos dias atrás o cliente fez a última compra.
- **Frequency (F):** quantas compras realizou no período analisado.
- **Monetary (M):** quanto gastou no total no período.

Clientes são pontuados de 1 a 5 em cada dimensão, gerando segmentos como “Campeões” (R=5, F=5, M=5) e “Em risco” (R=1, F=4, M=4).

K-Means para Segmentação Após normalização das métricas RFM, aplica-se K-Means para descobrir segmentos naturais:

Listing 2: Segmentação K-Means sobre RFM

```
1 from sklearn.preprocessing import StandardScaler
2 from sklearn.cluster import KMeans
3
4 # Normalizar RFM
5 scaler = StandardScaler()
6 rfm_scaled = scaler.fit_transform(rfm_df[['Recency', 'Frequency', '
    Monetary']])
7
8 # Encontrar k ótimo com método do cotovelo
9 inertias = [KMeans(n_clusters=k, random_state=42).fit(rfm_scaled).
    inertia_
10              for k in range(2, 11)]
11
12 # Treinar modelo final
13 km = KMeans(n_clusters=4, random_state=42)
14 rfm_df['Segment'] = km.fit_predict(rfm_scaled)
```

Cada segmento recebe um **perfil (persona)** com estratégia de marketing diferenciada: clientes “Hibernando” recebem campanhas de reativação, “Leais” recebem programas de fidelidade.

3.2.2 Previsão de Churn

O **churn** (cancelamento) é modelado como um problema de classificação binária:

- **Features:** padrões de uso, tickets de suporte abertos, tempo de resposta, engajamento com e-mails, NPS, variações de frequência de compra.
- **Label:** cancelou ou não cancelou no próximo trimestre.
- **Modelos:** Gradient Boosting (XGBoost, LightGBM), Análise de Sobrevida (Cox Proportional Hazards), Redes Neurais.
- **Métrica principal:** ROC-AUC (prioriza detecção de verdadeiros positivos com mínimo de falsos alarmes).

⚠ Desbalanceamento de Classes em Churn

Taxas de churn geralmente são entre 2% e 15%, causando forte desbalanceamento. Use técnicas como SMOTE, `class_weight='balanced'` ou thresholding customizado para melhorar o recall na classe minoritária.

3.2.3 Valor do Ciclo de Vida (CLV)

O **Customer Lifetime Value** quantifica o valor total esperado que um cliente gerará ao longo do relacionamento com a empresa:

$$CLV = \sum_{t=1}^T \frac{m_t \cdot r_t}{(1+d)^t} \quad (4)$$

onde m_t é a margem de contribuição no período t , r_t é a probabilidade de retenção acumulada até t e d é a taxa de desconto (custo de capital).

Modelos preditivos de CLV (BG/NBD + Gamma-Gamma, Pareto/NBD) permitem estimar o CLV individual para priorização de clientes.

3.2.4 Sistemas de Recomendação

Os sistemas de recomendação são uma das aplicações de DM com maior impacto comercial: representam 35% das vendas da Amazon e 75% do conteúdo consumido na Netflix.

Filtragem Colaborativa (Collaborative Filtering) **User-based CF:** recomenda itens preferidos por usuários similares:

$$\hat{r}_{u,i} = \bar{r}_u + \frac{\sum_{v \in N(u)} \text{sim}(u,v) (r_{v,i} - \bar{r}_v)}{\sum_{v \in N(u)} |\text{sim}(u,v)|} \quad (5)$$

Item-based CF: calcula similaridade entre itens a partir de co-avaliações, mais estável para grandes catálogos (Sarwar et al., 2001).

Matrix Factorization: decompõe a matriz de avaliações $R \approx P \cdot Q^T$, onde $P \in \mathbb{R}^{|U| \times k}$ são fatores latentes de usuários e $Q \in \mathbb{R}^{|I| \times k}$ são fatores latentes de itens. O problema de otimização é:

$$\min_{P,Q} \sum_{(u,i) \in \Omega} (r_{ui} - p_u^T q_i)^2 + \lambda (\|P\|_F^2 + \|Q\|_F^2) \quad (6)$$

onde Ω é o conjunto de avaliações observadas e λ é o termo de regularização L2 que previne overfitting (Koren et al., 2009).

Filtragem por Conteúdo (Content-Based Filtering) Recomenda itens similares ao histórico do usuário, baseando-se em atributos dos itens:

- Perfil do item: vetor TF-IDF construído a partir de descrição, gênero, tags.


- Similaridade por cosseno entre perfil do usuário e perfis dos itens:

$$\cos(\theta) = \frac{\mathbf{u} \cdot \mathbf{v}}{\|\mathbf{u}\| \cdot \|\mathbf{v}\|} \quad (7)$$

Métodos Híbridos A abordagem híbrida combina CF e CB, superando limitações individuais:

- **Cold-start problem:** CF falha para novos usuários/itens; CB resolve parcialmente.
- **Netflix Prize (2009):** a solução vencedora combinou mais de 100 modelos diferentes, com Matrix Factorization como base.

Arquitetura de um Sistema de Recomendação



Deep Learning para Recomendação

- **NCF** (Neural Collaborative Filtering, He et al., 2017): substitui o produto escalar de MF por MLP.
- **Wide & Deep** (Google, 2016): combina aprendizado de regras memorizadas (Wide) com generalização (Deep) para recomendação em app stores.
- **BERT4Rec** (Sun et al., 2019): modelagem sequencial de sessões do usuário com mecanismo de atenção bidirecional.
- **LightGCN** (He et al., 2020): graph neural network simplificada para CF, propagando embeddings no grafo usuário-item.
- **Two-Tower Models:** encoders separados para usuário e item, treinados com contrastive learning; amplamente usados em YouTube e TikTok para retrieval em escala.

Métricas de Avaliação

Tabela 3: Métricas para avaliação de sistemas de recomendação

Métrica	Fórmula / Descrição	Mede
Precision@K	$\frac{ \text{relevantes} \cap \text{Top-K} }{K}$	Acerto na lista
Recall@K	$\frac{ \text{relevantes} \cap \text{Top-K} }{ \text{relevantes} }$	Cobertura de relevantes
NDCG@K	DCG normalizado pelo IDCG	Ranking ordenado
MAP	Média das precisões nos pontos de recall	Ranking geral
Hit Rate	$\frac{\text{usuários com } \geq 1 \text{ acerto}}{ \text{usuários} }$	Experiência mínima
Coverage	% do catálogo recomendado	Diversidade de catálogo
Diversity	Dissimilaridade média na lista	Variedade intra-lista
Serendipity	Novidade útil e surpreendente	Descoberta

4 Análise de Sentimentos e Opinião

A **Análise de Sentimentos** (Sentiment Analysis, Opinion Mining) é a área de NLP focada em identificar, extrair e quantificar opiniões subjetivas expressas em texto. Com o crescimento exponencial de avaliações online, posts em redes sociais e comentários de usuários, tornou-se essencial para monitoramento de marca, análise de produto e inteligência competitiva.

4.1 Tarefas na Análise de Sentimentos

1. **Análise de sentimento em nível de documento:** classifica o documento inteiro como positivo, negativo ou neutro.
2. **Análise de sentimento em nível de sentença:** classifica cada sentença individualmente.
3. **Análise de sentimento baseada em aspectos (ABSA, Aspect-Based Sentiment Analysis):** identifica aspectos mencionados e o sentimento associado a cada um.
4. **Reconhecimento de emoções:** classifica texto em emoções básicas, a saber: alegria, tristeza, raiva, medo, desgosto e surpresa (Ekman, 1992).
5. **Mineração de opiniões:** extração estruturada de (detentor da opinião, alvo da opinião, expressão de opinião, sentimento, tempo).

4.2 Abordagem Baseada em Léxico

Léxico de Sentimentos

Dicionário que associa palavras ou frases a polaridades e intensidades de sentimento. Ex: “excelente” → positivo (+3), “terrível” → negativo (-3).

VADER (Valence Aware Dictionary and sEntiment Reasoner) VADER (Hutto & Gilbert, 2014) é um analisador léxico-baseado em regras especialmente eficaz para textos de mídias sociais:

- Lida com pontuação (“!!!”), capitalização (“ÓTIMO”), emoticons e gírias.
- Retorna escores: positivo, negativo, neutro e compound $\in [-1, 1]$.
- Compound $\geq 0.05 \rightarrow$ positivo; $\leq -0.05 \rightarrow$ negativo; caso contrário neutro.

Outros léxicos: **SentiWordNet** (escores positivo/negativo/objetivo por synset), **AFINN** (lista de 3.382 palavras pontuadas de -5 a $+5$), **OpLexicon** (português brasileiro).

Vantagens: não requer dados de treinamento, transparente e interpretável, rápido.

Desvantagens: não captura contexto, problemas com negação implícita e ironia.

4.3 Abordagem Baseada em ML Clássico

- **Representação:** Bag of Words (BoW), TF-IDF, n-gramas, word embeddings (Word2Vec, GloVe, FastText).
- **Algoritmos:** SVM (melhor desempenho geral), Naive Bayes (eficiente para texto), Regressão Logística (interpretável), Random Forest.
- **Pipeline típico:** tokenização $\rightarrow$ TF-IDF $\rightarrow$ seleção de features $\rightarrow$ treinamento $\rightarrow$ avaliação com F1-score.

Listing 3: Pipeline de SA com TF-IDF e SVM

```
1 from sklearn.pipeline import Pipeline
2 from sklearn.feature_extraction.text import TfidfVectorizer
3 from sklearn.svm import LinearSVC
4
5 pipeline = Pipeline([
6     ('tfidf', TfidfVectorizer(ngram_range=(1,2), max_features=50000)),
7     ('clf', LinearSVC(C=1.0, max_iter=2000))
8 ])
9 pipeline.fit(X_train, y_train)
10 print(classification_report(y_test, pipeline.predict(X_test)))
```


4.4 Deep Learning para Sentimentos

BERT (Devlin et al., 2019) O BERT (Bidirectional Encoder Representations from Transformers) revolucionou o NLP ao aprender representações contextualizadas em duas fases:

1. **Pré-treinamento:** Masked Language Model (MLM) + Next Sentence Prediction (NSP) em corpus massivo (Wikipedia + BooksCorpus).
2. **Fine-tuning:** adição de uma camada de classificação e ajuste fino no dataset de sentimentos específico.

Variantes relevantes: **RoBERTa** (Liu et al., 2019), **DistilBERT** (56% do tamanho, 97% da acurácia), **BERTimbau** (BERT pré-treinado em português, Souza et al., 2020).

Pipeline de Análise de Sentimentos



4.5 Aspect-Based Sentiment Analysis (ABSA)

A ABSA vai além da polaridade global do texto, extraindo o sentimento por aspecto:

💡 Exemplo de ABSA

“A câmera do celular é ótima, mas a bateria dura pouco.”

Aspecto	Sentimento	Expressão
Câmera	Positivo	“ótima”
Bateria	Negativo	“dura pouco”

Modelos de ABSA: datasets SemEval 2014/2015/2016, BERT-ADA (adaptado ao domínio), LCF-BERT (Local Context Focus). A tarefa é subdividida em: extração de termos de aspectos (ATE), classificação de sentimento por aspecto (ASC) e extração conjunta fim-a-fim.

5 Mineração de Redes Sociais

5.1 Análise de Redes Sociais (ARS)

📄 Grafo de Rede Social

Uma rede social é modelada como um grafo $G = (V, E)$, onde V é o conjunto de atores (usuários, organizações) e E é o conjunto de relações (amizade, seguimento, co-autoria). Grafos podem ser dirigidos ou não dirigidos, ponderados ou não ponderados.

5.1.1 Medidas de Centralidade

Tabela 4: Medidas de centralidade em redes sociais

Medida	Definição	Interpreta
Degree	$C_D(v) = \deg(v)$	Número de conexões diretas
Betweenness	Fração de caminhos mínimos passando por v	Intermediário / ponte
Closeness	Inverso da soma das distâncias	Velocidade de difusão
Eigenvector	Influência ponderada pelos vizinhos	Prestígio / influência
PageRank	Variante do eigenvector para grafos dirigidos	Autoridade na rede

5.1.2 Detecção de Comunidades

- **Algoritmo de Louvain:** otimização gulosa da modularidade Q ; escala para redes com milhões de nós.
- **Girvan-Newman:** remoção iterativa de arestas com maior betweenness; dendrograma hierárquico.
- **Modularidade:** $Q = \frac{1}{2m} \sum_{ij} \left[A_{ij} - \frac{k_i k_j}{2m} \right] \delta(c_i, c_j)$

5.1.3 Modelos de Propagação

- **SIR:** Suscetível $\rightarrow$ Infectado $\rightarrow$ Recuperado; modela viral de conteúdo.
- **SIS:** Suscetível $\rightarrow$ Infectado $\rightarrow$ Suscetível; modela rumores recorrentes.
- **Maximização de Influência:** problema NP-hard, aproximado com algoritmo guloso (Kempe et al., 2003).

5.2 Extração de Conhecimento de Redes Sociais

- **Predição de links:** prever novas conexões usando índice de Jaccard, adamic-adar, common neighbors.
- **Inferência de atributos:** deduzir localização, interesses ou características demográficas de usuários.
- **Propagação de influência:** identificar os k usuários mais influentes para maximizar a difusão de informação.
- **Dinâmica temporal:** evolução da rede ao longo do tempo, formação de comunidades, dissolução de laços.

6 Ética, Privacidade e LGPD em Aplicações

⚠ LGPD e Mineração de Dados

A Lei Geral de Proteção de Dados (Lei 13.709/2018) estabelece requisitos que impactam diretamente projetos de mineração de dados: base legal para tratamento, minimização de dados, direito ao esquecimento, transparência algorítmica e relatório de impacto à proteção de dados (RIPD).

Principais Requisitos da LGPD em Aplicações de DM

- **Base legal:** consentimento explícito ou legítimo interesse devidamente fundamentado.
- **Minimização:** coletar apenas dados necessários para a finalidade declarada.

- **Anonimização: k-anonimato** (cada registro indistinguível de pelo menos $k - 1$ outros), **l-diversidade** (pelo menos l valores diferentes para atributos sensíveis), **privacidade diferencial** (ruído calibrado para proteger indivíduos).
- **Viés algorítmico:** sistemas de recomendação podem criar *filter bubbles* (câmaras de eco), reforçando opiniões sem expor o usuário a perspectivas diversas.
- **Transparência:** direito à explicação de decisões automatizadas (artigo 20 da LGPD).

7 Estado da Arte (2020–2024)

LLMs para Text Mining e Sentimentos

Grandes Modelos de Linguagem (GPT-4, Claude 3, Llama 3, Gemini) demonstraram capacidade de análise de sentimentos zero-shot e few-shot com desempenho comparável a modelos fine-tuned em muitos benchmarks. A abordagem elimina a necessidade de datasets anotados, porém enfrenta desafios de custo computacional, latência e consistência em idiomas de baixo recurso como o português. LLM-based opinion mining sem fine-tuning especializado é viável para tarefas gerais, mas modelos menores fine-tuned superam LLMs em tarefas de domínio específico (e.g., sentimentos em laudos médicos).

Sistemas de Recomendação com Transformers e GNNs

Recomendação sequencial com BERT4Rec e SASRec (Self-Attentive Sequential Recommendation) tornaram-se estado da arte. LLM-augmented recommendations como LLaRA e ChatRec (2023) usam LLMs como feature encoders ou como motor de raciocínio para explicações. Recomendações multimodais (texto + imagem + vídeo) com encoders CLIP-based. Graph Neural Networks para CF: LightGCN (2020) e NGCF (2019) superam MF tradicional em datasets esparsos ao propagar embeddings no grafo bipartido usuário-item.

Fake News e Desinformação

Mineração de dados aplicada à detecção de fake news combina análise de grafo de propagação (quem compartilhou, quando, para quem) com NLP sobre o conteúdo. Modelos de credibilidade de fontes avaliam histórico de precisão jornalística. Detecção multimodal integra análise de texto e imagem (verificação de manipulação de imagens com redes de análise forense). Desafio: arms race entre geradores de desinformação (LLMs) e detectores.

8 Exercícios

1. **[Sistema de Recomendação do Zero]** Implemente um sistema de filtragem colaborativa user-based usando apenas NumPy. Dado uma matriz 5×6 de avaliações

(com zeros para não-avaliados), calcule a similaridade cosseno entre usuários e preveja a avaliação do usuário 1 para o item 4.

2. **[Análise de Sentimentos com VADER e BERT]** Colete 50 avaliações de um produto no Mercado Livre ou Amazon.com.br. Analise-as com VADER e com BERT-Timbau (fine-tuned para sentimentos). Compare os resultados em uma tabela, identificando pelo menos 5 casos onde os modelos divergem e explique por quê.
3. **[Segmentação para CRM]** Com o dataset “Online Retail” (UCI ML Repository), calcule RFM para cada cliente, aplique K-Means com $k = 4$ e crie um relatório descritivo de cada segmento incluindo: tamanho, RFM médio, percentual de receita e estratégia de marketing sugerida.
4. **[Pipeline de Web Scraping]** Construa um pipeline com Scrapy para extrair manchetes e timestamps das últimas 100 notícias de um portal de tecnologia. Armazene em CSV, remova duplicatas e aplique análise de sentimentos com VADER para calcular o sentimento médio por dia da semana.
5. **[Implementação do PageRank]** Implemente o algoritmo PageRank por iteração de potência em Python usando NumPy, sem bibliotecas de grafos. Teste com um grafo web de 10 páginas (definido manualmente) e compare com o resultado de `networkx.pagerank()`. Discuta convergência e fator de amortecimento.
6. **[ABSA Manual]** Dadas as 10 avaliações a seguir de um restaurante, faça ABSA manualmente identificando aspectos (comida, serviço, ambiente, preço) e o sentimento associado. Em seguida, implemente um classificador simples de ABSA com BERT para as mesmas avaliações e compare.
7. **[Análise Ética]** Escolha uma aplicação real de mineração de dados (e.g., sistema de recomendação de notícias, scoring de crédito, análise de sentimentos em redes sociais). Identifique: (a) dados coletados e base legal LGPD, (b) potenciais vieses algorítmicos, (c) riscos de privacidade, (d) mecanismos de transparência necessários. Escreva um relatório de 2 páginas.

9 Referências

Referências

- [1] Page, L., Brin, S., Motwani, R., & Winograd, T. (1999). *The PageRank citation ranking: Bringing order to the Web*. Stanford InfoLab Technical Report.
- [2] Kleinberg, J. M. (1999). Authoritative sources in a hyperlinked environment. *Journal of the ACM*, 46(5), 604–632.
- [3] Sarwar, B., Karypis, G., Konstan, J., & Riedl, J. (2001). Item-based collaborative filtering recommendation algorithms. In *Proceedings of WWW 2001* (pp. 285–295).
- [4] Koren, Y., Bell, R., & Volinsky, C. (2009). Matrix factorization techniques for recommender systems. *Computer*, 42(8), 30–37.

- [5] He, X., Liao, L., Zhang, H., Nie, L., Hu, X., & Chua, T. S. (2017). Neural collaborative filtering. In *Proceedings of WWW 2017* (pp. 173–182).
- [6] He, X., Deng, K., Wang, X., Li, Y., Zhang, Y., & Wang, M. (2020). LightGCN: Simplifying and powering graph convolution network for recommendation. In *Proceedings of SIGIR 2020* (pp. 639–648).
- [7] Sun, F., Liu, J., Wu, J., Pei, C., Lin, X., Ou, W., & Jiang, P. (2019). BERT4Rec: Sequential recommendation with bidirectional encoder representations from Transformer. In *Proceedings of CIKM 2019* (pp. 1441–1450).
- [8] Devlin, J., Chang, M. W., Lee, K., & Toutanova, K. (2019). BERT: Pre-training of deep bidirectional transformers for language understanding. In *Proceedings of NAACL-HLT 2019* (pp. 4171–4186).
- [9] Hutto, C., & Gilbert, E. (2014). VADER: A parsimonious rule-based model for sentiment analysis of social media text. In *Proceedings of ICWSM 2014*.
- [10] Pang, B., & Lee, L. (2008). Opinion mining and sentiment analysis. *Foundations and Trends in Information Retrieval*, 2(1–2), 1–135.
- [11] Liu, B. (2012). *Sentiment Analysis and Opinion Mining*. Morgan & Claypool Publishers.
- [12] Blei, D. M., Ng, A. Y., & Jordan, M. I. (2003). Latent Dirichlet allocation. *Journal of Machine Learning Research*, 3, 993–1022.
- [13] Srikant, R., & Agrawal, R. (1996). Mining sequential patterns: Generalizations and performance improvements. In *Proceedings of EDBT 1996* (pp. 1–17).
- [14] Souza, F., Nogueira, R., & Lotufo, R. (2020). BERTimbau: Pretrained BERT models for Brazilian Portuguese. In *Brazilian Conference on Intelligent Systems (BRACIS)*.